
Criterio 1: Entendimiento del objetivo del repositorio

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Versión 1.0 · 29 de agosto de 2026

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario para lectores sin formación en programación	2
2. Entendimiento del objetivo del repositorio	3
2.1. Preguntas de investigación que el repositorio responde	4
3. Relación con los demás criterios	4
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 1 de la rúbrica**: *Entendimiento del objetivo del repositorio*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica.

En resumen: Este criterio evalúa si el equipo entendió qué se proponía el repositorio: construir un observatorio crítico del sistema de reconocimiento de investigadores de MinCiencias (2013–2021), responder 7 preguntas de investigación y producir evidencia para un informe sobre las falencias del sistema.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (**maestro.auditoria.pdf**, 114 págs.). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario para lectores sin formación en programación

Los documentos usan términos técnicos con moderación; cuando aparecen, esta tabla los explica en lenguaje sencillo:

Tabla 1. Glosario de términos en lenguaje llano

Término	Qué significa
HHI (Herfindahl-Hirschman)	Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.
Matriz de transición	Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores.
Tasa de retención	Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.
Representación relativa	Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.

Término	Qué significa
k-prototypes	Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).
MCA / FAMD	Técnicas para resumir tablas con muchas categorías en pocos ejes visualizables, de modo que se puedan ver patrones (p. ej. qué áreas se asocian con qué géneros).
CRISP-DM	Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.
Modelo dimensional (esquema estrella)	Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes.
DuckDB	Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.
Mojibake	Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.
ETL / pipeline	Cadena de procesos que extrae los datos de la fuente (ETL: Extraer, Transformar, Cargar), los limpia y los deja listos para analizar.
CI/CD y Docker	Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.
Sprint	Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.

2 Entendimiento del objetivo del repositorio

El objetivo del repositorio es claro y bien documentado: consolidar, validar y analizar el padrón de investigadores reconocidos por MinCiencias y producir un observatorio crítico con evidencia sobre la fiabilidad, comparabilidad y equidad del sistema de reconocimiento. La documentación (README, informe_final.md, catálogo YAML) permite entender sin ambigüedad qué se buscaba. Se observa una evolución del alcance: el informe inicial trabajaba con 3 convocatorias (2017/2019/2021) y la versión final del README cubre 6 (2013-2021), incorporando producción, diversidad y redes; esta ampliación es coherente con un observatorio en maduración, aunque obliga a reinterpretar las métricas de las primeras fases. Punto de mejora: formalizar un marco de indicadores (definición operativa, fórmula, fuente y límites de cada métrica) para que la entrega sea auditable.

2.1 Preguntas de investigación que el repositorio responde

El repositorio declara 7 preguntas (README): fiabilidad de los datos, retención entre convocatorias, concentración territorial, brecha de género, redes de co-filiación, diversidad poblacional y productividad cruzada con el dataset de producción. Cada pregunta mapea a un módulo de análisis (`src/analisis/*`), lo que demuestra una descomposición objetivo → preguntas → módulos correcta y trazable.

3 Relación con los demás criterios

Este documento se centra en el criterio 1. Los demás criterios de la rúbrica — Datos utilizados: suficiencia y corrección; Documentación y crítica por archivo de código; Validación de la calidad estadística; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

El objetivo del repositorio está bien entendido y correctamente descompuesto en preguntas que los módulos efectivamente responden (patrón Pregunta ->Hallazgo ->Caveat). Recomendaciones: (1) formalizar un marco de indicadores; (2) documentar la evolución del alcance 3 ->6 convocatorias en un único documento; (3) alinear README, catálogo y artefactos versionados (el consolidado versionado solo cubre 3 convocatorias — ver criterio 2).

Referencias
