

---

## Criterio 2: Datos utilizados: suficiencia y corrección

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

---

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Versión 1.0 · 29 de agosto de 2026

---

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

## Índice

---

|                                                                     |          |
|---------------------------------------------------------------------|----------|
| <b>1. Contexto y guía de lectura</b>                                | <b>2</b> |
| 1.1. Qué es este documento . . . . .                                | 2        |
| 1.2. Glosario para lectores sin formación en programación . . . . . | 2        |
| <b>2. Datos utilizados: suficiencia y corrección</b>                | <b>3</b> |
| 2.1. Fuentes del repositorio . . . . .                              | 4        |
| <b>3. Relación con los demás criterios</b>                          | <b>4</b> |
| <b>4. Conclusiones y recomendaciones del criterio</b>               | <b>4</b> |

## 1 Contexto y guía de lectura

### 1.1 Qué es este documento

Este documento desarrolla el **criterio 2 de la rúbrica**: *Datos utilizados: suficiencia y corrección*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica.

**En resumen:** Este criterio evalúa si los datos del proyecto eran suficientes y correctos. Conclusión principal: los datos correctos existen y son suficientes (30.086 investigadores únicos, 3.166.629 productos), pero el archivo consolidado versionado en el repositorio está incompleto: solo contiene 3 de las 6 convocatorias, por lo que un clon del repositorio no reproduce todos los resultados del informe.

#### Nota metodológica

**Cómo leer este documento:** cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro\_auditoria.pdf*, 114 págs.). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

### 1.2 Glosario para lectores sin formación en programación

Los documentos usan términos técnicos con moderación; cuando aparecen, esta tabla los explica en lenguaje sencillo:

**Tabla 1.** Glosario de términos en lenguaje llano

| Término                       | Qué significa                                                                                                                                                                                                          |
|-------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| HHI<br>(Herfindahl-Hirschman) | Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.                  |
| Matriz de transición          | Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores. |
| Tasa de retención             | Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.                                                                          |
| Representación relativa       | Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.  |

| Término                               | Qué significa                                                                                                                                                                                    |
|---------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| k-prototypes                          | Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).                                           |
| MCA / FAMD                            | Técnicas para resumir tablas con muchas categorías en pocos ejes visualizables, de modo que se puedan ver patrones (p. ej. qué áreas se asocian con qué géneros).                                |
| CRISP-DM                              | Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.                                        |
| Modelo dimensional (esquema estrella) | Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes. |
| DuckDB                                | Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.                                                |
| Mojibake                              | Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.                                                                      |
| Contrato de esquema                   | Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.                                                                   |
| ETL / pipeline                        | Cadena de procesos que extrae los datos de la fuente (ETL: Extraer, Transformar, Cargar), los limpia y los deja listos para analizar.                                                            |
| CI/CD y Docker                        | Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.                                            |
| Sprint                                | Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.                                                                                                                 |

## 2 Datos utilizados: suficiencia y corrección

VERIFICADO EMPÍRICAMENTE: el consolidado versionado (XLSX y CSV en `datos/tarea_.join/`) contiene solo 50.891 filas y 3 convocatorias (2017: 13.001, 2019: 16.796, 2021: 21.094), frente a las 77.237 filas y 6 convocatorias (2013-2021) declaradas en el README y el catálogo. Las evidencias versionadas (p. ej. matrices de transición 2013-2014) sí cubren las 6 convocatorias, lo que indica que el artefacto versionado es un snapshot de la fase inicial de 3 convocatorias nunca actualizado. Consecuencia verificada: ejecutar el pipeline en un clon fresco genera solo 2 periodos de transición (2017-2019, 2019-2021) en vez de 5, y los resultados no reproducen el README. El CSV paralelo además presenta mojibake (UTF-8/Latin-1). El dataset de producción (~1.2 GB) está gitignored y no es reproducible desde el clon. En cuanto a la corrección de las fuentes: el padrón es la fuente oficial del sistema de reconocimiento y el dataset de producción su complemento natural; la elección de datos abiertos (`datos.gov.co/Socrata`) es apropiada y verificable.

## 2.1 Fuentes del repositorio

- **Padrón de investigadores** (Socrata bqtm-4y2h): convocatorias 2013–2021, 30 variables, **77 237 registros declarados** y 30 086 investigadores únicos.
- **Producción de grupos** (Socrata 33dq-ab5a): 3 166 629 filas producto-autor; dataset grande, no versionado en git.
- **Catálogo**: datos/catalogo.yaml con metadatos, diccionario de datos y llaves de cruce (`id_persona_pr` ↔ `id_persona_pd`).

### Nota metodológica

Los datos no son solo los archivos: también se evaluó *cómo se versionaron* en el repositorio. El detalle de la verificación (conteos reales, codificación, hallazgos) está en este documento y en el maestro.

## 3 Relación con los demás criterios

Este documento se centra en el criterio 2. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Documentación y crítica por archivo de código; Validación de la calidad estadística; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

## 4 Conclusiones y recomendaciones del criterio

Veredicto: los datos correctos existen y son suficientes para el objetivo, pero su versionado en el repositorio está incompleto (3 de 6 convocatorias) — un clon fresco no reproduce los hallazgos. Acciones prioritarias: (1) reconstruir y versionar el consolidado de 6 convocatorias; (2) normalizar UTF-8 y añadir contratos de esquema (pandera); (3) versionar el dataset de producción o documentar su ingesta reproducible; (4) declarar en el README qué artefacto es canónico.

## Referencias