
Criterio 2: Datos utilizados: suficiencia y corrección

Documentación técnica de auditoría · Versión LITE (versión resumida) · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Versión LITE (versión resumida) · 29 de agosto de 2026

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario para lectores sin formación en programación	2
2. Datos utilizados: suficiencia y corrección	3
2.1. Fuentes del repositorio	4
3. Relación con los demás criterios	4
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 2 de la rúbrica**: *Datos utilizados: suficiencia y corrección*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica.

En resumen: Este criterio evalúa si los datos del proyecto eran suficientes y correctos. Conclusión principal: los datos correctos existen y son suficientes (30.086 investigadores únicos, 3.166.629 productos), pero el archivo consolidado versionado en el repositorio está incompleto: solo contiene 3 de las 6 convocatorias, por lo que un clon del repositorio no reproduce todos los resultados del informe.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro_auditoria.pdf*, 114 págs.). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario para lectores sin formación en programación

Los documentos usan términos técnicos con moderación; cuando aparecen, esta tabla los explica en lenguaje sencillo:

Tabla 1. Glosario de términos en lenguaje llano

Término	Qué significa
HHI (Herfindahl-Hirschman)	Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.
Matriz de transición	Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores.
Tasa de retención	Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.
Representación relativa	Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.

Término	Qué significa
k-prototypes	Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).
MCA / FAMD	Técnicas para resumir tablas con muchas categorías en pocos ejes visualizables, de modo que se puedan ver patrones (p. ej. qué áreas se asocian con qué géneros).
CRISP-DM	Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.
Modelo dimensional (esquema estrella)	Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes.
DuckDB	Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.
Mojibake	Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.
ETL / pipeline	Cadena de procesos que extrae los datos de la fuente (ETL: Extraer, Transformar, Cargar), los limpia y los deja listos para analizar.
CI/CD y Docker	Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.
Sprint	Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.

2 Datos utilizados: suficiencia y corrección

VERIFICADO EMPÍRICAMENTE: el consolidado versionado (XLSX y CSV en `datos/tarea_.join/`) contiene solo 50.891 filas y 3 convocatorias (2017: 13.001, 2019: 16.796, 2021: 21.094), frente a las 77.237 filas y 6 convocatorias (2013-2021) declaradas en el README y el catálogo. Las evidencias versionadas (p. ej. matrices de transición 2013-2014) sí cubren las 6 convocatorias, lo que indica que el artefacto versionado es un snapshot de la fase inicial de 3 convocatorias nunca actualizado. Consecuencia verificada: ejecutar el pipeline en un clon fresco genera solo 2 periodos de transición (2017-2019, 2019-2021) en vez de 5, y los resultados no reproducen el README. El CSV paralelo además presenta mojibake (UTF-8/Latin-1). El dataset de producción (~1.2 GB) está gitignored y no es reproducible desde el clon. En cuanto a la corrección de las fuentes: el padrón es la fuente oficial del sistema de reconocimiento y el dataset de producción su complemento natural; la elección de datos abiertos (`datos.gov.co/Socrata`) es apropiada y verificable.

2.1 Fuentes del repositorio

- **Padrón de investigadores** (Socrata bqtm-4y2h): convocatorias 2013–2021, 30 variables, **77 237 registros declarados** y 30 086 investigadores únicos.
- **Producción de grupos** (Socrata 33dq-ab5a): 3 166 629 filas producto-autor; dataset grande, no versionado en git.
- **Catálogo**: datos/catalogo.yaml con metadatos, diccionario de datos y llaves de cruce (`id_persona_pr` ↔ `id_persona_pd`).

Nota metodológica

Los datos no son solo los archivos: también se evaluó *cómo se versionaron* en el repositorio. El detalle de la verificación (conteos reales, codificación, hallazgos) está en este documento y en el maestro.

3 Relación con los demás criterios

Este documento se centra en el criterio 2. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Documentación y crítica por archivo de código; Validación de la calidad estadística; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

Veredicto: los datos correctos existen y son suficientes para el objetivo, pero su versionado en el repositorio está incompleto (3 de 6 convocatorias) — un clon fresco no reproduce los hallazgos. Acciones prioritarias: (1) reconstruir y versionar el consolidado de 6 convocatorias; (2) normalizar UTF-8 y añadir contratos de esquema (pandera); (3) versionar el dataset de producción o documentar su ingesta reproducible; (4) declarar en el README qué artefacto es canónico.

Referencias