

---

## Criterio 4: Validación de la calidad de pruebas, tratamientos y lógica estadística

Documentación técnica de auditoría · Versión LITE (versión resumida) · Un documento  
por criterio de la rúbrica

---

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Versión LITE (versión resumida) · 29 de agosto de 2026

---

## Índice

---

|                                                                                  |          |
|----------------------------------------------------------------------------------|----------|
| <b>1. Contexto y guía de lectura</b>                                             | <b>2</b> |
| 1.1. Qué es este documento . . . . .                                             | 2        |
| 1.2. Glosario para lectores sin formación en programación . . . . .              | 2        |
| <b>2. Validación de la calidad de pruebas, tratamientos y lógica estadística</b> | <b>3</b> |
| <b>3. Relación con los demás criterios</b>                                       | <b>4</b> |
| <b>4. Conclusiones y recomendaciones del criterio</b>                            | <b>4</b> |

## 1 Contexto y guía de lectura

### 1.1 Qué es este documento

Este documento desarrolla el **criterio 4 de la rúbrica**: *Validación de la calidad de pruebas, tratamientos y lógica estadística*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica.

**En resumen:** Este criterio evalúa el rigor estadístico: cómo se limpiaron los datos (atípicos, faltantes) y si los métodos usados (matrices de transición, índices de concentración, comparaciones de género y diversidad, redes, agrupamientos) son correctos. Conclusión: la estadística descriptiva es sólida y transparente; la principal debilidad es la falta de inferencia formal (intervalos de confianza, pruebas de supuestos, modelos ajustados).

#### Nota metodológica

**Cómo leer este documento:** cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro\_auditoria.pdf*, 114 págs.). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

### 1.2 Glosario para lectores sin formación en programación

Los documentos usan términos técnicos con moderación; cuando aparecen, esta tabla los explica en lenguaje sencillo:

**Tabla 1.** Glosario de términos en lenguaje llano

| Término                       | Qué significa                                                                                                                                                                                                          |
|-------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| HHI<br>(Herfindahl-Hirschman) | Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.                  |
| Matriz de transición          | Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores. |
| Tasa de retención             | Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.                                                                          |
| Representación relativa       | Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.  |

| Término                               | Qué significa                                                                                                                                                                                    |
|---------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| k-prototypes                          | Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).                                           |
| MCA / FAMD                            | Técnicas para resumir tablas con muchas categorías en pocos ejes visualizables, de modo que se puedan ver patrones (p. ej. qué áreas se asocian con qué géneros).                                |
| CRISP-DM                              | Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.                                        |
| Modelo dimensional (esquema estrella) | Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes. |
| DuckDB                                | Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.                                                |
| Mojibake                              | Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.                                                                      |
| Contrato de esquema                   | Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.                                                                   |
| ETL / pipeline                        | Cadena de procesos que extrae los datos de la fuente (ETL: Extraer, Transformar, Cargar), los limpia y los deja listos para analizar.                                                            |
| CI/CD y Docker                        | Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.                                            |
| Sprint                                | Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.                                                                                                                 |

## 2 Validación de la calidad de pruebas, tratamientos y lógica estadística

Tratamientos: eliminación de 22 atípicos de edad (>100 años) con justificación documentada (0.028 % del padrón, sesgo despreciable) y comparación con imputación por mediana del grupo; imputación por mediana en numéricas (reduce varianza; aplicada a ordinales — cuestionable); etiqueta NO REPORTADO en categóricas; verificación de unicidad de IDs por coherencia de edad (+/-4 años) y género (heurística razonable sin formalizar). Veredicto por eje: (a) longitudinal: matrices de Markov empíricas correctas, pero sin test de markovianidad ni homogeneidad temporal, y sin supervivencia (Kaplan-Meier/Cox) para el tiempo hasta la salida; (b) territorial: HHI correcto pero sin IC bootstrap ni Gini/Theil; (c) género/diversidad: proporciones y representación relativa vs DANE correctas en concepto, pero sin modelos ajustados y con el bug del denominador 'NINGUN GRUPO ETNICO' (comentario vs código, diluye la subrepresentación); (d) redes: métricas sin modelos nulos, red = corte transversal (captura solo 2019); (e) clustering legacy: k-prototypes con k=3 fijo sin validación

(silhouette/Calinski-Harabasz) y pérdida del 8.4 % de la muestra; (f) pruebas: chi-cuadrado mencionado sin verificar frecuencias esperadas. La estadística descriptiva es sólida; la inferencia formal es la principal debilidad.

### Nota metodológica

**Principio de la auditoría:** la crítica es constructiva. Cuando un análisis o un archivo está bien construido se dice explícitamente; las debilidades se presentan como oportunidades de mejora, no como reproches. El detalle metodológico por eje (Markov, HHI, brechas, redes, clustering) está en el documento maestro, sección 6.

## 3 Relación con los demás criterios

---

Este documento se centra en el criterio 4. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Datos utilizados: suficiencia y corrección; Documentación y crítica por archivo de código; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

## 4 Conclusiones y recomendaciones del criterio

---

La calidad de tratamientos y la lógica descriptiva son adecuadas y transparentes; la inferencia formal requiere ampliación. Acciones prioritarias: (1) test de markovianidad + modelos de supervivencia; (2) IC bootstrap en HHI y Gini/Theil; (3) modelos logísticos ajustados para brechas; (4) modelos nulos de red; (5) validación formal de clusters y migración del legacy R al pipeline Python; (6) corregir el denominador de `comparar_dane()` y unificar el conteo de atípicos (10 vs 22).

## Referencias

---