
Criterio 5: Lógica de creación del repositorio y cumplimiento del objetivo principal

Documentación técnica de auditoría · Versión LITE (versión resumida) · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Versión LITE (versión resumida) · 29 de agosto de 2026

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario para lectores sin formación en programación	2
2. Lógica de creación del repositorio y cumplimiento del objetivo principal	3
3. Relación con los demás criterios	4
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 5 de la rúbrica**: *Lógica de creación del repositorio y cumplimiento del objetivo principal*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica.

En resumen: Este criterio evalúa cómo se construyó el repositorio y si la ejecución fue correcta. Conclusión: la arquitectura y la lógica general son correctas y los entregables cumplen el objetivo; la ejecución fue buena en lo analítico pero no óptima en la industrialización (automatización, despliegue y pruebas), con varios flujos concretos que conviene corregir.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (**maestro.auditoria.pdf**, 114 págs.). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario para lectores sin formación en programación

Los documentos usan términos técnicos con moderación; cuando aparecen, esta tabla los explica en lenguaje sencillo:

Tabla 1. Glosario de términos en lenguaje llano

Término	Qué significa
HHI (Herfindahl-Hirschman)	Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.
Matriz de transición	Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores.
Tasa de retención	Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.
Representación relativa	Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.

Término	Qué significa
k-prototypes	Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).
MCA / FAMD	Técnicas para resumir tablas con muchas categorías en pocos ejes visualizables, de modo que se puedan ver patrones (p. ej. qué áreas se asocian con qué géneros).
CRISP-DM	Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.
Modelo dimensional (esquema estrella)	Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes.
DuckDB	Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.
Mojibake	Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.
ETL / pipeline	Cadena de procesos que extrae los datos de la fuente (ETL: Extraer, Transformar, Cargar), los limpia y los deja listos para analizar.
CI/CD y Docker	Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.
Sprint	Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.

2 Lógica de creación del repositorio y cumplimiento del objetivo principal

La construcción siguió dos etapas: (1) fase académica inicial (ago-oct 2025): notebooks tarea_* con análisis por convocatoria, join, dimensiones y gran tabla, sin pipeline unificado; (2) fase de ingeniería (oct 2025 - may 2026): CRISP-DM, src/ (ingesta, transformación, análisis, modelo dimensional DuckDB), scripts/sprint*_*.py, dashboard Streamlit, CI/CD y documentación (LaTeX, Reveal.js, manual). El alcance creció de 3 a 6 convocatorias e integró producción (Sprint 5) y ajustes del director (Sprint 6). La arquitectura final es correcta (ingesta -> transformación -> modelo dimensional -> análisis por sprint -> visualización) y la separación de responsabilidades en src/ es limpia. Flujos INCORRECTOS o NO ÓPTIMOS detectados: (1) CI/CD rota (GitHub Actions referencia módulos inexistentes src.ingesta.main / src.transformacion.main); (2) Dockerfile ejecuta app/streamlit_app.py (placeholder) en lugar del dashboard real y no copia hallazgos/; (3) duplicación de apps (raíz vs app/); (4) legacy R (clustering/multivariado) fuera del pipeline con rutas hardcoded Downloads/; (5) scikit-learn y pandera declarados

sin uso; (6) datos crudos sin versionar (sin DVC); (7) consolidado versionado incompleto (3 de 6 convocatorias); (8) artefactos duplicados (matriz_* vs *_ext vs *_obs); (9) nomenclatura desactualizada (Grupo7/Grupo8). La ejecución real verificada: 10 de 16 scripts corren OK en clon fresco.

Hallazgo

El repositorio se construyó en dos etapas: tareas académicas iniciales (notebooks, ago–oct 2025) y pipeline de ingeniería de datos (`src/` + `scripts/sprint*`, oct 2025 – may 2026). La valoración detallada de flujos correctos e incorrectos está en el documento maestro (sección 7) y en el PDF del criterio 5.

3 Relación con los demás criterios

Este documento se centra en el criterio 5. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Datos utilizados: suficiencia y corrección; Documentación y crítica por archivo de código; Validación de la calidad estadística y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

La lógica de creación es correcta en lo esencial y los entregables cumplen el objetivo declarado; la ejecución fue correcta en lo analítico pero no óptima en la industrialización (reproducibilidad, automatización, pruebas). Acciones: corregir CI/CD y Dockerfile, unificar apps, migrar el legacy, versionar datos y ampliar tests.

Referencias
