

Auditoría estadística reproducible del sistema de reconocimiento de investigadores de MinCiencias (2013–2021) con datos abiertos

Entrega 1 — Anteproyecto · Consultoría Estadística · USTA 2026-II

Kevin Leonardo Chaparro Reyes Valentina Muñoz Palma Paula Margarita Triana Ancinez

Universidad Santo Tomás

15 de septiembre de 2026

El problema: ¿qué audita un instrumento público de medición?

- MinCiencias reconoce por **convocatorias** (2013–2021) a los investigadores del país y los clasifica: Junior, Asociado, Senior, Emérito.
- Ese padrón es la **principal fuente administrativa de capital humano científico** y alimenta decisiones de política, financiación y carrera.
- **Problema doble:** (1) nadie audita la *calidad y comparabilidad* del registro; (2) la *inequidad* estructural no está cuantificada con rigor en una sola fuente.

A quién le importa: MinCiencias y el SNCTI · los investigadores · los tomadores de decisión de política de CTI.

Evidencia propia de que el problema existe

- Padrón público declara **77 237 registros / 6 convocatorias** (30 086 únicos)... pero el archivo consolidado verificado tiene **50 891 filas y 3 convocatorias** (781/2017, 833/2018 y 894/2021) con **26 662 personas únicas**.
- **22 registros con edad > 100 años** (máx. 956) y errores de codificación.
- Concentración territorial: **Bogotá + Antioquia = 51 %**; Bogotá retiene 92 % y absorbe 1 000+ investigadores.
- Brecha de género por área: **24 % mujeres en Ingeniería vs. 48 % en ciencias médicas**.
- Vs. censo DANE 2018: afro **3×**, indígena **7,9×**, discapacidad **8×** subrepresentados.
- Solo **36,9 %** de los autores de la producción declarada son investigadores reconocidos.

La pregunta que vamos a responder

Pregunta estadística responsable

¿El padrón de investigadores reconocidos de MinCiencias (2013–2021) es fiable, comparable entre convocatorias y equitativo, y qué mejoras metodológicas y de gobernanza de datos lo convertirían en la base sólida de un observatorio de capital humano científico?

Si nadie hace nada: decisiones de política y de carrera seguirán apoyándose en un instrumento cuya calidad no está auditada de forma reproducible.

Estado del arte: lo que ya se sabe

Enfoques (mundo):

- *Science of science* y métricas responsables (Fortunato 2018; Leiden 2015; CoARA 2022)
- Calidad de datos y reproducibilidad (Wang & Strong 1996; FAIR 2016)
- Carreras longitudinales: Markov, supervivencia, movilidad (Sinatra 2016; Deville 2014)
- Desigualdad (HHI/Gini/Theil), género (Larivière 2013), redes y jerarquías (Clauset 2015)

Vacío: falta una **auditoría estadística reproducible** del padrón que combine calidad + longitudinal + equidad.

En Colombia / región:

- Lattes (Brasil) y ScienTI-CVLAC/Publindex (Colombia)
- Críticas al modelo de categorización del SNCTI
- CONPES 4069 (ciencia abierta)

Contraste: cadenas de Markov (homogeneidad) vs. modelos de supervivencia (tiempo al evento).

General: cuantificar y auditar de forma reproducible la fiabilidad, comparabilidad y equidad del padrón (2013–2021) y entregar un marco de indicadores y un tablero de auditoría.

- 1 **Cuantificar la calidad** del registro (completitud, unicidad, validez, consistencia) por convocatoria.
- 2 **Estimar la dinámica longitudinal:** retención, transición de categoría y tiempo hasta la salida (Markov + supervivencia).
- 3 **Cuantificar la equidad:** concentración territorial (HHI/Gini/Theil) y representación de género, etnia, discapacidad y víctimas vs. DANE 2018.

Cada objetivo declara con qué evidencia se dará por cumplido; la secuencia es visible: registro limpio → panel fiable → lectura de equidad.

Datos abiertos verificados (datos.gov.co):

- Padrón bqtm-4y2h: declara 6 convocatorias (2013–2021); verificadas 3 en el artefacto (781/2017, 833/2018 y 894/2021)
- Producción 33dq-ab5a: 3,2 M filas (cruce por id_persona)
- Censo DANE 2018 (referencia de equidad)

Alternativa descartada: análisis de producción individual (h); requiere 1,2 GB y queda como extensión. **Plan si el dato no llega:** OE1–OE3 no dependen de ese dataset; redescarga por API.

Ruta en 3 etapas (Python + DuckDB, reproducible):

- 1 Auditoría de calidad (contratos de esquema)
- 2 Panel longitudinal: Markov + supervivencia (KM/Cox)
- 3 Equidad: HHI/Gini/Theil + razones de representación con IC

Qué no haremos (y por qué):

- No validaremos contra registros internos de MinCiencias (no accesibles): se audita la fuente pública declarada.
- No haremos modelos predictivos individuales ni análisis causal (fuera del alcance semestral).
- No profundizaremos en producción individual (h) en esta fase.

Riesgos con contingencia:

- 1 Discrepancia 77 237 vs. 50 891 → es un *hallazgo del objetivo*, no un bloqueo.
- 2 Producción no descargable → OE1–OE3 no dependen de ella.
- 3 Tiempo ajustado → priorización por hitos + 2 semanas de holgura.

Por qué cabe en el semestre

Cronograma por hitos (12 semanas, con holgura):

Semanas	Hito
1-2	Datos y contratos de esquema
3-4	Auditoría de calidad (OE1)
5-6	Panel y transiciones (OE2.a)
7-8	Supervivencia (OE2.b)
9-10	Equidad (OE3)
11	Marco de indicadores + tablero
12	Informe final y sustentación

Horas: $3 \text{ integrantes} \times 6 \text{ h/semana} \times 12 \text{ semanas} \approx 216 \text{ h}$; carga estimada $\approx 180 \text{ h} \Rightarrow$ **17 % de holgura.**

Cierre

- El problema es real y **ya medido** con cifras propias verificables.
- La literatura (mundo y Colombia) deja un **vacío claro**: falta la auditoría reproducible del registro.
- Los datos son **abiertos, accesibles y ya abiertos por el equipo**.
- El plan es **realista** (hitos, holgura, horas).

Aporte

Un marco de indicadores y un tablero de auditoría que permitan a MinCiencias y a la comunidad saber *qué tan confiable, comparable y equitativo* es el sistema de reconocimiento.

¡Gracias!