
Estado del Arte y Referentes para la Mejora Observatorio MinCiencias — Investigadores Reconocidos

Guía de literatura científica y buenas prácticas aplicadas a este repositorio

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio.Ministerio_de_Ciencias_Grupo8`

Commit auditado: 1528939

Versión 1.0 · 6 de septiembre de 2026

Índice

1. Introducción, alcance y método de la revisión	3
1.1. Propósito	3
1.2. Criterio de búsqueda y fuentes	3
1.3. Cómo leer este documento	3
2. Ciencia de la Ciencia (SciSci) y evaluación responsable	4
2.1. Qué dice la literatura	4
2.2. Relación con este repositorio	4
2.3. Mejoras recomendadas	4
3. Sistemas nacionales de información y evaluación: el modelo colombiano en perspectiva	5
3.1. Qué dice la literatura	5
3.2. Relación con este repositorio	5
3.3. Mejoras recomendadas	5
4. Calidad de datos, gobernanza y reproducibilidad para observatorios	6
4.1. Qué dice la literatura	6
4.2. Relación con este repositorio	6
4.3. Mejoras recomendadas	6
5. Dinámica longitudinal de carreras científicas: retención, transición y atrición	7
5.1. Qué dice la literatura	7
5.2. Relación con este repositorio	7
5.3. Mejoras recomendadas	8
6. Desigualdad y concentración de la ciencia (territorio, productividad e instituciones)	8
6.1. Qué dice la literatura	8
6.2. Relación con este repositorio	8
6.3. Mejoras recomendadas	9
7. Género y diversidad en la ciencia	9
7.1. Qué dice la literatura	9
7.2. Relación con este repositorio	9
7.3. Mejoras recomendadas	10
8. Redes institucionales: co-afiliación, jerarquías y endogamia académica	10
8.1. Qué dice la literatura	10
8.2. Relación con este repositorio	10
8.3. Mejoras recomendadas	11
9. Segmentación con datos mixtos: métodos y validación moderna	11
9.1. Qué dice la literatura	11

9.2. Relación con este repositorio	11
9.3. Mejoras recomendadas	11
10.Ética y protección de datos personales en registros de ciencia	12
10.1. Qué dice la literatura	12
10.2. Relación con este repositorio	12
10.3. Mejoras recomendadas	12
11.Visualización y comunicación para observatorios	13
11.1. Qué dice la literatura	13
11.2. Relación con este repositorio	13
11.3. Mejoras recomendadas	13
12.Síntesis: matriz de mejora del repositorio	14
13.Referencias	15
13.1. Referencias canónicas (bibliografía)	15
13.2. Recursos clave descubiertos en línea (citados con URL)	15

1 Introducción, alcance y método de la revisión

1.1 Propósito

Este documento es un **estado del arte** orientado a la mejora del repositorio `Observatorio_Ministerio_de_Ciencias_Grupo8` (observatorio crítico del sistema de reconocimiento de investigadores de MinCiencias, Colombia). Su objetivo es doble: (i) situar el proyecto en la literatura científica relevante — qué se sabe, qué métodos se recomiendan y qué han hecho otros autores en problemas equivalentes — y (ii) traducir esa literatura en **acciones concretas de mejora** para este repositorio, respetando su alcance (6 convocatorias 2013–2021, 77 237 registros declarados, 30 086 investigadores únicos, cruce con 3 166 629 productos de grupos) y sus limitaciones documentadas en la auditoría (consolidado versionado incompleto, déficit de inferencia formal, reproducción end-to-end pendiente).

1.2 Criterio de búsqueda y fuentes

La revisión **no se limita por idioma**: incorpora literatura en inglés (núcleo de la bibliometría y la ciencia de la ciencia), español y portugués (estudios sobre los sistemas de información curricular de Brasil y Colombia, evaluación nacional, ciencia abierta) y materiales grises relevantes (declaraciones y acuerdos de política: DORA, Leiden, CoARA). La ventana prioritaria es 2018–2026, con los clásicos fundacionales anteriores cuando siguen siendo la referencia canónica (Lotka 1926; Hirsch 2005; Wang y Strong 1996; Kimball 2013; Huang 1998).

1.3 Cómo leer este documento

Cada sección temática sigue el mismo patrón: **(a) qué dice la literatura** (autores y hallazgos), **(b) cómo se relaciona con este repositorio** (estado actual verificado en la auditoría) y **(c) mejoras recomendadas**, con referencias. La sección 12 consolida todo en una matriz de mejora accionable. Las referencias canónicas aparecen en la bibliografía (sección 13.1); los recursos descubiertos por búsqueda en línea, citados con su URL (sección 13.2), sin fabricar metadatos de autoría no verificados.

Nota metodológica

Glosario rápido (lenguaje llano): *bibliometría*, estudio cuantitativo de publicaciones y citas; *ciencia de la ciencia* (*SciSci*), disciplina que estudia el sistema científico con datos masivos; *métricas responsables*, uso de indicadores cuantitativos solo como apoyo al juicio; *atrición*, abandono del sistema científico; *provenance/línea*, trazabilidad de cómo se produjo cada dato.

2 Ciencia de la Ciencia (SciSci) y evaluación responsable

2.1 Qué dice la literatura

La revisión fundacional de Fortunato et al. [2018] consolidó la **Ciencia de la Ciencia (SciSci)**: el estudio empírico del sistema científico con datos masivos (publicaciones, registros administrativos, redes) y métodos de la física estadística, las redes complejas y el aprendizaje automático. Sus líneas maduras — dinámicas de carrera, productividad, colaboración, movilidad, desigualdad y estructura institucional — son exactamente los ejes que aborda este repositorio. La síntesis de Zeng et al. [2021] y el libro de Wang and Barabási [2021] ordenan esos resultados; Clauset et al. [2017] mostró que los datos bibliométricos y de registro permiten predicciones cuantitativas sobre carreras individuales (edad de pico, probabilidad de alta productividad), con implicaciones directas para un observatorio de capital humano científico.

En paralelo, el movimiento de **evaluación responsable** fijó los límites de uso de los indicadores: la Declaración de San Francisco [DORA, 2012] (2012), los **Principios de Leiden** [Hicks et al., 2015] (2015) y el informe *Metric Tide* [Wilsdon et al., 2015] (2015) coinciden en que (i) los indicadores cuantitativos apoyan, no sustituyen, el juicio; (ii) deben ser robustos al contexto de campo; y (iii) sus definiciones y límites deben ser transparentes. El **Acuerdo de CoARA** [CoARA, 2022] (2022) lleva esta agenda a la práctica institucional en Europa (reforma de la evaluación de la investigación), y existe debate activo sobre su aplicación en América Latina, donde se ha señalado que ciertos indicadores "desestimulan" formas legítimas de producción de conocimiento (por ejemplo, los libros en ciencias sociales y humanidades; véase la crítica de CLACSO citada en la sección 13.2).

2.2 Relación con este repositorio

El proyecto ya adopta el espíritu SciSci (patrón *Pregunta* → *Hallazgo* → *Caveat* y hallazgos sobre retención, concentración, brechas y productividad) y su crítica del sistema de reconocimiento colombiano está alineada con la agenda de métricas responsables. La auditoría verificó, sin embargo, dos brechas frente a esta literatura: (a) **no existe un marco formal de indicadores** (definición operativa, fórmula, fuente y límites de cada métrica), condición mínima del enfoque de Leiden/CoARA; y (b) la inferencia es descriptiva, sin modelos predictivos ni de robustez, cuando SciSci ofrece herramientas maduras para ello.

2.3 Mejoras recomendadas

1. Publicar un **marco de indicadores responsable**: para cada métrica del observatorio (retención, transición, HHI, brechas, representación), declarar fórmula, fuente, población, supuestos y usos permitidos (Leiden; DORA; CoARA).
2. Adoptar **análisis de robustez** (bootstrap, sensibilidad a exclusiones) como estándar de publicación de cada hallazgo (recomendado por Hicks et al. [2015] para evitar sobreinterpretación).
3. Explorar **modelos predictivos de carreras** (estilo Clauset et al. [2017] y Wang and Ba-

rabási [2021]) como siguiente fase del observatorio: probabilidad de promoción/deserción por cohorte, edad y área — insumo de política de alto valor.

3 Sistemas nacionales de información y evaluación: el modelo colombiano en perspectiva

3.1 Qué dice la literatura

La literatura en español y portugués documenta que, entre los países latinoamericanos, Brasil y Colombia destacan por sus **sistemas de información curricular consolidados** — **Lattes/Plataforma Sucupira** en Brasil y **ScienTI-CVLAC/Pubindex** en Colombia —, si bien existen otros registros nacionales (CVar en Argentina, CVU en México); la afirmación de que son los únicos dos "consolidados" proviene de una fuente comparativa ya clásica (Revista CTS, 2010; sección 13.2) y debe leerse con esa fecha. La herramienta brasileña *ScriptLattes* [Mena-Chalco and Cesar Júnior, 2009] es un referente metodológico del aprovechamiento analítico de estos registros, y el **método del currículum vitae (CV method)** de Cañibano and Bozeman [2009] formaliza su uso en estudios de política científica. Sobre Colombia existen análisis críticos recientes del **modelo de categorización de grupos e investigadores ante el SNCTI** (convocatorias de MinCiencias; estudio en *Universidad y Sociedad*, sección 13.2), que señalan tensiones entre clasificación y calidad, sesgos disciplinares y efectos sobre la carrera académica; y estudios sobre ciencia abierta y métricas de nueva generación en el contexto de Pubindex y ScienTI (sección 13.2), enmarcados en la política nacional de ciencia abierta (CONPES 4069 de 2021). A nivel internacional, el diseño de sistemas de evaluación nacional está siendo reformado bajo los principios de Leiden/CoARA [CoARA, 2022] y la literatura de *research evaluation systems* compara modelos (indicadores vs. peer review vs. enfoques mixtos).

3.2 Relación con este repositorio

El repositorio audita precisamente el *producto registral* del modelo colombiano: el padrón de investigadores reconocidos por convocatoria. Sus hallazgos (cobertura selectiva de variables de diversidad, etiquetado erróneo de convocatorias, atípicos de edad, captura cambiante de co-filiación, 3 de 6 convocatorias en el consolidado versionado) constituyen evidencia empírica sobre la **calidad del registro**, un tema central en la literatura regional. La comparación implícita del proyecto con las convocatorias como "ventanas.es" coherente con cómo los estudios de la región tratan a Lattes y ScienTI.

3.3 Mejoras recomendadas

1. Incorporar explícitamente la **comparación Brasil-Colombia** (Lattes vs. ScienTI/CVLAC) como marco interpretativo: qué variables captura cada sistema, cómo manejan la desambiguación de autores y la actualización curricular, y qué lecciones

aplican al diseño de la captura de datos de MinCiencias.

2. Citar y contrastar los **estudios críticos del modelo colombiano** (sección 13.2) para posicionar los hallazgos del observatorio en el debate de política, no solo como ejercicio descriptivo.
3. Alinear las recomendaciones con la agenda de **métricas responsables y ciencia abierta** del país (Publindex, CONPES de ciencia abierta), de modo que el observatorio sirva como insumo de política pública reproducible.

4 Calidad de datos, gobernanza y reproducibilidad para observatorios

4.1 Qué dice la literatura

La gobernanza de datos para observatorios de investigación se apoya en tres pilares consolidados: (i) las **dimensiones de calidad de datos** de Wang and Strong [1996] (exactitud, completitud, consistencia, oportunidad, unicidad, validez) y su operacionalización en marcos de gestión (DAMA-DMBOK, DAMA International [2017]; ISO/IEC 25012); (ii) los **principios FAIR** [Wilkinson et al., 2016] (Findable, Accessible, Interoperable, Reusable) como estándar para datos de investigación; y (iii) la **reproducibilidad técnica**: contenedores, gestión de versiones de datos (DVC, Git LFS), gestores de flujos de trabajo (Nextflow, Snakemake) y *data observability* — monitoreo de la salud de los datos dentro del pipeline [Souza et al., 2023] (preprint IEEE eScience 2023, sección 13.2). La literatura reciente enfatiza el **linaje/provenance** (de dónde vino cada valor y qué transformaciones sufrió) como condición para auditar resultados.

4.2 Relación con este repositorio

La auditoría del proyecto (documento maestro) verificó: catálogo YAML con diccionario de datos y decisiones documentadas (buena base FAIR); pero dimensiones de calidad evaluadas como parciales (exactitud sin contraste externo; consistencia afectada por mojibake y duplicidad de artefactos; oportunidad con pull 2021–2026); datos crudos y procesados sin versionar (ausencia de DVC pese a la nota del `.gitignore`); CI/CD rota (módulos inexistentes en el workflow); contrato de esquema (**pandera**) declarado y sin uso; y ausencia de linaje explícito entre ingesta, transformación y evidencias.

4.3 Mejoras recomendadas

1. Formalizar una **auditoría de calidad por las 6 dimensiones** de Wang and Strong [1996] con reportes automáticos por convocatoria, y declarar el estado por dimensión (completitud, unicidad, validez, consistencia, exactitud, oportunidad).
2. Implementar **FAIR práctico**: documentando en el catálogo con identificadores persistentes, contratos de esquema (**pandera/great_expectations**) en ingesta y transformación, y un registro de **linaje** (archivo→transformación →evidencia).

3. Versionar datos críticos con **DVC o Git LFS** (incluido el consolidado completo de 6 convocatorias, hoy ausente del clon) y reparar CI/CD para que la ingesta periódica sea realmente reproducible (recomendación de [Souza et al., 2023] sobre observabilidad en pipelines). La arquitectura dimensional del repositorio (esquema estrella en DuckDB) sigue el modelo de Kimball and Ross [2013], apropiado para consultas analíticas; la literatura recomienda complementarlo con linaje y validación de contratos para convertirlo en un observatorio auditable.

5 Dinámica longitudinal de carreras científicas: retención, transición y atrición

5.1 Qué dice la literatura

El estudio cuantitativo de carreras científicas combina: (i) **cadena de Markov** para transiciones de estado [Kemeny and Snell, 1976] — ya usadas en bibliometría para movilidad entre categorías de productividad; (ii) **modelos de supervivencia** (Kaplan–Meier y riesgos proporcionales de Cox) para el *tiempo hasta el evento* (abandono o salida), con manejo de censura; y (iii) **modelos de crecimiento** (efectos mixtos) para trayectorias individuales de productividad. Los clásicos de la física de carreras establecen resultados robustos: el impacto individual evoluciona con reglas universales en las que el azar pesa tanto como la productividad [Sinatra et al., 2016]; la persistencia y la incertidumbre marcan el arranque académico [Petersen et al., 2012]; y la movilidad geográfica estratifica la carrera y el impacto [Deville et al., 2014]. La evidencia empírica reciente es abundante: la atrición de científicos es alta y estructural — estudios recientes sobre abandono en países OCDE estiman que una fracción importante de quienes publican una primera vez no persiste (p. ej., atrición de biólogos en 38 países OCDE, 2024, sección 13.2; patrones de atrición científica de Kwiek y Szymula, sección 13.2). La **movilidad** geográfica e institucional se asocia con mayor impacto (Science, Sugimoto et al. [2017]), y la desigualdad de impacto se acumula desde las carreras tempranas (estudio 2023 sobre movilidad y desigualdad de impacto en carreras tempranas, sección 13.2).

5.2 Relación con este repositorio

El proyecto implementa matrices de transición de Markov entre categorías (Junior/Asociado/Senior/Emérito) y tasas de retención por periodo, con las 6 convocatorias; su hallazgo de que Bogotá retiene 92 % y absorbe 1 000+ investigadores dialoga directamente con la literatura de movilidad. La auditoría identificó las brechas metodológicas frente a esta literatura: (a) no se testea la propiedad markoviana ni la homogeneidad temporal; (b) no hay modelos de supervivencia para el tiempo hasta la salida (los "desaparecen" mezclan abandono real con diseño del sistema, p. ej. eméritos vitalicios); (c) las ventanas irregulares entre convocatorias (2013, 2014, 2015, 2017, 2019, 2021) impiden comparar tasas directamente; (d) no hay análisis por cohorte de entrada ni modelos de crecimiento; y (e) el seguimiento individual depende de la estabilidad de `id_persona_pr` entre convocatorias, un supuesto de

vinculación de registros (record linkage) que la literatura trata con métodos formales de desambiguación de identidades [Christen, 2012] y que la adopción de identificadores persistentes tipo **ORCID** ayudaría a resolver en la fuente.

5.3 Mejoras recomendadas

1. Añadir **análisis de supervivencia** (Kaplan–Meier y Cox) sobre el panel: tiempo hasta la salida, con covariables (área OCDE, género, categoría, región) y manejo de la censura por diseño (eméritos como estado absorbente).
2. Testear la **propiedad markoviana** y reportar matrices de orden superior o modelos condicionados a historia (coherente con Kemeny and Snell [1976] y la práctica bibliométrica).
3. Analizar **cohortes de entrada y atrición por cohorte** (estilo de los estudios de atrición citados en 12.2), separando abandono real de artefactos del sistema (eméritos, cambio de convocatoria).
4. Modelar **movilidad geográfica** (flujos entre departamentos, ya esbozados en el Sprint 6) como insumo de la literatura de movilidad e impacto [Sugimoto et al., 2017].

6 Desigualdad y concentración de la ciencia (territorio, productividad e instituciones)

6.1 Qué dice la literatura

La medición de la desigualdad en ciencia usa la familia estándar de índices: **HHI** (Herfindahl–Hirschman), **Gini**, **Theil** [Theil, 1967] y la curva de Lorenz. La **geografía de la ciencia** es un campo activo con programa de investigación acumulativo [Frenken et al., 2009]: un artículo reciente en *Journal of Informetrics* (2023) cuantifica simultáneamente *competitividad y desigualdad* de la producción científica entre países (sección 13.2), mostrando que la concentración coexiste con dinámicas de cambio de liderazgo. A nivel institucional, Clauset et al. [2015] demostró en redes de contratación de profesores en EE. UU. que la jerarquía institucional es extrema, persistente y resistente a cambios tras controlar por productividad; replicaciones recientes siguen confirmando la *estratificación por prestigio* desde la carrera temprana (sección 13.2). La literatura clásica de productividad (**ley de Lotka**, Lotka [1926]) sigue siendo el marco nulo para testar concentración de producción. El índice h [Hirsch, 2005] y sus críticas marcan los límites de los indicadores de output individuales: la revisión sistemática de indicadores de impacto de cita [Waltman, 2016] documenta la necesidad de normalizar por campo y carrera, y de reportar incertidumbre, antes de comparar perfiles individuales.

6.2 Relación con este repositorio

El proyecto calcula **HHI por departamento y región** (hallazgo: Bogotá y Antioquia concentran 51 %), productividad media por categoría (Junior 30 / Asociado 65 / Senior 121) y

comparaciones per cápita DANE 2018. La auditoría verificó: HHI sin intervalos de confianza ni complemento de Gini/Theil; denominador per cápita fijo (DANE 2018) sin considerar dinámica poblacional 2013–2021; concentración de productividad sin contraste con la ley de Lotka; y duplicidad de artefactos de matrices que dificulta la trazabilidad de los índices.

6.3 Mejoras recomendadas

1. Ampliar la familia de índices: **HHI + Gini/Lorenz + Theil (descomponible entre/intra regiones)** con intervalos de confianza bootstrap, siguiendo [Theil, 1967] y la práctica de la geografía de la ciencia (sección 13.2).
2. Testar la **concentración de productividad** contra la ley de Lotka [Lotka, 1926] y normalizar la productividad por área y ventana antes de comparar categorías.
3. Analizar la **jerarquía institucional** con los métodos de Clauset et al. [2015] (redes de contratación.ºbservables en el padrón: retención, absorción y flujos entre instituciones) y reportar la persistencia temporal de la concentración.

7 Género y diversidad en la ciencia

7.1 Qué dice la literatura

El referente clásico es el estudio global de Larivière et al. [2013] (*Nature*), que documentó la subrepresentación femenina y su variación por disciplina. La literatura reciente en español y portugués aporta evidencia regional: análisis bibliométricos comparativos de la **Comunidad Andina** (2020–2024) sobre disparidades de género en producción (sección 13.2) y estudios sobre participación femenina en STEM (sección 13.2). El enfoque **interseccional** [Crenshaw, 1989] recomienda cruzar género con etnia, territorio y otras dimensiones, en vez de analizar el género de forma aislada. Las métricas estándar son proporciones de participación por disciplina, brechas relativas (odds ratios) y razones de representación frente a la población de referencia; la literatura advierte contra comparar proporciones sin ajustar por composición de área y cohorte.

7.2 Relación con este repositorio

El proyecto mide la participación femenina por gran área OCDE (hallazgo: 24 % en Ingeniería vs. 48 % en ciencias médicas), la evolución temporal y la brecha en productividad (5 de 6 grandes áreas con brecha); en diversidad, compara grupos étnicos, discapacidad y víctimas frente al censo DANE 2018 y el RUV (afro 3×, indígena 7.9×, discapacidad 8× subrepresentados) y produce un cruce interseccional género×etnia. La auditoría verificó debilidades: variables auto-declaradas y capturadas solo desde 2021 (sin serie temporal); comparaciones sin modelos ajustados (odds ratios con IC); el bug metodológico de `comparar_dane()`: el comentario promete excluir "NINGUN GRUPO ETNICO" del denominador pero el código solo excluye "NO DISPONIBLE", con lo que la subrepresentación queda diluida (el arreglo recomendado es

excluir de verdad ese grupo del denominador); y el cruce interseccional frágil ante subgrupos sin mujeres.

7.3 Mejoras recomendadas

1. Formalizar la inferencia de brechas con **modelos logísticos ajustados por área, cohorte y categoría** (odds ratios con IC), como recomienda la literatura [Larivière et al., 2013] y sus extensiones regionales (sección 13.2).
2. Reportar **razones de representación con intervalos de confianza** (bootstrap) y declarar explícitamente la ventana 2021 como única comparable para diversidad.
3. Robustecer el **análisis interseccional** (género×etnia ×área) con **reindex** de columnas y tamaños de celda mínimos (evitar desagregaciones sin respaldo muestral), siguiendo el enfoque de Crenshaw [1989].

8 Redes institucionales: co-afiliación, jerarquías y endogamia académica

8.1 Qué dice la literatura

El análisis de redes de colaboración tiene base consolidada en Newman [2001] y Wasserman and Faust [1994]; las medidas de centralidad (grado, intermediación de Freeman [1977]) identifican instituciones-puente. La literatura reciente sobre **jerarquía y endogamia académica** (academic inbreeding) — estudiar/contratar en la propia institución — documenta efectos sobre la productividad y la diversidad de ideas, con estudios tanto globales como latinoamericanos (sección 13.2). Clauset et al. [2015] mostró que las jerarquías institucionales en la contratación son extremas y persistentes; estudios recientes (2023) confirman la estratificación por prestigio desde la carrera temprana (sección 13.2). Un principio metodológico clave de la literatura: las métricas de red deben contrastarse contra **modelos nulos** (grafos aleatorios con la misma distribución de grados) antes de declarar significancia, y debe declararse la **ventana de captura** (qué relaciones son observables y cuáles no).

8.2 Relación con este repositorio

El proyecto construye el grafo de **co-filiación institucional** a partir de INST_FILIA (separador |), con métricas por convocatoria, normalización de nombres y una tabla maestra de IES (211 IES, 91 % de cobertura); identifica universidades-puente y la absorción de Bogotá. La auditoría verificó limitaciones: captura selectiva (co-filiación múltiple solo en 2019, 569 casos) → la red es un corte transversal; el bug de `split(n=1)` en `redes.py` pierde pares de 3+ afiliaciones y crea nodos con cadenas literales ("B|C"); métricas sin modelos nulos; y el tratamiento de 2 762 cadenas crudas de `inst_filia` (800 IES reales) requiere la tabla maestra para no inflar la red.

8.3 Mejoras recomendadas

1. Contrastar la centralidad y la detección de puentes contra **modelos nulos de configuración** (práctica estándar en redes; Newman [2001] y extensiones).
2. Corregir la extracción de pares (explode completo de INST.FILIA, no `split(n=1)`) y validar contra la **tabla maestra de IES** para eliminar nodos espurios.
3. Declarar la red como **corte transversal 2019** y, si se amplía a más convocatorias, estudiar la **evolución de la jerarquía** (estilo Clauset et al. [2015]) y la endogamia institucional en el contexto colombiano (sección 13.2).

9 Segmentación con datos mixtos: métodos y validación moderna

9.1 Qué dice la literatura

Cuando los datos combinan variables numéricas y categóricas (edad, órdenes, área, género, región), el estándar de reducción de dimensión es el **análisis factorial de datos mixtos (FAMD)** [Husson et al., 2017] y el **análisis de correspondencias (MCA)** [Greenacre, 2017]. Para agrupar, **k-prototypes** [Huang, 1998] sigue siendo el método de referencia para datos mixtos, pero la literatura de evaluación comparada recomienda: (i) comparar varios algoritmos (k-prototypes, k-means sobre codificación, agrupamiento basado en distancia de Gower) — existe un benchmark abierto reciente de agrupamiento mixto (sección 13.2); (ii) validar el número de grupos con **silhouette**, **Calinski–Harabasz** y **Davies–Bouldin**; (iii) manejar los faltantes con **imputación múltiple** (marco estándar de van Buuren [2018]) en lugar de eliminar casos completos; y (iv) cuando hay subgrupos pequeños, reportar estabilidad de los clusters (bootstrap o remuestreo).

9.2 Relación con este repositorio

La segmentación del proyecto vive en scripts R *legacy* (**kproto** con $k = 3$ fijo, sin validación) y en análisis multivariado (CA/FAMD) también en R con rutas hardcodeadas (`Downloads/`); la "gran tabla" sin identificadores se construyó con tipos degradados (`dtype='object'`). La auditoría verificó: $k = 3$ sin curvas de withinss/silhouette; pérdida del 8.4 % de la muestra por eliminar casos incompletos; y no reproducibilidad del pipeline de clustering en Python pese a declarar `scikit-learn`.

9.3 Mejoras recomendadas

1. **Migrar la segmentación al pipeline Python** con FAMD (**prince** o `scikit-learn`) + comparación de algoritmos (k-prototypes vs. k-means sobre codificación) y validación interna (**silhouette**, **Calinski–Harabasz**), siguiendo el benchmark citado en 12.2.
2. Aplicar **imputación múltiple** (o al menos documentar el sesgo del análisis de casos

completos) antes de clusterizar.

3. **Perfilear los clusters** contra las variables de política (género, región, categoría) y reportar estabilidad por remuestreo; conectar la segmentación con el marco de indicadores del observatorio.

10 Ética y protección de datos personales en registros de ciencia

10.1 Qué dice la literatura

El tratamiento de registros administrativos de investigadores implica datos personales y, con frecuencia, **categorías sensibles** (etnia, condición de discapacidad, condición de víctima del conflicto). La literatura sobre privacidad de datos muestra que la **anonimización ingenua no es suficiente**: los ataques de reidentificación tienen éxito incluso sobre datos incompletos o con seudónimos [Rocher et al., 2019], y el riesgo crece cuando se combinan múltiples variables cuasi-identificadoras (departamento, área, edad, cargo). Las prácticas recomendadas incluyen: minimización (recolectar solo lo necesario), seudonimización y anonimización robusta (k-anonimato y variantes), agregación de microdatos antes de publicar, y análisis de riesgo de reidentificación previo a cualquier liberación de datos. En Colombia, el marco normativo es la **Ley 1581 de 2012** (protección de datos personales) y sus decretos reglamentarios, con reglas específicas para datos sensibles (autorización explícita, finalidad, seguridad).

10.2 Relación con este repositorio

El proyecto procesa el padrón de MinCiencias con variables sensibles (auto-declaradas): grupo étnico, discapacidad y condición de víctima, además de identificadores de persona (`id_persona_pr`) y ubicación. Buena práctica ya adoptada: la construcción de una "gran tabla sin identificadores" para análisis y la publicación de agregados (evidencias y figuras). La auditoría identificó riesgos a formalizar: (a) el consolidado versionado (XLSX/CSV) incluye `ID_PERSONA_PR`, edad y geolocalización — microdatos personales en un repositorio público; (b) no hay documento de tratamiento de datos personales ni análisis formal de riesgo de reidentificación de la "gran tabla"; (c) la descarga pública por convocatoria de la fuente (Socrata) es legítima, pero el proyecto debe declarar su régimen de tratamiento y retención.

10.3 Mejoras recomendadas

1. Publicar una **nota de tratamiento de datos personales** (Ley 1581/2012): finalidad, base de legitimación, categorías sensibles, medidas de seguridad y política de retención del consolidado.
2. Realizar un **análisis de riesgo de reidentificación** de la "gran tabla" de los microdatos publicados (estilo Rocher et al. [2019]); si el riesgo es no despreciable, agregar o generalizar las variables cuasi-identificadoras.
3. Mantener la política de **no publicar microdatos identificables** (ya correcta en el

diseño) y documentarla explícitamente en el README y en el catálogo, indicando qué archivos son de acceso restringido.

11 Visualización y comunicación para observatorios

11.1 Qué dice la literatura

El producto público de un observatorio es su capa visual, y existe literatura madura al respecto. El concepto de **visualización narrativa** [Segel and Heer, 2010] formaliza cómo contar historias con datos (estructuras tipo magazine, flujo descendente, paneles tipo "martini glass"), exactamente el patrón *Pregunta* → *Hallazgo* → *Caveat* que el proyecto ya usa en su dashboard. Los principios clásicos de diseño siguen vigentes (datos-ink, eliminación de ruido visual; Tufte, 1983) y los marcos modernos de dashboards analíticos (Few, 2009) recomiendan jerarquía visual, contexto y encadenamiento pregunta-respuesta. La literatura de *visual analytics* enfatiza la **interacción como medio de exploración** (filtros, drill-down) y la **transparencia del dato** (mostrar la fuente y los supuestos de cada cifra junto a la visualización). Para observatorios de política, el desafío no es dibujar más, sino **auditar qué se muestra**: cada gráfico debe poder trazarse a su dato y a su método.

11.2 Relación con este repositorio

El proyecto entrega un dashboard Streamlit de 7 pestañas (calidad, trayectoria, territorio, género/diversidad, redes, productividad, datos crudos) con el patrón *Pregunta* → *Hallazgo* → *Caveat*, mapas, heatmaps, Sankeys y grafos interactivos (Pyvis). La auditoría verificó: el gráfico HHI del dashboard **nunca se dibuja** por un bug silencioso (ValueError capturado); la sección de productividad se degrada sin el dataset de producción; y el manual ejecutable no es reproducible. Frente a la literatura, faltan: (a) la **traza de cada visualización a su dato y método** (botón o nota "fuente y cálculo"), (b) indicadores de **incertidumbre** en los gráficos (intervalos de confianza), y (c) una política de auditoría visual de los gráficos antes de publicarlos.

11.3 Mejoras recomendadas

1. Documentar cada visualización con su **fuentes, definición del cálculo y limitaciones** (encadenando con el marco de indicadores de la sección 3 y con el linaje de la sección 4).
2. Reparar el bug del HHI y añadir **incertidumbre** (IC) a los gráficos de indicadores principales, siguiendo la práctica de visualización honesta de la literatura narrativa [Segel and Heer, 2010].
3. Mantener el patrón *Pregunta* → *Hallazgo* → *Caveat* como guía de diseño (ya es una fortaleza) y añadir una **vista de auditoría de datos crudos** que permita verificar cada hallazgo desde el propio dashboard (tab 7 ya existe; fortalecerla con descarga y con la traza metodológica).

12 Síntesis: matriz de mejora del repositorio

La tabla consolida la revisión: cada fila vincula un eje del proyecto con la referencia principal y una acción concreta de mejora. La prioridad se justifica por el riesgo o el valor esperado para el proyecto: *alta* = corrige un riesgo legal/metodológico o desbloquea la reproducibilidad; *media* = añade inferencia o profundidad analítica; *secundaria* = amplía el valor informativo.

Tabla 1. Matriz de mejora del repositorio según el estado del arte

Eje	Referencia(s)	Mejora prioritaria	Prioridad
Evaluación responsable	Leiden Hicks et al. [2015] ; DORA DO-RA [2012] ; CoARA CoARA [2022]	Marco de indicadores (fórmula, fuente, límites); robustez (IC) en cada hallazgo	Alta
Ética y datos personales	Ley 1581/2012; reidentificación Rocher et al. [2019]	Nota de tratamiento; análisis de riesgo de reidentificación de la "gran tabla"; no publicar microdatos	Alta
Calidad de datos	Wang & Strong Wang and Strong [1996] ; FAIR Wilkinson et al. [2016]	Auditoría DQ por 6 dimensiones; contratos de esquema; versionar datos (DVC); linaje	Alta
Longitudinal	Markov Kemeny and Snell [1976] ; carreras Sinatra et al. [2016] ; movilidad Sugimoto et al. [2017]	Supervivencia (KM/Cox); test de markovianidad; cohortes; modelos predictivos de carrera	Alta
Visualización	Narrativa Segel and Heer [2010]	Traza fuente/método por gráfico; IC visuales; reparar bug HHI	Media
Desigualdad	Theil Theil [1967] ; geografía Frenken et al. [2009] ; Lotka Lotka [1926]	HHI+Gini+Theil con IC; contraste con ley de Lotka	Media
Género y diversidad	Larivière Larivière et al. [2013] ; interseccionalidad Crenshaw [1989]	Modelos ajustados (odds ratios con IC); robustez interseccional	Media
Redes	Newman Newman [2001] ; jerarquía Clauset et al. [2015]	Modelos nulos de red; corregir extracción de pares; declarar corte 2019	Media

Eje	Referencia(s)	Mejora prioritaria	Prioridad
Datos mixtos	FAMD Husson et al. [2017] ; k-prototypes Huang [1998] ; imputación van Buuren [2018]	Migrar clustering a Python con validación (silhouette) e imputación	Media
Sistema nacional	CV method Cañibano and Bozeman [2009] ; ScriptLattes Mena-Chalco and Cesar Júnior [2009]	Posicionar hallazgos en el debate regional (Brasil–Colombia, ciencia abierta CONPES 4069)	Secundaria

Hallazgo

En síntesis: el repositorio está bien alineado con el **paradigma SciSci** y la **evaluación responsable**, pero su siguiente nivel de madurez exige (i) atender primero los riesgos de **datos personales** y la **gobernanza reproducible** (FAIR + DVC + contratos de esquema + CI/CD), (ii) añadir **inferencia formal con robustez** (supervivencia, IC, modelos nulos, validación de clusters), y (iii) consolidar la capa de **visualización auditable** (traza dato-método en cada gráfico del dashboard). La literatura no sugiere abandonar el diseño actual (observatorio descriptivo-crítico sobre registro administrativo) sino profundizarlo con los métodos aquí referenciados.

13 Referencias

13.1 Referencias canónicas (bibliografía)

Las referencias canónicas citadas en el texto (SciSci, evaluación responsable, carreras y movilidad, calidad de datos, desigualdad, género, redes, datos mixtos, ética y visualización) se listan en la **bibliografía** al final de este documento, en formato autor-año.

13.2 Recursos clave descubiertos en línea (citados con URL)

Estos recursos se descubrieron por búsqueda web durante esta revisión. La política editorial es: **se atribuyen autores y metadatos solo cuando fueron verificados en la fuente**; el resto se cita por título con su URL. Algunos son recursos secundarios (señalados como tales) que sirven para localizar la obra original.

1. *Dos países latinoamericanos cuentan actualmente con sistemas de información curricular consolidados: Brasil y Colombia* (Lattes vs. ScienTI). *Revista Iberoamericana de Ciencia, Tecnología y Sociedad* (artículo comparativo clásico, 2010; citado con su fecha de publicación original, no como estado vigente). <https://www.revistacts.net/wp-con>

- tent/uploads/2020/01/vol5-nro13-cts13.pdf
2. *Categorización de grupos e investigadores ante el sistema nacional de ciencia, tecnología e innovación en Colombia*. Universidad y Sociedad (scielo, 2023). http://scielo.sld.cu/scielo.php?script=sci_abstract&pid=S2218-36202023000500133
 3. *Producción científica en Colombia relacionada con ciencia abierta, métricas de nueva generación y métricas responsables en el contexto de Publindex y SCIENTI*. Revista Científica (UDistrital). <https://revistas.udistrital.edu.co/index.php/revcie/article/view/20852>
 4. *Geography of science: Competitiveness and inequality*. *Journal of Informetrics* 17(1), 2023. <https://ideas.repec.org/a/eee/infome/v17y2023i1s1751157722001109.html>
 5. *Leaving science — attrition of biologists in 38 OECD countries* (2024). *FEBS Letters*. <https://febs.onlinelibrary.wiley.com/doi/full/10.1002/1873-3468.70028>
 6. *Ranking mobility and impact inequality in early academic careers* (2023). <https://pmc.ncbi.nlm.nih.gov/articles/PMC10450398/>
 7. *Quantifying hierarchy and dynamics in US faculty hiring and retention*. <https://pesquisa.bvsalud.org/enfermeria/resource/en/mdl-36131023>
 8. *Hierarchy in Hiring: Quantifying Effects of Academic Pedigree in US Faculty Appointments and Attrition* (recurso secundario: síntesis divulgativa, 2024). <https://career.ucla.edu/blog/2024/03/01/hierarchy-in-hiring-quantifying-effects-of-academic-pedigree-in-us-faculty-appointments-and-attrition-3/>
 9. *Gender disparities in scientific output in the Andean Community: a comparative bibliometric analysis (2020–2024)*. <https://pure.ucacue.edu.ec/en/publications/disparidades-de-g%C3%A9nero-en-la-producci%C3%B3n-cient%C3%ADfica-de-la-comunidad/>
 10. *Gender Gaps and Female Participation in STEM: A Bibliometric Analysis of the Literature*. <https://www.portal.so.ucr.ac.cr/sites/default/files/documents/paper15.pdf>
 11. *CLACSO — medidas que desestiman la producción de libros y desconocen la producción colectiva en ciencias sociales y humanidades*. <https://www.clacso.org/en/medidas-que-desestiman-la-inversion-financiera-en-materia-editorial/>
 12. *Benchmark-Mixed-Clustering: benchmarking algorithms suited for mixed data* (repositorio abierto). <https://github.com/ClementCornet/Benchmark-Mixed-Clustering>
 13. *The Role of Early-Career University Prestige Stratification on the Future Academic Performance of Scholars*. *Research in Higher Education* 64 (2023). https://econpapers.repec.org/article/sprreihed/v_3a64_3ay_3a2023_3ai_3a1_3ad_3a10.1007_5fs11162-022-09679-7.htm
 14. Estudios sobre *academic inbreeding* (L. F. M. Grochocki y colaboradores; recurso secundario para localizar la obra). <https://searchworks.stanford.edu/catalog?q=%22Grochocki%2C+Luis+Filipe+de+Miranda%2C%22>

Referencias

- Carolina Cañibano and Barry Bozeman. Curriculum vitae method in science policy research. *Research Policy*, 38(2):259–266, 2009.
- Peter Christen. *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*. Springer, 2012.
- Aaron Clauset, Samuel Arbesman, and Daniel B Larremore. Systematic inequality and hierarchy in faculty hiring networks. *Science Advances*, 1(1):e1400005, 2015.
- Aaron Clauset, Daniel B Larremore, and Roberta Sinatra. Data-driven predictions in the science of science. *Science*, 355(6324):477–480, 2017.
- CoARA. Agreement on reforming research assessment, 2022. URL <https://coara.eu/agreement/the-agreement-full-text/>.
- Kimberle Crenshaw. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine, feminist theory and antiracist politics. *University of Chicago Legal Forum*, 1989:139–167, 1989.
- DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. Technics Publications, 2nd edition, 2017.
- Pierre Deville, Chaoming Song, Roberta Sinatra, Dashun Wang, and Albert-László Barabási. Career on the move: Geography, stratification, and scientific impact. *Proceedings of the National Academy of Sciences*, 111(42):14472–14476, 2014.
- DORA. San francisco declaration on research assessment (dora), 2012. URL <https://sfdora.org/>.
- Santo Fortunato, Carl T Bergstrom, Katy Börner, James A Evans, Dirk Helbing, Staša Milojević, Alexander M Petersen, Filippo Radicchi, Roberta Sinatra, Brian Uzzi, et al. Science of science. *Science*, 359(6379):eaao0185, 2018.
- Linton C Freeman. A set of measures of centrality based on betweenness. *Sociometry*, 40(1):35–41, 1977.
- Koen Frenken, Sjoerd Hardeman, and Jarno Hoekman. Spatial scientometrics: Towards a cumulative research program. *Journal of Informetrics*, 3(3):222–232, 2009.
- Michael Greenacre. *Correspondence Analysis in Practice*. Chapman and Hall/CRC, 3rd edition, 2017.
- Diana Hicks, Paul Wouters, Ludo Waltman, Sarah de Rijcke, and Ismael Rafols. The leiden manifesto for research metrics. *Nature*, 520(7548):429–431, 2015.
- Jorge E Hirsch. An index to quantify an individual’s scientific research output. *Proceedings of the National Academy of Sciences*, 102(46):16569–16572, 2005.

- Zhexue Huang. Extensions to the k-means algorithm for clustering large data sets with categorical variables. *Data Mining and Knowledge Discovery*, 2(3):283–304, 1998.
- François Husson, Sébastien Lê, and Jérôme Pagès. *Exploratory Multivariate Analysis by Example Using R*. Chapman and Hall/CRC, 2nd edition, 2017.
- John G Kemeny and J Laurie Snell. *Finite Markov Chains*. Springer-Verlag, 1976.
- Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. John Wiley & Sons, 3rd edition, 2013.
- Vincent Larivière, Chaoqun Ni, Yves Gingras, Blaise Cronin, and Cassidy R Sugimoto. Bibliometrics: Global gender disparities in science. *Nature*, 504(7479):211–213, 2013.
- Alfred J Lotka. The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences*, 16(12):317–323, 1926.
- Jesús Pascual Mena-Chalco and Roberto Marcondes Cesar Júnior. Scriptlattes: integração de dados curriculares à plataforma lattes. In *Conferência sobre Tecnologia, Cultura e Sociedade (actas)*, 2009. Herramienta ampliamente citada para minería de datos curriculares de la Plataforma Lattes.
- Mark EJ Newman. The structure of scientific collaboration networks. *Proceedings of the National Academy of Sciences*, 98(2):404–409, 2001.
- Alexander M Petersen, Massimo Riccaboni, H Eugene Stanley, and Fabio Pammolli. Persistence and uncertainty in the academic career. *Proceedings of the National Academy of Sciences*, 109(14):5213–5218, 2012.
- Luc Rocher, Julien M Hendrickx, and Yves-Alexandre de Montjoye. Estimating the success of re-identifications in incomplete datasets: Generating insights from attacks. *Nature Communications*, 10:3069, 2019.
- Edward Segel and Jeffrey Heer. Narrative visualization: Telling stories with data. *IEEE Transactions on Visualization and Computer Graphics*, 16(6):1139–1148, 2010.
- Roberta Sinatra, Dashun Wang, Pierre Deville, Chaoming Song, and Albert-László Barabási. Quantifying the evolution of individual scientific impact. *Science*, 354(6312):aaf5239, 2016.
- Renan Souza, Tyler Skluzacek, Sean Wilkinson, Maxim Ziatdinov, and Rafael da Silva. Towards lightweight data integration using multi-workflow provenance and data observability. *IEEE eScience 2023 (preprint)*, 2023. URL <https://arxiv.labs.arxiv.org/html/2308.09004>.
- Cassidy R Sugimoto, Nicolás Robinson-García, Dakota S Murray, Alfredo Yegros-Yegros, Rodrigo Costas, and Vincent Larivière. Scientists have most impact when they’re free to move. *Nature*, 550(7674):29–31, 2017.
- Henri Theil. *Economics and Information Theory*. North-Holland, 1967.
- Stef van Buuren. *Flexible Imputation of Missing Data*. Chapman and Hall/CRC, 2nd edition, 2018.

- Ludo Waltman. A review of the literature on citation impact indicators. *Journal of Informetrics*, 10(2):365–391, 2016.
- Dashun Wang and Albert-László Barabási. *The Science of Science*. Cambridge University Press, 2021.
- Richard Y Wang and Diane M Strong. Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4):5–33, 1996.
- Stanley Wasserman and Katherine Faust. *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.
- Mark D Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.
- James Wilsdon et al. The metric tide: Report of the independent review of the role of metrics in research assessment and management. Technical report, HEFCE, 2015. URL <https://re.ukri.org/documents/hefce-documents/the-metric-tide-2015-pdf/>.
- An Zeng, Zhesi Shen, Jianlin Zhou, Jinshan Fan, Zengru Di, Yougui Wang, H Eugene Stanley, and Shlomo Havlin. The science of science: From the perspective of complex systems. *Physics Reports*, 935:1–60, 2021.