Criterio 1: Entendimiento del objetivo del repositorio

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Commit auditado: `1528939`

Versión 1.0 · 22 de octubre de 2026

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

Índice

1. Contexto y guía de lectura **3**
1.1. Qué es este documento . . . 3
1.2. Glosario (solo los términos que usa este documento) . . . 3

2. Entendimiento del objetivo del repositorio **3**
2.1. Preguntas de investigación que el repositorio responde . . . 4

3. Relación con los demás criterios **4**

4. Muestreo y estimación del análisis longitudinal **4**
4.1. Marco teórico . . . 4
4.1.1. Por qué un EDA antes de decidir el muestreo . . . 4
4.1.2. Los tres estimadores y su relación . . . 5
4.2. EDA: qué se exploró y qué se encontró . . . 6
4.2.1. Univariado . . . 6
4.2.2. Bivariado: ¿la retención depende del grupo? . . . 7
4.2.3. ¿Hay estratos naturales? . . . 7
4.3. Decisión de muestreo: MAS, y por qué . . . 8
4.4. Post-estratificación . . . 8
4.4.1. Fundamento y pesos . . . 9
4.4.2. Condición de tamaño mínimo: no se cumple en tres pares . . . 9
4.4.3. Resultados sobre la retención . . . 10
4.4.4. ¿La post-estratificación acerca las estimaciones al censo? . . . 10
4.5. Estimador GREG (model-assisted) . . . 11
4.5.1. Modelos ajustados . . . 11
4.5.2. Resultados . . . 11
4.6. Comparación de los tres estimadores . . . 12
4.6.1. Comprobación interna: la post-estratificación es un caso particular de GREG . . . 12
4.6.2. Tabla comparativa completa . . . 13
4.6.3. Ganancia de precisión . . . 13
4.6.4. Una advertencia metodológica importante . . . 13
4.7. Diagnósticos y verificación de supuestos . . . 14
4.7.1. Normalidad de la única variable continua: la edad . . . 14
4.7.2. Heterocedasticidad del modelo GREG . . . 15
4.7.3. g-weights e influencia . . . 16
4.7.4. Colapso de las categorías de género no representadas . . . 17
4.7.5. Conclusión: ¿es razonable el modelo GREG? . . . 20
4.8. Conclusión: qué se reporta y por qué . . . 20
Referencias de esta sección . . . 21
Artefactos y reproducibilidad . . . 22

5. Conclusiones y recomendaciones del criterio **22**

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 1 de la rúbrica**: *Entendimiento del objetivo del repositorio*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica. Esta serie cubre los **6 criterios** de la rúbrica en documentos separados, más el documento maestro que los integra.

En resumen: Este criterio evalúa si el equipo entendió qué se proponía el repositorio: construir un observatorio crítico del sistema de reconocimiento de investigadores de MinCiencias (2013-2021), responder 7 preguntas de investigación y producir evidencia para un informe sobre las falencias del sistema.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (`maestro_auditoria.pdf`). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario (solo los términos que usa este documento)

Esta tabla incluye únicamente los términos técnicos que aparecen en este documento, explicados en lenguaje sencillo:

Tabla 1. Glosario de términos presentes en este documento

Término	Qué significa
Tasa de retención	Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.

2 Entendimiento del objetivo del repositorio

El objetivo del repositorio es claro y bien documentado: consolidar, validar y analizar el padrón de investigadores reconocidos por MinCiencias y producir un observatorio crítico con evidencia sobre la fiabilidad, comparabilidad y equidad del sistema de reconocimiento. La documentación (README, informe_final.md, catálogo YAML) permite entender sin ambigüedad qué se buscaba. Se observa una evolución del alcance: el informe inicial trabajaba con 3 convocatorias (2017/2019/2021) y la versión final del README cubre 6 (2013-2021), incorporando producción, diversidad y redes; esta ampliación es coherente con un observatorio en maduración, aunque obliga a reinterpretar las métricas de las primeras fases. Punto de mejora: formalizar un marco

de indicadores (definición operativa, fórmula, fuente y límites de cada métrica) para que la entrega sea auditable.

2.1 Preguntas de investigación que el repositorio responde

El repositorio declara 7 preguntas (README): fiabilidad de los datos, retención entre convocatorias, concentración territorial, brecha de género, redes de co-filiación, diversidad poblacional y productividad cruzada con el dataset de producción. Cada pregunta mapea a un módulo de análisis (`src/analisis/*`), lo que demuestra una descomposición objetivo → preguntas → módulos correcta y trazable.

3 Relación con los demás criterios

Este documento se centra en el criterio 1. Los demás criterios de la rúbrica — Datos utilizados: suficiencia y corrección; Documentación y crítica por archivo de código; Validación de la calidad estadística; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Muestreo y estimación del análisis longitudinal

Alcance. Esta sección es un *ejercicio metodológico*: documenta *cómo* se estimaría y qué se gana con cada estimador. Las cifras oficiales del análisis longitudinal son las del **censo** (la base completa está disponible) y se reportan en `analisis_longitudinal.md`; aquí se usan además como patrón de contraste, lo que permite verificar de verdad cada estimador en lugar de confiar en la teoría.

Datos. 77 237 registros, 30 086 personas únicas y 6 convocatorias (2013–2021). Muestra vigente: 2 224 personas, muestreo aleatorio simple (MAS) con semilla 2026.

4.1 Marco teórico

4.1.1 Por qué un EDA antes de decidir el muestreo

El análisis exploratorio no es un trámite previo: es lo que permite elegir el diseño. Como resume la literatura de muestreo, «el análisis exploratorio de datos, incluidas la producción de resúmenes simples, tabulaciones y gráficos, es normalmente la primera etapa de cualquier análisis de este tipo» y se debe «llevar a cabo trabajo exploratorio sobre subconjuntos o muestras para clarificar qué enfoque será a la vez práctico y eficaz» (StatsRef.com, sobre Cochran, 1977). En este proyecto el EDA cumple tres funciones concretas:

1. **Detectar si hay estratos naturales**, es decir, grupos con comportamiento muy distinto. Si no los hay, la estratificación no aporta y complica el diseño.
2. **Detectar grupos pequeños** que necesitarían representación garantizada y no la tienen con un MAS.
3. **Cuantificar la varianza intra e inter-grupo**, que es exactamente lo que determina cuánta precisión se gana al estratificar.

4.1.2 Los tres estimadores y su relación

Tabla 2. Los tres estimadores comparados.

Estimador	Idea	Fundamento
MAS (expansión simple)	Cada persona entra con el mismo peso N/n	Cochran (1977); Lohr (2010). Insesgado por diseño
Post-estratificado	Se reponderan los pesos para que la muestra reproduzca la composición conocida de la población en categorías	Cochran (1977, §5A); Lohr (2010, §7.6). Su distribución asintótica coincide con la de un muestreo estratificado con asignación proporcional
GREG (model-assisted)	Se usa un modelo de regresión como auxiliar, pero la validez de la estimación **no** depende de que el modelo sea correcto	Särndal, Swensson & Wretman (1992, §6.4–6.5); FCSM (2003); Kalton (2002)

La idea central del GREG es la del **modelo asistido**: el modelo se usa para ganar eficiencia, no para sostener la inferencia. Como lo formulan Kalton (2002) y el FCSM (2003), «los modelos se usan ampliamente dentro del modo de inferencia basado en el diseño, tanto en el diseño muestral como en la estimación, pero de manera asistida por el modelo, de forma que la validez de las estimaciones no depende de la validez de los supuestos del modelo». La propiedad que lo garantiza es la consistencia por diseño: si el modelo es malo, el estimador sigue siendo aproximadamente insesgado porque el término de corrección usa los residuos observados en la muestra.

Formalmente, con probabilidades de inclusión $\pi_i = n/N$ (MAS sin reemplazo) el estimador de diferencia que se implementa aquí es

$$\hat{Y}_{GREG} \;=\; \frac{1}{N}\sum_{i\in U}\hat{y}_i \;+\; \frac{1}{n}\sum_{i\in s}(y_i-\hat{y}_i) \tag{1}$$

y con un modelo **lineal** adopta la forma clásica $\bar{Y}_{GREG} = \bar{y}_s + (\bar{X}_U - \bar{x}_s)'\hat{\beta}_s$, donde las medias de las auxiliares se conocen para **toda** la población. Un detalle importante para interpretar los resultados: **la post-estratificación es un caso particular de GREG** con un modelo saturado en los post-estratos. En la sección 4.6 se comprueba numéricamente.

4.2 EDA: qué se exploró y qué se encontró

4.2.1 Univariado

Categóricas (perfil de cada persona en su última convocatoria observada, $n = 30\,086$):

Tabla 3. Distribución de las variables categóricas del censo.

Variable	Categorías	Distribución
Categoría	4	Investigador Junior 68,7 % · Investigador Asociado 19,2 % · Investigador Sénior 10,
Género †	3	Masculino 60,6 % · Femenino 39,4 % · Otro / No especificado 0,0 %
Gran área	7	Ciencias Sociales 30,7 % · Ciencias Naturales 20,9 % · Ingeniería y Tecnología 18,7
Nivel de formación	10	Doctorado 49,4 % · Maestría/Magister 36,0 % · Postdoctorado 7,6 % · Especialidad
Departamento	35	Bogotá D. C. 32,6 % · Antioquia 16,6 % · Valle del Cauca 8,3 % · Atlántico 6,2 % ·

† El género se presenta **colapsado**: *Intersexual* (5 personas) y *No disponible* (4) se agrupan en *Otro / No especificado* (9 personas, 0,030 % del censo) porque **ninguna de las dos aparece en la muestra**. La decisión y sus consecuencias se documentan en la sección 4.7.4.

Edad. Media 45,52 años, desviación 13,91, mediana 43,8, rango intercuartílico 15,6 (Q1 = 37,2; Q3 = 52,8). El criterio del bigote 1,5×IQR marca **106 valores atípicos**, y 11 personas declaran **más de 100 años** (máximo registrado: 956,25). Sin esos casos la media baja a 45,39 años: es un problema de **calidad de captura**, no de la población, y por eso se reporta explícitamente.

Presencia. Cada persona aparece en promedio en 2,567 convocatorias. El 36,1 % aparece en una sola y nunca vuelve, y solo el 9,1 % está en las seis. Esto ya anticipa que la serie temporal tendrá mucha entrada y salida, y que la unidad de análisis correcta es la persona, no el registro.

Faltantes. De 30 columnas, 4 tienen valores vacíos:

Tabla 4. Columnas con valores faltantes en el padrón.

Columna	Vacíos	%	Convocatorias afectadas
`INST_FILIA`	9 326	12,1 %	2013: 2 016, 2014: 1 415, 2015: 1 622, 2017: 1 634, 2019: 321, 2021: 2 318
`COD_DANE_NAC_PR`	4 591	5,9 %	2013: 624, 2014: 519, 2015: 694, 2017: 790, 2019: 940, 2021: 1 024
`COD_DANE_RES_PR`	2 448	3,2 %	2013: 347, 2014: 242, 2015: 329, 2017: 291, 2019: 488, 2021: 751
`EDAD_ANOS_PR`	1	0,0 %	2021: 1

Las tres columnas más afectadas son institucionales o geográficas (`COD_DANE_*`), **ninguna es una variable del análisis longitudinal**, y el único vacío en edad es un registro. Conclusión operativa: los faltantes no obligan a un tratamiento especial (imputación o excluir dominios), lo que refuerza la viabilidad del MAS.

4.2.2 Bivariado: ¿la retención depende del grupo?

Para cada par de convocatorias consecutivas se calculó la retención por estrato candidato. La pregunta que importa para el diseño es **cuánta varianza de la retención explica cada variable**, porque con asignación proporcional la reducción teórica de varianza al estratificar es exactamente esa proporción. Se calcula sobre el **censo** (par de referencia 2019→2021, retención global 79,5 %):

Tabla 5. Varianza de la retención explicada por cada estrato candidato (censo).

Estrato candidato	Estratos	Varianza entre	Varianza dentro	χ^2	p
CLASIFICACION	4	**7,1 %**	92,9 %	1 189,0	$< 10^{-200}$
GENERO_COL	2	**0,1 %**	99,9 %	18,9	1,35e-05
GRAN_AREA	7	**1,4 %**	98,6 %	232,3	2,44e-47
DEPARTAMENTO_RES	32	**1,0 %**	99,0 %	166,8	1,59e-20
NIV_FORM	8	**0,3 %**	99,7 %	50,7	1,06e-08

Los contrastes χ^2 dan significativos todos los candidatos, pero eso es casi inevitable con $N = 30\,086$: la significación estadística no mide relevancia. Lo informativo es la **magnitud**: la categoría de reconocimiento explica el 7,1 % de la varianza de la retención, mientras que género, gran área, departamento y nivel de formación no llegan al 1,4 % cada uno. Es decir: **la población es homogénea en su comportamiento de permanencia salvo por la categoría**.

4.2.3 ¿Hay estratos naturales?

Tabla 6. Reducción teórica de varianza y estrato más pequeño por candidato.

Candidato	Estratos	Reducción teórica	Estrato más pequeño (censo)
CLASIFICACION × GRAN_AREA	27	8,4 %	2
CLASIFICACION × GENERO_COL	8	7,1 %	16
CLASIFICACION	4	7,1 %	53
GRAN_AREA	7	1,4 %	105
DEPARTAMENTO_RES	32	1,0 %	1
NIV_FORM	8	0,3 %	1
GENERO_COL	2	0,1 %	6 411

Lectura del EDA, que es la que sostiene las decisiones posteriores:

1. **Sí hay un estrato natural, pero uno solo: la categoría.** Con 4 estratos explica alrededor del 7 % de la varianza de la retención. Ese 7 % es el techo de lo que se puede ganar por esta vía, y es modesto.
2. **Combinar variables casi no añade y sí complica.** Añadir género a la categoría sube la varianza explicada de 7,08 % a 7,12 % (ocho estratos en lugar de cuatro), y cruzar

categoría con gran área llega a 8,39 % pero genera 27 estratos con celdas de 2 personas en el censo: inaplicable.

3. **Cuatro estratos es además lo que recomienda la teoría.** Cochran (1977, pp. 132–134) aconseja entre cuatro y seis estratos cuando el tamaño por estrato es razonable: el número de estratos se elige por el tamaño de muestra disponible, no por el tamaño de la población.
4. **No hay grupos pequeños que exijan representación garantizada** en el diseño: el grupo minoritario del censo (Emérito, 334 personas = 1,1 %) queda cubierto por el MAS en proporción, y su tratamiento se resuelve en la etapa de estimación (sección 4.4), no en la de diseño.

Las gráficas del EDA están en `data/memoria/eda/`.

4.3 Decisión de muestreo: MAS, y por qué

Se mantiene el **muestreo aleatorio simple de personas** ya ejecutado ($n = 2\,224$, semilla 2026). La decisión se sostiene en cuatro razones, y la tercera responde directamente a la pregunta de por qué no se combina con regresión:

1. **El marco es una lista completa de unidades finales.** Las 30 086 personas tienen identificador único y no hay duplicados persona × convocatoria, así que no existe la situación que justifica un diseño por conglomerados o polietápico (Cochran, 1977, §9–§10): no hay que muestrear unidades compuestas para llegar a las finales.
2. **El EDA no muestra estructura fuerte que obligue a estratificar.** Con un techo de ∼7 % de varianza explicada, y con un MAS cuyo error de diseño efectivo es de ±2,0 pp, la ganancia potencial de un diseño estratificado no compensa la pérdida de simplicidad: estratificar exigiría definir cuotas y ponderar cada estimación posterior.
3. **«MAS o regresión» es un falso dilema: se combinan, y aquí se hace.** La regresión no sustituye al diseño; entra como **información auxiliar** en la etapa de estimación. Eso es exactamente el estimador GREG de la sección 4.5: el diseño aporta la validez (insesgadez aproximada por diseño) y el modelo aporta eficiencia (menos varianza). Kalton (2002) y el FCSM (2003) formulan esta posición como el uso *asistido por el modelo* de la inferencia basada en el diseño. Dicho de otro modo: no se elige entre muestrear y modelar, se elige no hacer depender la validez del modelo.
4. **La igualdad de probabilidades simplifica el análisis longitudinal.** Al ser autoponderado, la retención de un par es directamente una proporción muestral y las matrices de transición son proporciones de celdas, sin ponderadores intermedios. Eso reduce las oportunidades de error en una cadena de cálculo que ya es larga.

Además, el MAS conserva la propiedad que hace posible esta sección: se puede **verificar** contra el censo, porque la base completa está disponible. La sección 4.6 explota esa posibilidad.

4.4 Post-estratificación

4.4.1 Fundamento y pesos

La post-estratificación repondera las observaciones para que la muestra reproduzca una composición de la población **conocida de antemano**. Con N_h el total poblacional del estrato h y n_h el de la muestra, el peso de cada persona del estrato es

$$w_i \;=\; \frac{N_h/N}{n_h/n} \tag{2}$$

y el estimador es $\sum_h W_h\,\hat{p}_h$ con $W_h = N_h/N$, con varianza estimada

$$v \;=\; \sum_h W_h^2 \left(1 - \frac{n_h}{N_h}\right) \frac{s_h^2}{n_h} \tag{3}$$

La propiedad que justifica usarla es que su distribución asintótica es la misma que la de un muestreo estratificado con asignación proporcional (Cochran, 1977, §5A; Lohr, 2010, §7.6). Su atractivo aquí es que es **barata**: la composición por categoría de toda la población se conoce, así que no hay coste de diseño.

4.4.2 Condición de tamaño mínimo: no se cumple en tres pares

Cochran (1977, pp. 132–134) recomienda que **cada estrato tenga un tamaño razonable, del orden de 20**, porque $\hat{p}_h$ se estima solo con las observaciones de ese estrato. El resultado de comprobarlo es incómodo y hay que decirlo:

Tabla 7. Tamaño muestral por estrato en cada par de convocatorias.

Par	n_h por estrato (Junior / Asociado / Sénior / Emérito)	¿Cumple $n_h > 20$?
2013→2014	440 / 128 / 50 / 0	sí
2014→2015	400 / 169 / 71 / 0	sí
2015→2017	444 / 227 / 81 / 1	**no** (Emérito $n_h = 1$)
2017→2019	580 / 271 / 125 / 7	**no** (Emérito $n_h = 7$)
2019→2021	757 / 322 / 176 / 3	**no** (Emérito $n_h = 3$)
2013→2021	440 / 128 / 50 / 0	sí

Un 0 en esa columna no significa un estrato pequeño sino **inexistente**: el reconocimiento Emérito no aparece en el padrón hasta 2015, así que en las convocatorias de 2013 y 2014 ese estrato no existe ni en la población ni en la muestra, y no hay nada que reponderar.

Consecuencias, y qué se hizo al respecto. En los pares donde Emérito tiene 1, 7 o 3 observaciones, la post-estratificación de 4 estratos hace depender el resultado de una celda diminuta: s_h^2 es inestable y el peso de esas personas se dispara (hasta 5,5 en el estrato «Investigador Emérito», estimado con 1 observación). Un peso así significa que una sola persona representa a decenas en la población, que es exactamente lo que la condición de Cochran busca

evitar. Las dos salidas estándar son **colapsar estratos** o **usar un modelo** que preste fuerza a la celda pequeña. Aquí se implementaron **las dos** y se reportan ambas: una post-estratificación colapsada (Sénior + Emérito, con lo que el estrato pequeño pasa a tener un tamaño suficiente en todos los pares) y el estimador GREG de la sección 4.5, que no depende de que cada celda tenga 20 casos porque estima un efecto común con todas las observaciones.

4.4.3 Resultados sobre la retención

Tabla 8. Retención estimada por par de convocatorias y por estimador.

Par	Censo	MAS	Post-estratificado (4)	Post-estratificado colapsado
2013→2014	60,09 %	61,17 %	62,19 %	62,19 %
2014→2015	82,81 %	82,66 %	82,66 %	82,66 %
2015→2017	81,23 %	80,74 %	80,09 %	80,66 %
2017→2019	76,87 %	76,50 %	76,44 %	76,64 %
2019→2021	79,51 %	80,21 %	80,35 %	80,41 %
2013→2021	56,18 %	56,63 %	57,31 %	57,31 %

Tabla 9. Error frente al censo y ganancia de varianza de la post-estratificación.

Par	Error MAS	Error PS	Error PS colapsado	Ganancia (PS)	Ganancia teórica del EDA
2013→2014	+1,073 pp	+2,099 pp	+2,099 pp	16,6 %	12,0 %
2014→2015	-0,158 pp	-0,155 pp	-0,155 pp	0,6 %	1,2 %
2015→2017	-0,490 pp	-1,139 pp	-0,575 pp	4,8 %	6,4 %
2017→2019	-0,371 pp	-0,427 pp	-0,232 pp	8,1 %	8,7 %
2019→2021	+0,694 pp	+0,834 pp	+0,895 pp	7,1 %	7,1 %
2013→2021	+0,459 pp	+1,133 pp	+1,133 pp	6,4 %	4,9 %

La última columna es la comprobación de que el EDA sirvió: la ganancia de varianza que la post-estratificación logra en la muestra sigue de cerca a la que el EDA había predicho con el censo (por ejemplo, 7,1 % previsto frente a 7,1 % logrado en 2019→2021). Es decir: **la decisión de estratificar por categoría se tomó con evidencia previa y el resultado la confirmó**.

4.4.4 ¿La post-estratificación acerca las estimaciones al censo?

No de forma sistemática. El MAS es el más cercano al censo en 4 de los 6 pares. La post-estratificación reduce la varianza entre 0,6 % y 16,6 %, pero no reduce el error frente al valor poblacional; en los pares 2013→2014, 2015→2017 y 2013→2021 incluso lo aumenta.

La explicación es la que ya anticipaba el EDA: **la muestra del MAS ya estaba equilibrada**. La categoría explica solo ∼7 % de la varianza de la retención, de modo que el desbalance que la post-estratificación podría corregir es pequeño, y lo que queda es ruido de muestreo. Dicho con precisión: la post-estratificación **no corrige un sesgo, compra precisión**.

4.5 Estimador GREG (model-assisted)

4.5.1 Modelos ajustados

Para cada variable de interés se ajustó un modelo con variables auxiliares **conocidas en toda la población**:

Tabla 10. Modelos auxiliares ajustados por variable de interés.

Variable de interés	Modelo	Auxiliares
Retención (sí/no)	Logístico	categoría, género †, gran área, departamento de residencia
Edad	Lineal	género †, gran área, región de residencia
Ascenso de categoría	Ordinal (odds proporcionales, 3 niveles) y logístico (binario)	categoría en t_1, género †, gran área

† El género entra por la columna **colapsada** (*Otro / No especificado*), no por las cuatro categorías originales. Motivo y consecuencias en la sección 4.7.4.

El modelo ordinal se ajustó por máxima verosimilitud implementada directamente (con penalización L2 para estabilizar), porque el entorno no dispone de `statsmodels`. Del modelo ordinal se deriva $P(\text{asciende})$ por persona y se usa como modelo de trabajo del GREG, igual que con el logístico.

4.5.2 Resultados

Tabla 11. Retención estimada por el GREG (modelo lineal y logístico).

Par	Censo	MAS	GREG lineal	GREG logístico
2013→2014	60,09 %	61,17 %	61,65 %	61,80 %
2014→2015	82,81 %	82,66 %	82,72 %	82,76 %
2015→2017	81,23 %	80,74 %	79,97 %	80,53 %
2017→2019	76,87 %	76,50 %	76,78 %	76,59 %
2019→2021	79,51 %	80,21 %	80,42 %	80,35 %
2013→2021	56,18 %	56,63 %	56,95 %	57,14 %

Tabla 12. Ganancia de varianza del GREG y ajuste del modelo lineal.

Par	Ganancia GREG-lineal	Ganancia GREG-logit	R^2 en la muestra (lineal)
2013→2014	20,6 %	20,1 %	0,2056
2014→2015	7,6 %	5,9 %	0,0762
2015→2017	10,6 %	9,3 %	0,1063
2017→2019	10,0 %	9,1 %	0,1002
2019→2021	8,9 %	8,5 %	0,0885
2013→2021	18,5 %	17,5 %	0,1850

Edad (población: personas en su última convocatoria; censo = 45,5190 años):

Tabla 13. Estimación de la edad media por estimador.

Estimador	Valor	Error estándar	IC 95 %	Ganancia de varianza
MAS	45,1435	0,2096	[44,733; 45,554]	0,0 %
Post-estratificado	45,2399	0,2043	[44,839; 45,640]	5,0 %
GREG lineal	45,1528	0,2059	[44,749; 45,556]	3,5 %

El modelo lineal de la edad explica poco ($R^2 = 0{,}0351$), coherente con el EDA: género, área y región apenas distinguen la edad. La ganancia de precisión es por tanto pequeña (3,5 %). Con las 46 edades mayores de 100 excluidas, el censo pasa a 45,3931 años y el MAS a 45,1435.

Ascenso de categoría 2019→2021 (población: 13 355 personas presentes en ambas convocatorias; en el censo ascendieron 2 336, permanecieron 9 657 y descendieron 1 362):

Tabla 14. Estimación del ascenso de categoría 2019→2021.

Estimador	Valor	Error estándar	Ganancia de varianza	Error vs censo
MAS	18,73 %	1,18 %	0,0 %	+1,240 pp
Post-estratificado	18,34 %	1,12 %	9,4 %	+0,847 pp
GREG lineal	18,26 %	1,14 %	7,3 %	+0,769 pp
GREG logístico	18,37 %	1,14 %	7,3 %	+0,881 pp
GREG con modelo ordinal	18,41 %	1,15 %	5,0 %	+0,920 pp

Aquí sí ocurre lo que la teoría predice: **los tres estimadores asistidos por modelo reducen el error** frente al MAS (de +1,240 pp a +0,881 pp con el logístico), y además reducen la varianza. El motivo es que en este caso sí había desbalance: el MAS sobrerrepresentó a quienes ascendieron, y tanto la reponderación como el modelo lo corrigen.

4.6 Comparación de los tres estimadores

4.6.1 Comprobación interna: la post-estratificación es un caso particular de GREG

Si el modelo auxiliar del GREG se satura en los post-estratos, los dos estimadores deben **coincidir exactamente**. Se verificó con los datos reales (retención 2019→2021, post-estratos = categoría):

Tabla 15. Comprobación numérica: post-estratificación como GREG saturado.

Estimador	Valor
GREG con modelo saturado en categoría	80,347473 %
Post-estratificado por categoría	80,347473 %
Diferencia absoluta	**1.11e-16** pp (ruido de coma flotante)

No es un detalle decorativo: confirma que las dos implementaciones son coherentes entre sí y con la teoría (Särndal et al., 1992), y que cualquier diferencia entre ellas proviene del modelo, no de un error de cálculo.

4.6.2 Tabla comparativa completa

Tabla 16. Comparación completa de los tres estimadores con intervalos de confianza.

Parámetro	Censo	MAS	Post-estratificado	GREG	Más cercano
Retención 2013→2014	60,09 %	61,17 % [57,47; 64,86]	62,19 % [58,82; 65,56]	61,80 % [58,50; 65,10]	MAS
Retención 2014→2015	82,81 %	82,66 % [79,84; 85,48]	82,66 % [79,85; 85,47]	82,76 % [80,02; 85,49]	GREG
Retención 2015→2017	81,23 %	80,74 % [78,03; 83,45]	80,09 % [77,45; 82,74]	80,53 % [77,95; 83,11]	MAS
Retención 2017→2019	76,87 %	76,50 % [73,95; 79,05]	76,44 % [74,00; 78,89]	76,59 % [74,16; 79,02]	GREG
Retención 2019→2021	79,51 %	80,21 % [78,09; 82,33]	80,35 % [78,31; 82,39]	80,35 % [78,32; 82,38]	MAS
Retención 2013→2021	56,18 %	56,63 % [52,88; 60,39]	57,31 % [53,67; 60,94]	57,14 % [53,72; 60,55]	MAS
Edad media	45,519	45,144 [44,73; 45,55]	45,240 [44,84; 45,64]	45,153 [44,75; 45,56]	Post-estrat.
Ascenso 2019→2021	17,49 %	18,73 % [16,42; 21,05]	18,34 % [16,13; 20,54]	18,37 % [16,14; 20,60]	Post-estrat.

Cada celda de estimador lleva su intervalo de confianza al 95 %; la última columna indica cuál quedó más cerca del valor del censo.

4.6.3 Ganancia de precisión

Tabla 17. Reducción de varianza por estimador, según el parámetro.

Parámetro	Reducción con post-estratificación	Con GREG
Retención 2013→2014	16,6 %	20,1 %
Retención 2014→2015	0,6 %	5,9 %
Retención 2015→2017	4,8 %	9,3 %
Retención 2017→2019	8,1 %	9,1 %
Retención 2019→2021	7,1 %	8,5 %
Retención 2013→2021	6,4 %	17,5 %
Edad media	5,0 %	3,5 %
Ascenso 2019→2021	9,4 %	7,3 %

4.6.4 Una advertencia metodológica importante

La columna «estimador más cercano al censo» se calcula comparando cada estimación con el valor poblacional verdadero. Es una comprobación valiosa **porque aquí el censo se conoce**, y sirve para verificar que las implementaciones no están sesgadas. Pero **no** es un criterio válido para elegir estimador: el error realizado es **una sola realización** de la muestra. Si se hubiera sorteado otra semilla, el orden podría cambiar. El criterio correcto para elegir es la **varianza** (la ganancia de precisión de la sección 4.6), que sí es una propiedad del estimador y no del sorteo concreto. Por eso se reportan las dos cosas por separado y no se elige por el error observado.

4.7 Diagnósticos y verificación de supuestos

Hedlin et al. (2001) recomiendan no dar por buena una estimación asistida por modelo sin antes analizar **los g-weights, los residuos y los diagnósticos estándar de regresión**. Esta sección los presenta. El entorno no dispone de `statsmodels`, así que cada prueba se implementó directamente: la corrección de Lilliefors por Monte Carlo (el KS con parámetros estimados de los propios datos no es válido), Breusch-Pagan, una versión recortada de White, Levene y Bartlett, errores estándar robustos HC3 y los g-weights del GREG.

4.7.1 Normalidad de la única variable continua: la edad

Tabla 18. Diagnósticos de normalidad de la edad y de los residuos.

Conjunto	n	Asimetría	Curtosis (exceso)	Shapiro-Wilk W (p)	Lilliefors D (p)
Edad — **censo**	30 085	**25,396**	**1 562,470**	0,8386 (1,34e-57)	0,0927 ($< 10^{-300}$)
Edad — muestra MAS	2 224	**0,493**	**-0,212**	0,9774 (2,78e-18)	0,0681 ($< 10^{-300}$)
Residuos del modelo de edad	2 224	**0,495**	**-0,130**	0,9797 (2,79e-17)	0,0630 ($< 10^{-300}$)

Conclusión, y aquí está el matiz importante. Con n grande las pruebas formales rechazan casi siempre, y este caso lo ilustra: en la muestra el p-valor de Shapiro-Wilk es 2,78e-18 y el de Lilliefors es $< 10^{-300}$, es decir rechazan la normalidad. Pero la asimetría (0,493) y el exceso de curtosis (-0,212) están **dentro de los umbrales aceptables** (|asimetría| < 1 y |curtosis| < 7; Field, 2009, recomienda precisamente los momentos para $n > 200$). El rechazo es un efecto del tamaño, no una desviación relevante.

El censo cuenta otra historia: asimetría 25,40 y curtosis 1 562,5, valores incompatibles con una normal y que no son ruido: los producen los 11 registros con más de 100 años (máximo 956,25). Dicho de otro modo, **la conclusión sobre normalidad depende de si se analiza el censo o la muestra**, porque la muestra no captura esa cola patológica. Es un argumento más para (i) reportar el censo y (ii) tratar esas edades como error de captura y no como una característica de la población.

Conviene añadir que la normalidad de y **no es un supuesto del que dependa la validez del GREG** (consistente por diseño) ni la insesgadez de mínimos cuadrados ordinarios: solo condiciona los intervalos en muestras finitas. Por eso se evaluó también la normalidad de los **residuos**, que es la que importa: asimetría 0,495 y exceso de curtosis -0,130, ambas aceptables, con pruebas formales que vuelven a rechazar por tamaño.

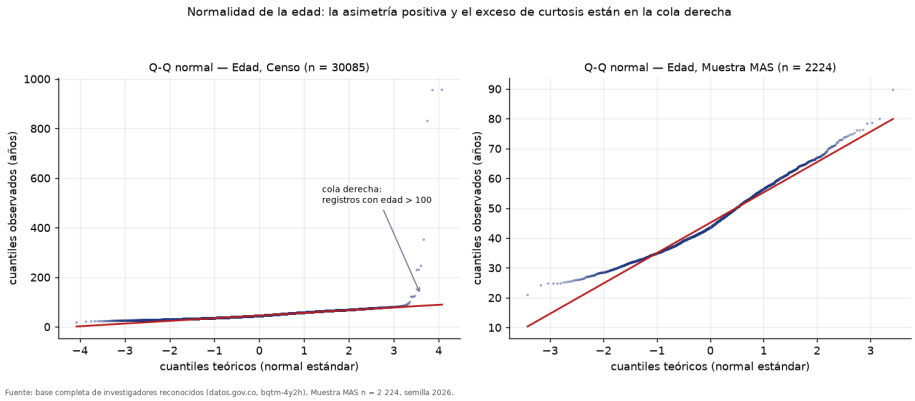


Figura 1. Q-Q plot de la edad: censo y muestra. El censo se aparta en la cola por los registros con edad superior a 100 años.

4.7.2 Heterocedasticidad del modelo GREG

Modelo diagnosticado: la edad con auxiliares género, gran área y región (2 224 observaciones, 17 parámetros).

Tabla 19. Contrastes de heterocedasticidad del modelo de edad.

Prueba	**Estadístico**	**gl**	p	**Lectura**
Breusch-Pagan	LM = 25,10	16	6,80e-02	**sin evidencia** de heterocedasticidad al 5 %
White (recortada)	LM = 62,12	136	1,00e+00	degenerada: ver nota
Levene entre celdas	1,057	—	3,52e-01	**sin evidencia**
Bartlett entre celdas	59,99	—	8,43e-01	**sin evidencia**

Sobre la prueba de White: aquí no aplica limpiamente, y conviene explicar por qué. Con regresores **solo dicotómicos**, el cuadrado de una variable dummy es la propia dummy y el producto cruzado de dos dummies es otra dummy. Los términos adicionales que White introduce son por tanto colineales con los niveles, y la matriz de diseño queda singular. Se ejecutó una versión recortada (únicamente los 120 productos cruzados distintos): da LM = 62,1 con 136 grados de libertad, un resultado degenerado que no aporta información. Lo apropiado con un diseño factorial de este tipo es comparar las **varianzas entre las celdas del modelo**, que es lo que hacen Levene y Bartlett, y ninguna de las dos encuentra diferencias.

Queda un matiz honesto: la razón entre la varianza mayor y la menor de las celdas es de 30,4×, que en abstracto parece grande. La razón de que los contrastes no la detecten es que las celdas con varianza extrema son muy pequeñas (la menor tiene 5 observaciones), y un contraste no puede declarar una diferencia estable con esa base. Se reportan las dos cosas en lugar de elegir la que conviene.

¿Se justifican errores robustos? No. El error estándar clásico de la media ajustada es 1,1447 y el robusto HC3 es 1,1206: la razón es **0,979**, es decir la corrección robusta no solo

no agranda el error sino que lo reduce ligeramente. Con esa evidencia, un modelo con errores robustos añadiría complejidad sin cambiar ninguna conclusión.

El caso de la retención es distinto y hay que decirlo. En una variable binaria la heterocedasticidad es **estructural** —$\mathrm{Var}(y) = p(1-p)$ depende de p—, así que Breusch-Pagan la detecta siempre (LM = 125,1, p = 1,92e-10). No es un defecto del ajuste: es la razón por la que el GREG de la retención se implementó con un modelo **logístico** y no con una probabilidad lineal. Como comprobación de que la lineal no bastaba, sus valores ajustados se salen del intervalo $[0, 1]$: van de -0,028 a 1,126.

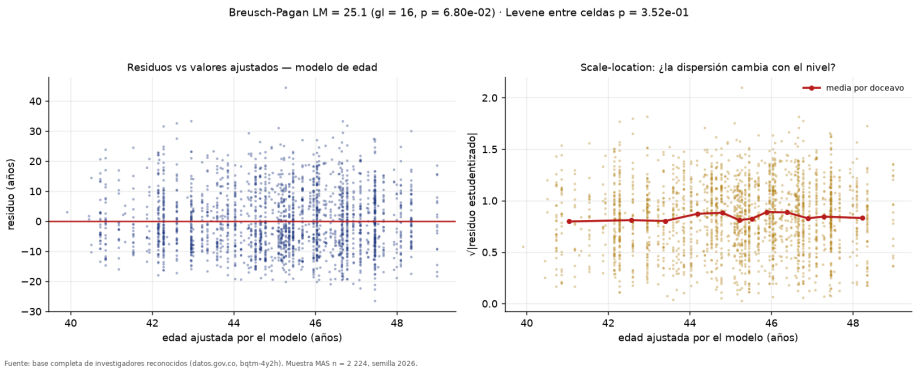


Figura 2. Residuos frente a valores ajustados y scale-location del modelo de edad.

4.7.3 g-weights e influencia

Los g-weights son los pesos implícitos que el GREG introduce sobre los pesos de diseño: $w_i^G = w_i\, g_i$, con $g_i = 1 + \lambda' x_i$. Un g-weight grande significa que unas pocas observaciones están cargando con toda la corrección del modelo, y es la primera cosa que Hedlin et al. (2001) recomiendan mirar.

Tabla 20. Distribución de los g-weights por modelo.

Modelo	Mínimo	q05	Mediana	q95	Máximo	> 5	> 10
Edad (género, área, región)	0,584	0,827	1,020	1,103	**1,471**	0	0
Retención 2019→2021 (lineal)	0,374	0,753	1,006	1,228	**2,696**	0	0

No hay ningún g-weight extremo: el máximo es 1,471 en el modelo de edad y 2,696 en el de retención, muy por debajo de los umbrales de alarma de 5 y 10. La media es exactamente 1, como debe ser. Adicionalmente se comprobó la propiedad de calibración: $\sum w_i g_i = N$ se cumple de forma exacta (razón 1,000000).

Un hallazgo que sí conviene declarar. Los totales auxiliares se reproducen exactamente **salvo una columna** de género, y por una razón de diseño, no de cálculo: la categoría *Otro / No especificado* tiene cero observaciones en la muestra, así que ninguna observación la representa y su total poblacional no es calibrable. La matriz de calibración tiene número de condición 5,2e+17 y rango 16 sobre 17 columnas. Es un límite del método frente a categorías

no representadas, y la solución —si interesara— sería de diseño: garantizar representación de esas categorías. La sección 4.7.4 lo cuantifica.

Las demás columnas se reproducen con precisión de máquina (desvío máximo 4,0e-11 en las calibrables), y la masa que queda sin calibrar son 8 personas de 30 085, es decir el 0,0266 % del universo de esa población.

Observaciones influyentes. Leverage medio 0,0072 y máximo 0,0941; distancia de Cook máxima **0,0223**. Aquí hay que leer los umbrales con cuidado: superan el umbral de Cook ($4/n$ = 0,0018) 84 observaciones y el de leverage ($2k/n$ = 0,0153) 103, pero el criterio convencional de preocupación es Cook > 1 y el máximo observado es 0,0223: **dos órdenes de magnitud por debajo**. Con n grande esos umbrales señalizan muchas observaciones sin que ninguna sea materialmente influyente. Lo que decide es la magnitud, no el recuento.

Para no quedarse en la teoría, se recalculó el estimador GREG **eliminando** las observaciones de g más alto y se midió el efecto:

Tabla 21. Sensibilidad del estimador de la edad a las observaciones con mayor g.

Se eliminan	Estimador de la edad	Cambio	g máximo restante
las 0 de mayor g	45,1528	0,00000	1,471
las 5 de mayor g	45,1423	-0,01054	2,428
las 10 de mayor g	45,1110	-0,04178	8,205
las 25 de mayor g	45,1705	0,01766	1,314
ninguna (completo)	45,1528	0,00000	1,471

El efecto máximo de quitar las 25 observaciones con mayor g es de 0,04178 años, es decir **menos de un mes de edad media**: ninguna observación individual está moviendo el resultado.

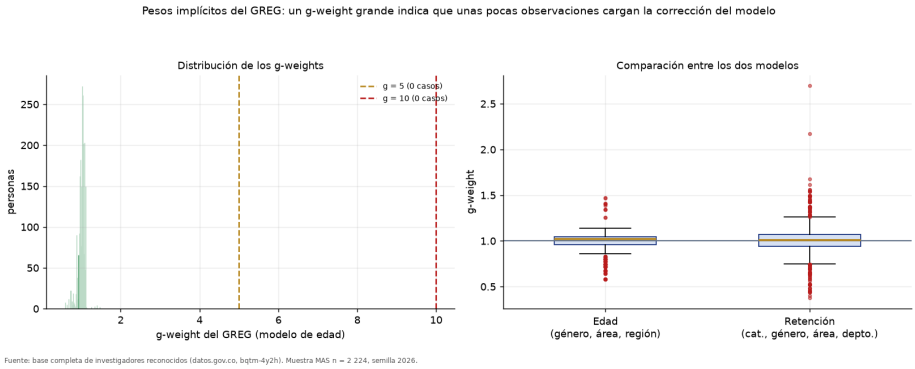


Figura 3. Distribución de los g-weights del modelo de edad.

4.7.4 Colapso de las categorías de género no representadas

El problema. El registro reconoce cuatro categorías de género. Dos de ellas tienen una presencia mínima en el universo y **ninguna** en la muestra:

Tabla 22. Categorías de género con presencia mínima y su representación muestral.

Categoría	Personas en el censo	% del censo	Registros	Observaciones en la m
Intersexual	5	0,0166 %	5	
No disponible	4	0,0133 %	4	
Otro / No especificado (colapsada)	9	0,0299 %	—	

Las **9 personas** son el 0,030 % del censo. Un detalle que importa para lo que sigue: las etiquetas *Intersexual* y *No disponible* aparecen **únicamente en la convocatoria 2021** (5 y 4 registros, respectivamente). Las mismas personas sí figuran en convocatorias anteriores, pero con otra etiqueta de género.

La consecuencia. Una categoría auxiliar con cero observaciones en la muestra no es calibrable: el GREG no puede reproducir su total poblacional porque ninguna observación lo representa, y su coeficiente queda indeterminado. No es un error de cálculo; es un límite del diseño. En la comprobación de calibración aparecía como un desvío exactamente igual al recuento censal de la columna (8 personas sin calibrar, repartidas en dos columnas). Son 8 y no 9 porque el modelo de edad excluye a la persona sin edad registrada, que es una de las 9 colapsadas.

La decisión. En **todos los análisis desagregados por género** las dos categorías se colapsan en una sola, *Otro / No especificado*. Se conserva la columna original del registro para dos usos que sí necesitan el dato crudo: el control de calidad de género contradictorio (que cuenta categorías distintas por persona y por eso debe ver el registro tal como está) y el visor de trayectorias, que reproduce el censo sin transformarlo.

Qué cambia y qué no. Se midieron tres variantes del vector auxiliar del modelo de edad. Los estimadores son idénticos en las tres:

Tabla 23. Variantes del vector auxiliar de género y su efecto sobre la calibración.

Variante	Cols.	Rango(M)	cond(M)	No calibrables	Sin calibrar	GREG edad
Sin colapsar (4 categorías crudas)	18	16 de 18	2,3e+17	2	8	45,1528
Colapsada (decisión adoptada)	17	16 de 17	5,2e+17	1	8	45,1528
Colapsada y columna excluida	16	16 de 16	3,9e+02	0	0	45,1528

El colapso **no devuelve la calibrabilidad** a la categoría: la causa es la ausencia en la muestra, no la granularidad excesiva. Reduce de dos a una las columnas no calibrables y agrupa el hueco en un rótulo, pero la masa sin calibrar sigue siendo de 8 personas y el rango de M no mejora. Tampoco empeora el ajuste: el desvío de esa columna es exactamente su recuento censal y las demás se reproducen con precisión de máquina.

Dos consecuencias verificadas que conviene dejar dichas, porque podrían esperarse mal:

1. **El estimador y su varianza no cambian en absoluto** (diferencia 0 años entre colapsar y no colapsar). Era previsible: en la muestra ambas columnas eran constantes cero, así que su coeficiente ya era nulo y el colapso solo fusiona dos columnas nulas

en una. El colapso es una decisión de **coherencia y trazabilidad**, no una corrección numérica, y así se reporta.

2. **Las tablas de retención y transición por género no cambian.** La convocatoria base de cada par es siempre anterior a 2021, y las etiquetas solo existen en 2021: ninguna persona aparece con ellas como base de un par. Se comprobó sobre los resultados del panel y no hay ni una sola celda de las tablas desagregadas por género que las contenga. Lo que sí cambia es la prueba de representatividad, y solo en los grados de libertad: el estadístico es invariante ($\chi^2 = 3{,}1283$ en ambos casos, porque una celda con observado cero aporta a χ^2 exactamente su esperado), mientras los gl bajan de 3 a 2 y el p-valor sube de 0,3723 a 0,2093. Con el colapso la distribución de género de la muestra sigue siendo compatible con la del censo, y el supuesto de frecuencia esperada mínima sigue sin cumplirse en ninguno de los dos casos (esperado mínimo $0{,}6653 < 5$).
3. **Los diagnósticos que se normalizan por el número de parámetros sí se mueven, y en la proporción esperada.** La distancia de Cook máxima pasa de 0,0211 a 0,0223: el factor es el cociente de parámetros ($18/17 = 1{,}0588$), porque la fórmula de Cook divide por k, más el ajuste de $n - k$ en la varianza residual. El ajuste no cambia —los residuos son los mismos— pero conviene decirlo para que la diferencia no parezca un efecto del colapso sobre el modelo.

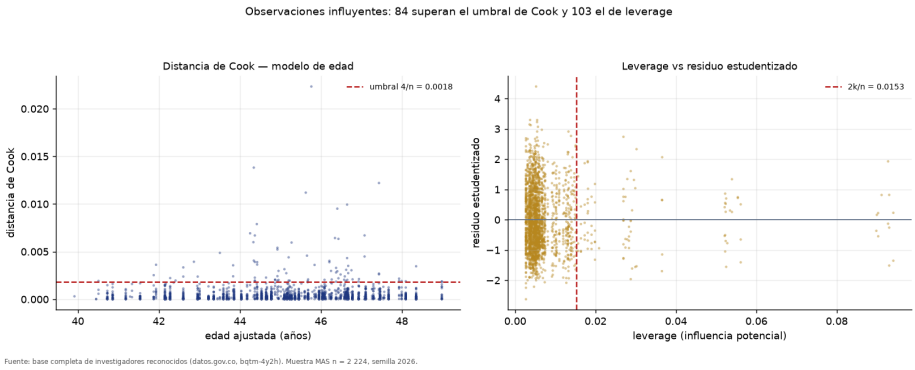


Figura 4. Distancia de Cook y leverage del modelo de edad. El máximo de Cook (0,0223) está dos órdenes de magnitud por debajo del umbral de preocupación.

La limitación que permanece, y su salida. La categoría colapsada sigue sin ser calibrable, así que los totales auxiliares no se reproducen al 100 %. Si se quisiera cerrar el hueco por completo hay dos caminos, y ninguno es un truco de cálculo: (i) **de diseño**, garantizar representación de esas categorías en la muestra; o (ii) **de alcance**, excluir del vector auxiliar la columna no representada y declarar que el género de esas 8 personas queda fuera de la calibración. La tercera fila de la tabla 23 mide la variante (ii): deja **cero** columnas sin calibrar y un número de condición de 3,9e+02 —frente a 5,2e+17— con el **mismo estimador**. No se adoptó porque la decisión acordada es colapsar y declarar, y porque dejar la columna dentro hace visible la limitación en la propia comprobación de calibración; pero está medida y disponible si se prefiere la calibración exacta.

4.7.5 Conclusión: ¿es razonable el modelo GREG?

Sí, con dos matices documentados. La evidencia:

1. **Sin g-weights extremos.** Máximo 1,471 (edad) y 2,696 (retención); ninguno supera 5. La calibración se verifica exactamente ($\sum w_i g_i = N$).
2. **Sin observaciones influyentes materiales.** Distancia de Cook máxima 0,0223, muy por debajo del nivel de preocupación; quitar las observaciones de mayor g mueve la estimación menos de 0,05 años.
3. **Sin heterocedasticidad que exija corrección.** Breusch-Pagan p = 6,80e-02, Levene p = 3,52e-01, Bartlett p = 8,43e-01; y la razón HC3/clásico de 0,979 confirma que los errores robustos no aportan.
4. **La normalidad no es un supuesto crítico.** No se cumple en el censo por 11 edades erróneas, pero la consistencia del GREG es por diseño y no depende de ella.

Los dos matices. Primero, la categoría de género *Otro / No especificado* no es calibrable porque no tiene representación en la muestra: el límite está en el diseño muestral, no en el estimador, y se declara en lugar de omitirse (ver la sección 4.7.4, donde además se mide la variante que sí calibra exactamente). Segundo, la prueba de White no es aplicable a un diseño de solo dicotómicas y se sustituye por contrastes de homocedasticidad entre celdas, que es lo apropiado para un modelo factorial. Con esas salvedades, los diagnósticos respaldan el uso del GREG que se reporta en las secciones 4.5 y 4.6.

4.8 Conclusión: qué se reporta y por qué

1. **Las cifras oficiales del análisis longitudinal son las del censo.** La base completa está disponible, así que no hay razón para reportar una estimación cuando se puede reportar el parámetro. Toda la maquinaria de muestreo de esta sección tiene un valor **metodológico y de verificación**, no de sustitución.
2. **Si hubiera que estimar a partir de la muestra, el MAS simple ya sería suficiente y es el que menos supuestos exige.** Es insesgado por diseño y en esta aplicación resultó el más cercano al censo en 4 de los 6 pares, precisamente porque la muestra quedó equilibrada.
3. **La post-estratificación por categoría no corrige sesgo: compra precisión.** Reduce la varianza entre 0,6 % y 16,6 % según el par, sin mejorar de forma sistemática el error frente al censo. Se justifica cuando el objetivo es estrechar intervalos, no cuando se sospecha un desbalance.
4. **El GREG es el estimador recomendado si hay que estimar**, porque domina en varianza (hasta 20,1 % de reducción) y porque su validez no depende de que el modelo esté bien especificado: es la propiedad *model-assisted* de Kalton (2002) y del FCSM (2003). Además resuelve el problema del estrato pequeño, que es el punto débil de la post-estratificación en este corpus.
5. **El estrato pequeño se declara, no se esconde.** Con Emérito en 1, 7 y 3 observaciones

según el par, la post-estratificación de 4 estratos incumple la condición de tamaño mínimo de Cochran (1977). La versión colapsada (Sénior + Emérito) la cumple y se reporta junto a la otra, y el GREG ofrece una tercera vía que no depende de que cada celda sea grande.

Recomendación operativa. Reportar el censo; documentar el MAS como el diseño de referencia y su validación (Anexo A de `analisis_longitudinal.md`); y usar GREG —no la post-estratificación de 4 estratos— si en algún momento hubiera que producir una estimación muestral con intervalos más estrechos.

Referencias de esta sección

- Cochran, W. G. (1977). *Sampling Techniques* (3rd ed.). John Wiley & Sons. — Formulación y ajuste del tamaño de muestra; post-estratificación (§5A); recomendación de 4 a 6 estratos con ∼20 observaciones por estrato (pp. 132–134).
- Lohr, S. L. (2010). *Sampling: Design and Analysis* (2nd ed.). Brooks/Cole. — Muestreo aleatorio simple, estimación de proporciones y post-estratificación (§7.6).
- Särndal, C.-E., Swensson, B., & Wretman, J. (1992). *Model Assisted Survey Sampling*. Springer-Verlag. — Estimador GREG y su forma de diferencia (§6.4–6.5); la post-estratificación como caso particular con modelo saturado.
- Kalton, G. (2002). Models in the practice of survey sampling. *International Statistical Review*, 70(2), 175–192. — Uso de modelos en modo asistido, de forma que la validez de las estimaciones no dependa de los supuestos del modelo.
- FCSM (2003). *Glossary of Terms*. Federal Committee on Statistical Methodology. — Definición y motivación del estimador GREG como *model-assisted*.
- StatsRef.com (s. f.). *Exploratory data analysis*. En *Statistics Reference Online*. — «EDA . . . is typically the first stage of any such analysis»; síntesis de la posición de Cochran (1977) sobre el trabajo exploratorio previo.
- OhioLINK ETD Center. *Post-stratification variance*. — La distribución asintótica del estimador post-estratificado coincide con la del estimador de un muestreo estratificado con asignación proporcional (Cochran, 1977; Lohr, 1999).
- Canadian Journal of Forest Research (2019). *Efficiency of post-stratification for a large-scale forest inventory*. — Recomendación de Cochran (1977, pp. 132–134) sobre el número de estratos y el tamaño mínimo por estrato.
- Hedlin, D., y Falvey, H. *Does the model matter for GREG estimation? A business survey example*. — Análisis de g-weights, residuos y diagnósticos de regresión para verificar que una estimación GREG es razonable. Nota de transparencia: la ficha se verificó por búsqueda en línea (Semantic Scholar y DiVA, Universidad de Estocolmo), pero el año (2001) procede del enunciado de la tarea: el metadato accesible no permitió confirmarlo en el entorno de trabajo.
- Valliant, R. et al. *svydiags: Regression Model Diagnostics for Survey Data* [paquete de R]. CRAN. — Diagnósticos de regresión (residuos, leverage, influencia) adaptados a datos

de encuesta.

- Field, A. (2009). *Discovering Statistics Using SPSS* (3rd ed.). SAGE. — Recomendación de usar asimetría y curtosis como criterio principal de normalidad cuando $n > 200$.

Artefactos y reproducibilidad

Tabla 24. Artefactos que producen las cifras de esta sección.

Artefacto	Contenido
`src/eda_longitudinal.py`	EDA completo (parte 1)
`data/memoria/eda_resultados.json`	Cifras del EDA
`data/memoria/eda/`	6 gráficas del EDA
`src/estimadores_longitudinal.py`	Post-estratificación y GREG (partes 2–3)
`data/memoria/estimadores_resultados.json`	Cifras de los estimadores
`src/genero_comun.py`	Colapso de las categorías de género
`src/diagnosticos_greg.py`	Diagnósticos de supuestos y g-weights
`data/memoria/diagnosticos_greg.json`	Cifras de los diagnósticos
`data/memoria/eda/07_qq_edad.png`	Q-Q plot de la edad
`data/memoria/eda/08_residuos_vs_ajustados.png`	Residuos frente a ajustados
`data/memoria/eda/09_gweights.png`	Distribución de los g-weights
`data/memoria/eda/10_influencia.png`	Distancia de Cook y leverage
`src/generar_metodologia_muestreo.py`	Genera el informe de origen

```
python src/eda_longitudinal.py
python src/estimadores_longitudinal.py
python src/diagnosticos_greg.py
python src/generar_metodologia_muestreo.py
```

El muestreo **no se rehizo**: se reutilizan los identificadores de `data/memoria/muestra_ids.csv` (semilla 2026).

5 Conclusiones y recomendaciones del criterio

El objetivo del repositorio está bien entendido y correctamente descompuesto en preguntas que los módulos efectivamente responden (patrón Pregunta ->Hallazgo ->Caveat). Recomendaciones: (1) formalizar un marco de indicadores; (2) documentar la evolución del alcance 3 ->6 convocatorias en un único documento; (3) alinear README, catálogo y artefactos versionados (el consolidado versionado solo cubre 3 convocatorias — ver criterio 2).

Fuentes de consulta (no citadas en el texto)

[Clauset et al.(2015)Clauset, Arbesman, and Larremore] Aaron Clauset, Samuel Arbesman, and Daniel B Larremore. Systematic inequality and hierarchy in faculty hiring networks. *Science Advances*, 1(1):e1400005, 2015.

[Clauset et al.(2017)Clauset, Larremore, and Sinatra] Aaron Clauset, Daniel B Larremore, and Roberta Sinatra. Data-driven predictions in the science of science. *Science*, 355(6324): 477–480, 2017.

[Crenshaw(1989)] Kimberle Crenshaw. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine, feminist theory and antiracist politics. *University of Chicago Legal Forum*, 1989:139–167, 1989.

[Fortunato et al.(2018)Fortunato, Bergstrom, Börner, Evans, Helbing, Milojević, Petersen, Radicchi, Sinatra, Santo Fortunato, Carl T Bergstrom, Katy Börner, James A Evans, Dirk Helbing, Staša Milojević, Alexander M Petersen, Filippo Radicchi, Roberta Sinatra, Brian Uzzi, et al. Science of science. *Science*, 359(6379):eaao0185, 2018.

[Freeman(1977)] Linton C Freeman. A set of measures of centrality based on betweenness. *Sociometry*, 40(1):35–41, 1977.

[Greenacre(2017)] Michael Greenacre. *Correspondence Analysis in Practice*. Chapman and Hall/CRC, 3rd edition, 2017.

[Hicks et al.(2015)Hicks, Wouters, Waltman, de Rijcke, and Rafols] Diana Hicks, Paul Wouters, Ludo Waltman, Sarah de Rijcke, and Ismael Rafols. The leiden manifesto for research metrics. *Nature*, 520(7548):429–431, 2015.

[Hirsch(2005)] Jorge E Hirsch. An index to quantify an individual's scientific research output. *Proceedings of the National Academy of Sciences*, 102(46):16569–16572, 2005.

[Huang(1998)] Zhexue Huang. Extensions to the k-means algorithm for clustering large data sets with categorical variables. *Data Mining and Knowledge Discovery*, 2(3):283–304, 1998.

[Husson et al.(2017)Husson, Lê, and Pagès] François Husson, Sébastien Lê, and Jérôme Pagès. *Exploratory Multivariate Analysis by Example Using R*. Chapman and Hall/CRC, 2nd edition, 2017.

[International(2017)] DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. Technics Publications, 2nd edition, 2017.

[Kemeny and Snell(1976)] John G Kemeny and J Laurie Snell. *Finite Markov Chains*. Springer-Verlag, 1976.

[Kimball and Ross(2013)] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. John Wiley & Sons, 3rd edition, 2013.

[Larivière et al.(2013)Larivière, Ni, Gingras, Cronin, and Sugimoto] Vincent Larivière, Chaoqun Ni, Yves Gingras, Blaise Cronin, and Cassidy R Sugimoto. Bibliometrics: Global gender disparities in science. *Nature*, 504(7479):211–213, 2013.

[Lotka(1926)] Alfred J Lotka. The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences*, 16(12):317–323, 1926.

[Newman(2001)] Mark EJ Newman. The structure of scientific collaboration networks. *Proceedings of the National Academy of Sciences*, 98(2):404–409, 2001.

[Wang and Strong(1996)] Richard Y Wang and Diane M Strong. Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12 (4):5–33, 1996.

[Wasserman and Faust(1994)] Stanley Wasserman and Katherine Faust. *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.

[Wilkinson et al.(2016)Wilkinson, Dumontier, Aalbersberg, Appleton, Axton, Baak, Blomberg, Boiten, da Si
Mark D Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.

[Wirth and Hipp(2000)] Rüdiger Wirth and Jochen Hipp. Crisp-dm: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, 2000.

[Zeng et al.(2021)Zeng, Shen, Zhou, Fan, Di, Wang, Stanley, and Havlin] An Zeng, Zhesi Shen, Jianlin Zhou, Jinshan Fan, Zengru Di, Yougui Wang, H Eugene Stanley, and Shlomo Havlin. The science of science: From the perspective of complex systems. *Physics Reports*, 935:1–60, 2021.