
Criterio 2: Datos utilizados: suficiencia y corrección

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Commit auditado: 1528939

Versión 1.0 · 30 de septiembre de 2026

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario (solo los términos que usa este documento)	2
2. Datos utilizados: suficiencia y corrección	3
2.1. Fuentes del repositorio	3
3. Relación con los demás criterios	3
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 2 de la rúbrica**: *Datos utilizados: suficiencia y corrección*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica. Esta serie cubre los **6 criterios** de la rúbrica en documentos separados, más el documento maestro que los integra.

En resumen: Este criterio evalúa si los datos del proyecto eran suficientes y correctos. Conclusión principal: los datos correctos existen y son suficientes (30.086 investigadores únicos, 3.166.629 productos), pero el archivo consolidado versionado en el repositorio está incompleto: solo contiene 3 de las 6 convocatorias, por lo que un clon del repositorio no reproduce todos los resultados del informe.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro_auditoria.pdf*). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario (solo los términos que usa este documento)

Esta tabla incluye únicamente los términos técnicos que aparecen en este documento, explicados en lenguaje sencillo:

Tabla 1. Glosario de términos presentes en este documento

Término	Qué significa
Matriz de transición	Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores.
Mojibake	Texto ilegible por un problema de codificación (p. ej. 'FÃsica' en lugar de 'Física'). Detectado en el CSV del repositorio.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.
Pipeline	Cadena de procesos que lleva los datos desde la fuente hasta el análisis (ingesta, limpieza, transformación, modelado). También llamada 'cadena de procesamiento' o 'flujo de datos'.

2 Datos utilizados: suficiencia y corrección

VERIFICADO EMPÍRICAMENTE: el consolidado versionado (XLSX y CSV en `datos/tarea_join/`) contiene solo 50.891 filas y 3 convocatorias (2017: 13.001, 2019: 16.796, 2021: 21.094), frente a las 77.237 filas y 6 convocatorias (2013-2021) declaradas en el README y el catálogo. Las evidencias versionadas (p. ej. matrices de transición 2013-2014) sí cubren las 6 convocatorias, lo que indica que el artefacto versionado es un snapshot de la fase inicial de 3 convocatorias nunca actualizado. Consecuencia verificada: ejecutar el pipeline en un clon fresco genera solo 2 periodos de transición (2017-2019, 2019-2021) en vez de 5, y los resultados no reproducen el README. El CSV paralelo además presenta mojibake (UTF-8/Latin-1). El dataset de producción (~1.2 GB) está gitignored y no es reproducible desde el clon. En cuanto a la corrección de las fuentes: el padrón es la fuente oficial del sistema de reconocimiento y el dataset de producción su complemento natural; la elección de datos abiertos (datos.gov.co/Socrata) es apropiada y verificable.

2.1 Fuentes del repositorio

- **Padrón de investigadores** (Socrata `bqtm-4y2h`): convocatorias 2013–2021, 30 variables, **77 237 registros declarados** y 30 086 investigadores únicos.
- **Producción de grupos** (Socrata `33dq-ab5a`): 3 166 629 filas producto-autor; dataset grande, no versionado en git.
- **Catálogo**: `datos/catalogo.yaml` con metadatos, diccionario de datos y llaves de cruce (`id_persona_pr` ↔ `id_persona_pd`).

Nota metodológica

Los datos no son solo los archivos: también se evaluó *cómo se versionaron* en el repositorio. El detalle de la verificación (conteos reales, codificación, hallazgos) está en este documento y en el maestro.

3 Relación con los demás criterios

Este documento se centra en el criterio 2. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Documentación y crítica por archivo de código; Validación de la calidad estadística; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

Veredicto: los datos correctos existen y son suficientes para el objetivo, pero su versionado en el repositorio está incompleto (3 de 6 convocatorias) — un clon fresco no reproduce los hallazgos. Acciones prioritarias: (1) reconstruir y versionar el consolidado de 6 convocatorias; (2) normalizar UTF-8 y añadir contratos de esquema (pandera); (3) versionar el dataset de producción o documentar su ingesta reproducible; (4) declarar en el README qué artefacto es canónico.

Fuentes de consulta (no citadas en el texto)

[Clauset et al.(2015)Clauset, Arbesman, and Larremore] Aaron Clauset, Samuel Arbesman, and Daniel B Larremore. Systematic inequality and hierarchy in faculty hiring networks. *Science Advances*, 1(1):e1400005, 2015.

[Clauset et al.(2017)Clauset, Larremore, and Sinatra] Aaron Clauset, Daniel B Larremore, and Roberta Sinatra. Data-driven predictions in the science of science. *Science*, 355(6324):477–480, 2017.

[Crenshaw(1989)] Kimberle Crenshaw. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine, feminist theory and antiracist politics. *University of Chicago Legal Forum*, 1989:139–167, 1989.

[Fortunato et al.(2018)Fortunato, Bergstrom, Börner, Evans, Helbing, Milojević, Petersen, Radicchi, Sinatra, Santo Fortunato, Carl T Bergstrom, Katy Börner, James A Evans, Dirk Helbing, Staša Milojević, Alexander M Petersen, Filippo Radicchi, Roberta Sinatra, Brian Uzzi, et al. Science of science. *Science*, 359(6379):eaao0185, 2018.

[Freeman(1977)] Linton C Freeman. A set of measures of centrality based on betweenness. *Sociometry*, 40(1):35–41, 1977.

[Greenacre(2017)] Michael Greenacre. *Correspondence Analysis in Practice*. Chapman and Hall/CRC, 3rd edition, 2017.

[Hicks et al.(2015)Hicks, Wouters, Waltman, de Rijcke, and Rafols] Diana Hicks, Paul Wouters, Ludo Waltman, Sarah de Rijcke, and Ismael Rafols. The leiden manifesto for research metrics. *Nature*, 520(7548):429–431, 2015.

[Hirsch(2005)] Jorge E Hirsch. An index to quantify an individual’s scientific research output. *Proceedings of the National Academy of Sciences*, 102(46):16569–16572, 2005.

[Huang(1998)] Zhexue Huang. Extensions to the k-means algorithm for clustering large data sets with categorical variables. *Data Mining and Knowledge Discovery*, 2(3):283–304, 1998.

- [Husson et al.(2017)]Husson, Lê, and Pagès] François Husson, Sébastien Lê, and Jérôme Pagès. *Exploratory Multivariate Analysis by Example Using R*. Chapman and Hall/CRC, 2nd edition, 2017.
- [International(2017)] DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. Technics Publications, 2nd edition, 2017.
- [Kemeny and Snell(1976)] John G Kemeny and J Laurie Snell. *Finite Markov Chains*. Springer-Verlag, 1976.
- [Kimball and Ross(2013)] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. John Wiley & Sons, 3rd edition, 2013.
- [Larivière et al.(2013)]Larivière, Ni, Gingras, Cronin, and Sugimoto] Vincent Larivière, Chaoqun Ni, Yves Gingras, Blaise Cronin, and Cassidy R Sugimoto. Bibliometrics: Global gender disparities in science. *Nature*, 504(7479):211–213, 2013.
- [Lotka(1926)] Alfred J Lotka. The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences*, 16(12):317–323, 1926.
- [Newman(2001)] Mark EJ Newman. The structure of scientific collaboration networks. *Proceedings of the National Academy of Sciences*, 98(2):404–409, 2001.
- [Wang and Strong(1996)] Richard Y Wang and Diane M Strong. Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4):5–33, 1996.
- [Wasserman and Faust(1994)] Stanley Wasserman and Katherine Faust. *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.
- [Wilkinson et al.(2016)]Wilkinson, Dumontier, Aalbersberg, Appleton, Axton, Baak, Blomberg, Boiten, da Si Mark D Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.
- [Wirth and Hipp(2000)] Rüdiger Wirth and Jochen Hipp. Crisp-dm: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, 2000.
- [Zeng et al.(2021)]Zeng, Shen, Zhou, Fan, Di, Wang, Stanley, and Havlin] An Zeng, Zhesi Shen, Jianlin Zhou, Jinshan Fan, Zengru Di, Yougui Wang, H Eugene Stanley, and Shlomo Havlin. The science of science: From the perspective of complex systems. *Physics Reports*, 935:1–60, 2021.