
Criterio 2: Datos utilizados: suficiencia y corrección

Documentación técnica de auditoría · Versión LITE (versión resumida) · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Commit auditado: 1528939

Versión LITE (versión resumida) · 2 de septiembre de 2026

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario (solo los términos que usa este documento)	2
2. Datos utilizados: suficiencia y corrección	3
2.1. Hallazgos de mayor impacto	3
3. Relación con los demás criterios	3
4. Conclusiones y recomendaciones del criterio	3

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 2 de la rúbrica**: *Datos utilizados: suficiencia y corrección*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica. Esta serie cubre los **6 criterios** de la rúbrica en documentos separados, más el documento maestro que los integra.

En resumen: Este criterio evalúa si los datos del proyecto eran suficientes y correctos. Conclusión principal: los datos correctos existen y son suficientes (30.086 investigadores únicos, 3.166.629 productos), pero el archivo consolidado versionado en el repositorio está incompleto: solo contiene 3 de las 6 convocatorias, por lo que un clon del repositorio no reproduce todos los resultados del informe.

Nota metodológica

Versión LITE: este documento resume el criterio (veredicto y hallazgos de mayor impacto). El desarrollo completo está en la versión completa del criterio y en el documento maestro.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** ([maestro_auditoria.pdf](#)). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario (solo los términos que usa este documento)

Esta tabla incluye únicamente los términos técnicos que aparecen en este documento, explicados en lenguaje sencillo:

Tabla 1. Glosario de términos presentes en este documento

Término	Qué significa
Mojibake	Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.

2 Datos utilizados: suficiencia y corrección

Hallazgo

Veredicto: Datos correctos y suficientes en origen (30.086 investigadores, 6 convocatorias, 3.166.629 productos), pero el consolidado versionado solo tiene 3 de 6 convocatorias (50.891 de 77.237 filas).

2.1 Hallazgos de mayor impacto

- Un clon del repositorio no reproduce los resultados del informe (verificado: 2 periodos de transición en vez de 5).
- Mojibake en el CSV y dataset de producción (~1.2 GB) sin versionar.

3 Relación con los demás criterios

Este documento se centra en el criterio 2. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Documentación y crítica por archivo de código; Validación de la calidad estadística; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (**maestro_auditoria.pdf**), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

Veredicto: los datos correctos existen y son suficientes para el objetivo, pero su versionado en el repositorio está incompleto (3 de 6 convocatorias) — un clon fresco no reproduce los hallazgos. Acciones prioritarias: (1) reconstruir y versionar el consolidado de 6 convocatorias; (2) normalizar UTF-8 y añadir contratos de esquema (pandera); (3) versionar el dataset de producción o documentar su ingesta reproducible; (4) declarar en el README qué artefacto es canónico.

Referencias