
Criterio 4: Validación de la calidad de pruebas, tratamientos y lógica estadística

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Commit auditado: 1528939

Versión 1.0 · 30 de septiembre de 2026

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario (solo los términos que usa este documento)	2
2. Validación de la calidad de pruebas, tratamientos y lógica estadística	3
3. Relación con los demás criterios	3
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 4 de la rúbrica**: *Validación de la calidad de pruebas, tratamientos y lógica estadística*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica. Esta serie cubre los **6 criterios** de la rúbrica en documentos separados, más el documento maestro que los integra.

En resumen: Este criterio evalúa el rigor estadístico: cómo se limpiaron los datos (atípicos, faltantes) y si los métodos usados (matrices de transición, índices de concentración, comparaciones de género y diversidad, redes, agrupamientos) son correctos. Conclusión: la estadística descriptiva es sólida y transparente; la principal debilidad es la falta de inferencia formal (intervalos de confianza, pruebas de supuestos, modelos ajustados).

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro_auditoria.pdf*). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario (solo los términos que usa este documento)

Esta tabla incluye únicamente los términos técnicos que aparecen en este documento, explicados en lenguaje sencillo:

Tabla 1. Glosario de términos presentes en este documento

Término	Qué significa
HHI (Herfindahl-Hirschman)	Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.
Representación relativa	Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.
k-prototypes	Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).
Pipeline	Cadena de procesos que lleva los datos desde la fuente hasta el análisis (ingesta, limpieza, transformación, modelado). También llamada 'cadena de procesamiento' o 'flujo de datos'.

Término	Qué significa
Markovianidad	Propiedad de un proceso en el que la probabilidad de pasar al siguiente estado solo depende del estado actual (y no de toda la historia). Se usa para validar si las matrices de transición de categorías son adecuadas.
Modelos de supervivencia (Kaplan-Meier / Cox)	Técnicas estadísticas para analizar 'tiempo hasta que ocurre un evento' (p. ej. cuánto tarda un investigador en salir del sistema), incluyendo datos incompletos.
Intervalo de confianza (IC) y bootstrap	El intervalo de confianza indica el rango plausible de una estimación (p. ej. 0.15-0.19). El bootstrap es un método que lo calcula remuestreando los datos muchas veces, sin fórmulas complejas.

2 Validación de la calidad de pruebas, tratamientos y lógica estadística

Tratamientos: eliminación de 22 atípicos de edad (>100 años) con justificación documentada (0.028 % del padrón, sesgo despreciable) y comparación con imputación por mediana del grupo; imputación por mediana en numéricas (reduce varianza; aplicada a ordinales — cuestionable); etiqueta NO REPORTADO en categóricas; verificación de unicidad de IDs por coherencia de edad (+/-4 años) y género (heurística razonable sin formalizar). Veredicto por eje: (a) longitudinal: matrices de Markov empíricas correctas, pero sin test de markovianidad ni homogeneidad temporal, y sin supervivencia (Kaplan-Meier/Cox) para el tiempo hasta la salida; (b) territorial: HHI correcto pero sin IC bootstrap ni Gini/Theil; (c) género/diversidad: proporciones y representación relativa vs DANE correctas en concepto, pero sin modelos ajustados y con el bug del denominador 'NINGUN GRUPO ETNICO' (comentario vs código, diluye la subrepresentación); (d) redes: métricas sin modelos nulos, red = corte transversal (captura solo 2019); (e) clustering legacy: k-prototypes con k=3 fijo sin validación (silhouette/Calinski-Harabasz) y pérdida del 8.4 % de la muestra; (f) pruebas: chi-cuadrado mencionado sin verificar frecuencias esperadas. La estadística descriptiva es sólida; la inferencia formal es la principal debilidad.

Nota metodológica

Principio de la auditoría: la crítica es constructiva. Cuando un análisis o un archivo está bien construido se dice explícitamente; las debilidades se presentan como oportunidades de mejora, no como reproches. El detalle metodológico por eje (Markov, HHI, brechas, redes, clustering) está en el documento maestro, sección 6.

3 Relación con los demás criterios

Este documento se centra en el criterio 4. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Datos utilizados: suficiencia y corrección; Documentación y crítica

por archivo de código; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

La calidad de tratamientos y la lógica descriptiva son adecuadas y transparentes; la inferencia formal requiere ampliación. Acciones prioritarias: (1) test de markovianidad + modelos de supervivencia; (2) IC bootstrap en HHI y Gini/Theil; (3) modelos logísticos ajustados para brechas; (4) modelos nulos de red; (5) validación formal de clusters y migración del legacy R al pipeline Python; (6) corregir el denominador de `comparar_dane()` y unificar el conteo de atípicos (10 vs 22).

Fuentes de consulta (no citadas en el texto)

[Clauset et al.(2015)]Clauset, Arbesman, and Larremore] Aaron Clauset, Samuel Arbesman, and Daniel B Larremore. Systematic inequality and hierarchy in faculty hiring networks. *Science Advances*, 1(1):e1400005, 2015.

[Clauset et al.(2017)]Clauset, Larremore, and Sinatra] Aaron Clauset, Daniel B Larremore, and Roberta Sinatra. Data-driven predictions in the science of science. *Science*, 355(6324):477–480, 2017.

[Crenshaw(1989)] Kimberle Crenshaw. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine, feminist theory and antiracist politics. *University of Chicago Legal Forum*, 1989:139–167, 1989.

[Fortunato et al.(2018)]Fortunato, Bergstrom, Börner, Evans, Helbing, Milojević, Petersen, Radicchi, Sinatra, Santo Fortunato, Carl T Bergstrom, Katy Börner, James A Evans, Dirk Helbing, Staša Milojević, Alexander M Petersen, Filippo Radicchi, Roberta Sinatra, Brian Uzzi, et al. Science of science. *Science*, 359(6379):eaao0185, 2018.

[Freeman(1977)] Linton C Freeman. A set of measures of centrality based on betweenness. *Sociometry*, 40(1):35–41, 1977.

[Greenacre(2017)] Michael Greenacre. *Correspondence Analysis in Practice*. Chapman and Hall/CRC, 3rd edition, 2017.

[Hicks et al.(2015)]Hicks, Wouters, Waltman, de Rijcke, and Rafols] Diana Hicks, Paul Wouters, Ludo Waltman, Sarah de Rijcke, and Ismael Rafols. The leiden manifesto for research metrics. *Nature*, 520(7548):429–431, 2015.

[Hirsch(2005)] Jorge E Hirsch. An index to quantify an individual’s scientific research output. *Proceedings of the National Academy of Sciences*, 102(46):16569–16572, 2005.

- [Huang(1998)] Zhexue Huang. Extensions to the k-means algorithm for clustering large data sets with categorical variables. *Data Mining and Knowledge Discovery*, 2(3):283–304, 1998.
- [Husson et al.(2017)Husson, Lê, and Pagès] François Husson, Sébastien Lê, and Jérôme Pagès. *Exploratory Multivariate Analysis by Example Using R*. Chapman and Hall/CRC, 2nd edition, 2017.
- [International(2017)] DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. Technics Publications, 2nd edition, 2017.
- [Kemeny and Snell(1976)] John G Kemeny and J Laurie Snell. *Finite Markov Chains*. Springer-Verlag, 1976.
- [Kimball and Ross(2013)] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. John Wiley & Sons, 3rd edition, 2013.
- [Larivière et al.(2013)Larivière, Ni, Gingras, Cronin, and Sugimoto] Vincent Larivière, Chaoqun Ni, Yves Gingras, Blaise Cronin, and Cassidy R Sugimoto. Bibliometrics: Global gender disparities in science. *Nature*, 504(7479):211–213, 2013.
- [Lotka(1926)] Alfred J Lotka. The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences*, 16(12):317–323, 1926.
- [Newman(2001)] Mark EJ Newman. The structure of scientific collaboration networks. *Proceedings of the National Academy of Sciences*, 98(2):404–409, 2001.
- [Wang and Strong(1996)] Richard Y Wang and Diane M Strong. Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4):5–33, 1996.
- [Wasserman and Faust(1994)] Stanley Wasserman and Katherine Faust. *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.
- [Wilkinson et al.(2016)Wilkinson, Dumontier, Aalbersberg, Appleton, Axton, Baak, Blomberg, Boiten, da Si Mark D Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.
- [Wirth and Hipp(2000)] Rüdiger Wirth and Jochen Hipp. Crisp-dm: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, 2000.
- [Zeng et al.(2021)Zeng, Shen, Zhou, Fan, Di, Wang, Stanley, and Havlin] An Zeng, Zhesi Shen, Jianlin Zhou, Jinshan Fan, Zengru Di, Yougui Wang, H Eugene Stanley, and Shlomo Havlin. The science of science: From the perspective of complex systems. *Physics Reports*, 935:1–60, 2021.