
Criterio 4: Validación de la calidad de pruebas, tratamientos y lógica estadística

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Versión 1.0 · 29 de agosto de 2026

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario para lectores sin formación en programación	2
2. Validación de la calidad de pruebas, tratamientos y lógica estadística	3
3. Relación con los demás criterios	4
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 4 de la rúbrica**: *Validación de la calidad de pruebas, tratamientos y lógica estadística*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica.

En resumen: Este criterio evalúa el rigor estadístico: cómo se limpiaron los datos (atípicos, faltantes) y si los métodos usados (matrices de transición, índices de concentración, comparaciones de género y diversidad, redes, agrupamientos) son correctos. Conclusión: la estadística descriptiva es sólida y transparente; la principal debilidad es la falta de inferencia formal (intervalos de confianza, pruebas de supuestos, modelos ajustados).

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro_auditoria.pdf*, 114 págs.). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario para lectores sin formación en programación

Los documentos usan términos técnicos con moderación; cuando aparecen, esta tabla los explica en lenguaje sencillo:

Tabla 1. Glosario de términos en lenguaje llano

Término	Qué significa
HHI (Herfindahl-Hirschman)	Índice que mide si algo está concentrado o repartido. Va de 0 (todo repartido) a 1 (todo en un solo lugar). En el informe se usa para ver si los investigadores se concentran en pocos departamentos.
Matriz de transición	Tabla que muestra con qué probabilidad un investigador pasa de una categoría (p. ej. Junior) a otra (p. ej. Asociado) entre dos convocatorias. Permite ver si el sistema 'sube', 'mantiene' o 'pierde' investigadores.
Tasa de retención	Porcentaje de investigadores que siguen presentes en la siguiente convocatoria. Una retención baja puede indicar abandono o cambio de reglas.
Representación relativa	Cuántas veces aparece un grupo (p. ej. afrocolombianos) en el padrón frente a lo que correspondería según su peso en la población colombiana (DANE). Un valor de 0.3 indica que aparece 3 veces menos de lo esperado.

Término	Qué significa
k-prototypes	Algoritmo de agrupamiento (clustering) que agrupa personas con perfiles similares cuando los datos mezclan números (edad) y categorías (área, género).
MCA / FAMD	Técnicas para resumir tablas con muchas categorías en pocos ejes visualizables, de modo que se puedan ver patrones (p. ej. qué áreas se asocian con qué géneros).
CRISP-DM	Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.
Modelo dimensional (esquema estrella)	Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes.
DuckDB	Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.
Mojibake	Texto ilegible por un problema de codificación (p. ej. 'Física' en lugar de 'Física'). Detectado en el CSV del repositorio.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.
ETL / pipeline	Cadena de procesos que extrae los datos de la fuente (ETL: Extraer, Transformar, Cargar), los limpia y los deja listos para analizar.
CI/CD y Docker	Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.
Sprint	Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.

2 Validación de la calidad de pruebas, tratamientos y lógica estadística

Tratamientos: eliminación de 22 atípicos de edad (>100 años) con justificación documentada (0.028 % del padrón, sesgo despreciable) y comparación con imputación por mediana del grupo; imputación por mediana en numéricas (reduce varianza; aplicada a ordinales — cuestionable); etiqueta NO REPORTADO en categóricas; verificación de unicidad de IDs por coherencia de edad (+-4 años) y género (heurística razonable sin formalizar). Veredicto por eje: (a) longitudinal: matrices de Markov empíricas correctas, pero sin test de markovianidad ni homogeneidad temporal, y sin supervivencia (Kaplan-Meier/Cox) para el tiempo hasta la salida; (b) territorial: HHI correcto pero sin IC bootstrap ni Gini/Theil; (c) género/diversidad: proporciones y representación relativa vs DANE correctas en concepto, pero sin modelos ajustados y con el bug del denominador 'NINGUN GRUPO ETNICO' (comentario vs código, diluye la subrepresentación); (d) redes: métricas sin modelos nulos, red = corte transversal (captura solo 2019); (e) clustering legacy: k-prototypes con k=3 fijo sin validación

(silhouette/Calinski-Harabasz) y pérdida del 8.4 % de la muestra; (f) pruebas: chi-cuadrado mencionado sin verificar frecuencias esperadas. La estadística descriptiva es sólida; la inferencia formal es la principal debilidad.

Nota metodológica

Principio de la auditoría: la crítica es constructiva. Cuando un análisis o un archivo está bien construido se dice explícitamente; las debilidades se presentan como oportunidades de mejora, no como reproches. El detalle metodológico por eje (Markov, HHI, brechas, redes, clustering) está en el documento maestro, sección 6.

3 Relación con los demás criterios

Este documento se centra en el criterio 4. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Datos utilizados: suficiencia y corrección; Documentación y crítica por archivo de código; Lógica de creación del repositorio y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

La calidad de tratamientos y la lógica descriptiva son adecuadas y transparentes; la inferencia formal requiere ampliación. Acciones prioritarias: (1) test de markovianidad + modelos de supervivencia; (2) IC bootstrap en HHI y Gini/Theil; (3) modelos logísticos ajustados para brechas; (4) modelos nulos de red; (5) validación formal de clusters y migración del legacy R al pipeline Python; (6) corregir el denominador de `comparar_dane()` y unificar el conteo de atípicos (10 vs 22).

Referencias
