
Criterio 5: Lógica de creación del repositorio y cumplimiento del objetivo principal

Documentación técnica de auditoría · Documento 1.0 · Un documento por criterio de la rúbrica

Consultor Estadístico Senior · Auditoría de Proyectos de Datos

Universidad Santo Tomás · Ustadistica · 2026-I

Repositorio auditado: `Observatorio_Ministerio_de_Ciencias_Grupo8`

Commit auditado: 1528939

Versión 1.0 · 30 de septiembre de 2026

Documento generado de forma reproducible a partir de la auditoría del repositorio. La construcción de este documento está documentada en `documentacion_auditoria`.

Índice

1. Contexto y guía de lectura	2
1.1. Qué es este documento	2
1.2. Glosario (solo los términos que usa este documento)	2
2. Lógica de creación del repositorio y cumplimiento del objetivo principal	3
3. Relación con los demás criterios	4
4. Conclusiones y recomendaciones del criterio	4

1 Contexto y guía de lectura

1.1 Qué es este documento

Este documento desarrolla el **criterio 5 de la rúbrica**: *Lógica de creación del repositorio y cumplimiento del objetivo principal*. El repositorio auditado es el Observatorio de investigadores reconocidos del Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias), que consolida y analiza **6 convocatorias (2013–2021)** del padrón oficial de investigadores y su producción científica. Esta serie cubre los **6 criterios** de la rúbrica en documentos separados, más el documento maestro que los integra.

En resumen: Este criterio evalúa cómo se construyó el repositorio y si la ejecución fue correcta. Conclusión: la arquitectura y la lógica general son correctas y los entregables cumplen el objetivo; la ejecución fue buena en lo analítico pero no óptima en la industrialización (automatización, despliegue y pruebas), con varios flujos concretos que conviene corregir.

Nota metodológica

Cómo leer este documento: cada PDF de esta serie desarrolla *un* criterio de la rúbrica. Los demás criterios se tratan a fondo en sus propios documentos y en el **documento maestro** (*maestro_auditoria.pdf*). Si este es tu primer acercamiento, lee primero la portada y este contexto; al final encontrarás las conclusiones del criterio.

1.2 Glosario (solo los términos que usa este documento)

Esta tabla incluye únicamente los términos técnicos que aparecen en este documento, explicados en lenguaje sencillo:

Tabla 1. Glosario de términos presentes en este documento

Término	Qué significa
CRISP-DM	Metodología estándar de proyectos de datos: entender el problema, preparar los datos, modelar, evaluar y desplegar. El proyecto la usa como guía general.
Modelo dimensional (esquema estrella)	Forma de organizar los datos en tablas de 'hechos' (métricas: quién, cuándo, qué categoría) y 'dimensiones' (descripciones: área, región, institución), para hacer consultas rápidas y reportes.
DuckDB	Base de datos analítica ligera que se ejecuta dentro del propio proyecto (sin instalar un servidor). Se usa para almacenar el modelo dimensional.
Contrato de esquema	Validación automática que garantiza que un archivo de datos tenga las columnas, tipos y valores esperados antes de analizarlo.
ETL	Sigla de Extraer, Transformar y Cargar: procesos que extraen los datos de la fuente, los limpian y los dejan listos para analizar.

Término	Qué significa
Pipeline	Cadena de procesos que lleva los datos desde la fuente hasta el análisis (ingesta, limpieza, transformación, modelado). También llamada 'cadena de procesamiento' o 'flujo de datos'.
DVC (versionado de datos)	Herramienta para versionar archivos de datos grandes junto con el código (como Git, pero para datos), lo que permite reproducir análisis desde versiones exactas.
CI/CD y Docker	Automatización de pruebas y despliegue (CI/CD) y empaquetado de la aplicación en un contenedor (Docker) para que funcione igual en cualquier máquina.
Sprint	Ciclo corto de trabajo (en este proyecto, de 2 semanas) con objetivos concretos.

2 Lógica de creación del repositorio y cumplimiento del objetivo principal

La construcción siguió dos etapas: (1) fase académica inicial (ago-oct 2025): notebooks tarea_* con análisis por convocatoria, join, dimensiones y gran tabla, sin pipeline unificado; (2) fase de ingeniería (oct 2025 - may 2026): CRISP-DM, src/ (ingesta, transformación, análisis, modelo dimensional DuckDB), scripts/sprint*_*.py, dashboard Streamlit, CI/CD y documentación (LaTeX, Reveal.js, manual). El alcance creció de 3 a 6 convocatorias e integró producción (Sprint 5) y ajustes del director (Sprint 6). La arquitectura final es correcta (ingesta ->transformación ->modelo dimensional ->análisis por sprint ->visualización) y la separación de responsabilidades en src/ es limpia. Flujos INCORRECTOS o NO ÓPTIMOS detectados: (1) CI/CD rota (el flujo ETL de GitHub Actions, .github/workflows/etl_update.yml, referencia módulos inexistentes src.ingesta.main / src.transformacion.main); (2) Dockerfile ejecuta app/streamlit_app.py (placeholder) en lugar del dashboard real y no copia hallazgos/; (3) duplicación de apps (raíz vs app/); (4) legacy R (clustering/multivariado) fuera del pipeline con rutas hardcodeadas Downloads/; (5) scikit-learn y pandera declarados sin uso; (6) datos crudos sin versionar (sin DVC); (7) consolidado versionado incompleto (3 de 6 convocatorias); (8) artefactos duplicados (matriz_* vs *_ext vs *_obs); (9) nomenclatura desactualizada (Grupo7/Grupo8). La ejecución real verificada: 10 de 16 scripts corren OK en clon fresco.

Hallazgo

El repositorio se construyó en dos etapas: tareas académicas iniciales (notebooks, ago-oct 2025) y pipeline de ingeniería de datos (src/ + scripts/sprint*, oct 2025 - may 2026). La valoración detallada de flujos correctos e incorrectos está en el documento maestro (sección 7) y en el PDF del criterio 5.

3 Relación con los demás criterios

Este documento se centra en el criterio 5. Los demás criterios de la rúbrica — Entendimiento del objetivo del repositorio; Datos utilizados: suficiencia y corrección; Documentación y crítica por archivo de código; Validación de la calidad estadística y Línea de tiempo de commits — se desarrollan a fondo en sus propios documentos y en el **documento maestro** de la auditoría (`maestro_auditoria.pdf`), que los integra todos con el detalle completo de datos, código, estadística, lógica y línea de tiempo. Esta separación evita repetir contenido: cada PDF profundiza en lo suyo.

4 Conclusiones y recomendaciones del criterio

La lógica de creación es correcta en lo esencial y los entregables cumplen el objetivo declarado; la ejecución fue correcta en lo analítico pero no óptima en la industrialización (reproducibilidad, automatización, pruebas). Acciones: corregir CI/CD y Dockerfile, unificar apps, migrar el legacy, versionar datos y ampliar tests.

Fuentes de consulta (no citadas en el texto)

[Clauset et al.(2015)Clauset, Arbesman, and Larremore] Aaron Clauset, Samuel Arbesman, and Daniel B Larremore. Systematic inequality and hierarchy in faculty hiring networks. *Science Advances*, 1(1):e1400005, 2015.

[Clauset et al.(2017)Clauset, Larremore, and Sinatra] Aaron Clauset, Daniel B Larremore, and Roberta Sinatra. Data-driven predictions in the science of science. *Science*, 355(6324): 477–480, 2017.

[Crenshaw(1989)] Kimberle Crenshaw. Demarginalizing the intersection of race and sex: A black feminist critique of antidiscrimination doctrine, feminist theory and antiracist politics. *University of Chicago Legal Forum*, 1989:139–167, 1989.

[Fortunato et al.(2018)Fortunato, Bergstrom, Börner, Evans, Helbing, Milojević, Petersen, Radicchi, Sinatra, Santo Fortunato, Carl T Bergstrom, Katy Börner, James A Evans, Dirk Helbing, Staša Milojević, Alexander M Petersen, Filippo Radicchi, Roberta Sinatra, Brian Uzzi, et al. Science of science. *Science*, 359(6379):eaao0185, 2018.

[Freeman(1977)] Linton C Freeman. A set of measures of centrality based on betweenness. *Sociometry*, 40(1):35–41, 1977.

[Greenacre(2017)] Michael Greenacre. *Correspondence Analysis in Practice*. Chapman and Hall/CRC, 3rd edition, 2017.

[Hicks et al.(2015)Hicks, Wouters, Waltman, de Rijcke, and Rafols] Diana Hicks, Paul Wouters, Ludo Waltman, Sarah de Rijcke, and Ismael Rafols. The leiden manifesto for research metrics. *Nature*, 520(7548):429–431, 2015.

- [Hirsch(2005)] Jorge E Hirsch. An index to quantify an individual's scientific research output. *Proceedings of the National Academy of Sciences*, 102(46):16569–16572, 2005.
- [Huang(1998)] Zhexue Huang. Extensions to the k-means algorithm for clustering large data sets with categorical variables. *Data Mining and Knowledge Discovery*, 2(3):283–304, 1998.
- [Husson et al.(2017)Husson, Lê, and Pagès] François Husson, Sébastien Lê, and Jérôme Pagès. *Exploratory Multivariate Analysis by Example Using R*. Chapman and Hall/CRC, 2nd edition, 2017.
- [International(2017)] DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. Technics Publications, 2nd edition, 2017.
- [Kemeny and Snell(1976)] John G Kemeny and J Laurie Snell. *Finite Markov Chains*. Springer-Verlag, 1976.
- [Kimball and Ross(2013)] Ralph Kimball and Margy Ross. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. John Wiley & Sons, 3rd edition, 2013.
- [Larivière et al.(2013)Larivière, Ni, Gingras, Cronin, and Sugimoto] Vincent Larivière, Chaouqun Ni, Yves Gingras, Blaise Cronin, and Cassidy R Sugimoto. Bibliometrics: Global gender disparities in science. *Nature*, 504(7479):211–213, 2013.
- [Lotka(1926)] Alfred J Lotka. The frequency distribution of scientific productivity. *Journal of the Washington Academy of Sciences*, 16(12):317–323, 1926.
- [Newman(2001)] Mark EJ Newman. The structure of scientific collaboration networks. *Proceedings of the National Academy of Sciences*, 98(2):404–409, 2001.
- [Wang and Strong(1996)] Richard Y Wang and Diane M Strong. Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4):5–33, 1996.
- [Wasserman and Faust(1994)] Stanley Wasserman and Katherine Faust. *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.
- [Wilkinson et al.(2016)Wilkinson, Dumontier, Aalbersberg, Appleton, Axton, Baak, Blomberg, Boiten, da Si Mark D Wilkinson, Michel Dumontier, IJsbrand Jan Aalbersberg, Gabrielle Appleton, Myles Axton, Arie Baak, Niklas Blomberg, Jan-Willem Boiten, Luiz Bonino da Silva Santos, Philip E Bourne, et al. The fair guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018, 2016.
- [Wirth and Hipp(2000)] Rüdiger Wirth and Jochen Hipp. Crisp-dm: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, 2000.
- [Zeng et al.(2021)Zeng, Shen, Zhou, Fan, Di, Wang, Stanley, and Havlin] An Zeng, Zhesi Shen, Jianlin Zhou, Jinshan Fan, Zengru Di, Yougui Wang, H Eugene Stanley, and

FUENTES DE CONSULTA (FUENTES DE CONSULTA NO CITADAS EN EL TEXTO)

Shlomo Havlin. The science of science: From the perspective of complex systems. *Physics Reports*, 935:1–60, 2021.