
Auditoría estadística reproducible del sistema de reconocimiento de investigadores de MinCiencias (2013–2021) con datos abiertos y propuesta de mejora para su observatorio

Consultoría Estadística · Universidad Santo Tomás · 2026-II

Entrega 1 — Anteproyecto · Modalidad: proyecto con datos abiertos

Integrantes

Kevin Leonardo Chaparro Reyes

Valentina Muñoz Palma

Paula Margarita Triana Ancinez

Experto temático: Javier Mauricio Sierra

Fecha: 17 de septiembre de 2026

Declaración: este documento fue elaborado con apoyo de herramientas de IA generativa; el uso está declarado en la sección 6 conforme a la rúbrica.

Índice

1. Planteamiento del problema y contexto	2
1.1. El problema y a quién afecta	2
1.2. Estado actual del problema: evidencia propia	2
1.3. La pregunta que este proyecto responde	3
2. Estado del arte y antecedentes	3
2.1. Enfoques 1–2: Ciencia de la Ciencia, evaluación responsable y sistemas nacionales	3
2.2. Enfoques 3–4: calidad de datos y dinámica longitudinal	3
2.3. Enfoques 5–6: desigualdad, género, diversidad y redes	4
2.4. Contraste de aproximaciones y vacío	4
3. Objetivos	4
3.1. Objetivo general	4
3.2. Objetivos específicos	4
4. Datos disponibles y aproximación metodológica preliminar	5
4.1. Fuentes de datos (modalidad datos abiertos)	5
4.2. Variables ligadas a cada objetivo	6
4.3. Ruta metodológica preliminar	6
4.4. ¿Por qué no está ya resuelto con estos datos?	6
5. Alcance, riesgos y cronograma	7
5.1. Qué hará y qué no hará el proyecto	7
5.2. Riesgos principales y plan de contingencia	7
5.3. Cronograma por hitos (12 semanas)	7
6. Declaración de uso de herramientas de IA y reparto del trabajo	8
6.1. Reparto del trabajo	8
6.2. Uso declarado de herramientas de IA	8
6.3. Riesgos éticos del proyecto y marco legal	9
6.4. Gestión de la información del agente de IA	9
Referencias	11

1. Planteamiento del problema y contexto

1.1. El problema y a quién afecta

Desde 2013, el Ministerio de Ciencia, Tecnología e Innovación de Colombia (MinCiencias) reconoce periódicamente a los investigadores activos del país a través de **convocatorias nacionales** (640/2013, 693/2014, 737/2015, 781/2017, 833/2018 y 894/2021). El resultado es un padrón oficial que clasifica a los investigadores en categorías —Junior, Asociado, Senior y Emérito— y que alimenta decisiones de política de ciencia, financiación, ascenso y visibilidad. Este padrón es, en la práctica, la **principal fuente administrativa de capital humano científico** del país y la base de su observatorio de ciencia y tecnología.

El problema que aborda este anteproyecto es doble. **En primer lugar**, no existe una evaluación estadística sistemática y reproducible de la **calidad y comparabilidad** de ese registro oficial: ¿la información publicada por MinCiencias es fiable entre convocatorias? ¿el padrón permite seguir a los investigadores a lo largo del tiempo? ¿qué distorsiones introduce el propio sistema de captura? **En segundo lugar**, el padrón exhibe patrones de **inequidad estructural** (concentración territorial, brechas de género y subrepresentación de minorías) cuya magnitud exacta y evolución no están cuantificadas con rigor estadístico en una sola fuente. A quién le importa: a MinCiencias y al Sistema Nacional de Ciencia, Tecnología e Innovación (SNCTI) —porque sus convocatorias son el instrumento—, a los investigadores reconocidos —porque su categoría condiciona su carrera— y a los tomadores de decisión de política de CTI en el país —porque necesitan saber si el instrumento mide lo que dice medir.

Este problema **no es un síntoma ni una preferencia metodológica**: es una pregunta sobre la validez de un instrumento público de medición. La literatura regional lo considera un tema vigente: la categorización de grupos e investigadores ante el SNCTI ha sido objeto de análisis críticos recientes (“Categorización de grupos e investigadores”, 2023), y Colombia es, junto con Brasil, uno de los pocos países latinoamericanos con un sistema de información curricular consolidado (Revista CTS, 2010), lo que hace especialmente relevante auditar la calidad de ese registro.

1.2. Estado actual del problema: evidencia propia

Como parte de este trabajo ya se construyó y verificó evidencia empírica propia sobre el registro, que constituye la línea base del anteproyecto:

- El dataset público `bqtm-4y2h` declara **77 237 registros y 6 convocatorias (2013–2021)** con 30 086 investigadores únicos; sin embargo, la verificación directa del archivo consolidado disponible muestra **solo 50 891 filas y 3 convocatorias** (781/2017, 833/2018 y 894/2021), con **26 662 investigadores únicos**: el artefacto versionado no corresponde al alcance declarado, lo que impide reproducir los análisis completos desde un clon del repositorio.
- Se detectaron **22 registros con edad mayor a 100 años** (máximo 956) y errores de codificación (mojibake) en el archivo canónico.
- La concentración territorial es extrema: **Bogotá y Antioquia concentran el 51 %** de los investigadores reconocidos; la retención de Bogotá alcanza el 92 % y absorbe más de 1 000 investigadores de otros departamentos.
- La brecha de género por área es estructural: **24 % de mujeres en Ingeniería frente a 48 % en ciencias médicas y de la salud**.
- Frente a la población (censo DANE 2018), la población afrocolombiana está **3 veces**

subrepresentada, la indígena **7,9 veces** y las personas con discapacidad **8 veces**.

- Solo **el 36,9 %** de los autores únicos que firman la producción declarada de grupos son investigadores reconocidos: el sistema de medición captura coautoría externa al padrón.

Estas cifras son **propias y verificables** (obtenidas y auditadas en este trabajo, con métodos reproducibles) y muestran que el problema existe, es cuantificable y tiene consecuencias: decisiones de política y de carrera apoyadas en un instrumento cuya fiabilidad, comparabilidad y equidad no están garantizadas.

1.3. La pregunta que este proyecto responde

El problema se traduce en una **pregunta estadística responsable**:

¿El padrón de investigadores reconocidos de MinCiencias (2013–2021) es fiable (calidad del registro), comparable entre convocatorias (trazabilidad longitudinal) y equitativo (distribución territorial, de género y de diversidad), y qué mejoras metodológicas y de gobernanza de datos permitirían convertirlo en la base sólida de un observatorio de capital humano científico en Colombia?

Responderla importa porque **si nadie hace nada**, el país seguirá tomando decisiones de política de ciencia sobre un registro cuya calidad no ha sido auditada de forma sistemática y reproducible, con el riesgo de perpetuar inequidades y de basar evaluaciones individuales en datos no comparables.

2. Estado del arte y antecedentes

Esta revisión sintetiza, **por enfoque** y no por autor, la literatura relevante, distinguiendo lo hecho en el mundo de lo hecho en Colombia. Se apoya en el estado del arte completo del equipo (20 págs., 39 referencias verificadas).

2.1. Enfoques 1–2: Ciencia de la Ciencia, evaluación responsable y sistemas nacionales

La *science of science* estudia el sistema científico con datos masivos y métodos cuantitativos (Fortunato et al., 2018; Wang & Barabási, 2021), y la agenda de **evaluación responsable**—DORA (2012), Principios de Leiden (Hicks et al., 2015), CoARA (2022)— fijó el estándar de uso de indicadores. En América Latina, Brasil (Lattes) y Colombia (ScienTI-CVLAC/Pubindex) son referentes de registros curriculares (Revista CTS, 2010), con herramientas como ScriptLattes (Mena-Chalco & Cesar Júnior, 2009) y el método del currículum vitae (Cañibano & Bozeman, 2009). Para Colombia existen análisis críticos del modelo de categorización ante el SNCTI (“Categorización de grupos e investigadores”, 2023) y estudios de métricas responsables y ciencia abierta (CONPES 4069, 2021). Nuestro proyecto se inscribe en esta intersección: auditar un instrumento público de medición bajo estándares de métricas responsables.

2.2. Enfoques 3–4: calidad de datos y dinámica longitudinal

La evaluación de registros administrativos usa las dimensiones de Wang & Strong (1996) y los principios FAIR (Wilkinson et al., 2016); la reproducibilidad exige versionado de datos y observabilidad de pipelines (Souza et al., 2023). El seguimiento de carreras se apoya en cadenas

de Markov (Kemeny & Snell, 1976), modelos de supervivencia y análisis de cohortes; los clásicos de física de carreras muestran que el impacto individual evoluciona con reglas cuantificables (Sinatra et al., 2016; Petersen et al., 2012) y que la movilidad geográfica estratifica la carrera (Deville et al., 2014; Sugimoto et al., 2017).

2.3. Enfoques 5–6: desigualdad, género, diversidad y redes

La medición de la desigualdad usa HHI, Gini y Theil (Theil, 1967) y la geografía de la ciencia (Frenken et al., 2009); la brecha de género global se documentó en Larivière et al. (2013), con análisis interseccional (Crenshaw, 1989); las redes de colaboración (Newman, 2001) y la jerarquía institucional extrema y persistente (Clauset et al., 2015) proveen los métodos de estructura de poder del sistema.

2.4. Contraste de aproximaciones y vacío

Dos aproximaciones compiten para la pregunta longitudinal con supuestos distintos: las **cadenas de Markov** suponen que la transición depende solo del estado actual (homogeneidad), mientras los **modelos de supervivencia** modelan el tiempo hasta el evento con covariables y censura. Nuestro diseño **las contrasta**: primero se testea la propiedad markoviana y luego se complementa con supervivencia. **Vacío que el proyecto atiende**: no se ha publicado una auditoría estadística reproducible del padrón de investigadores reconocidos de MinCiencias que combine, sobre los datos abiertos oficiales, calidad del registro + trazabilidad longitudinal + equidad con métodos de la ciencia de la ciencia; lo publicado en Colombia es descriptivo o normativo, no evidencia cuantitativa auditable.

3. Objetivos

3.1. Objetivo general

Cuantificar y auditar de forma reproducible la fiabilidad, comparabilidad y equidad del padrón de investigadores reconocidos de MinCiencias (convocatorias 2013–2021), a partir de los datos abiertos oficiales —con el cruce contra la producción de grupos ya ejecutado como línea base de contexto—, y entregar un marco de indicadores y un tablero de auditoría que orienten la mejora del observatorio de capital humano científico en Colombia.

El objetivo general responde exactamente al problema planteado: no es más ancho (se limita al padrón, 2013–2021) ni más angosto (abarca las tres dimensiones de la pregunta: fiabilidad, comparabilidad y equidad). El cruce con la producción de grupos (33dq-ab5a) se usó para cuantificar la cobertura del padrón (36,9 % de autores reconocidos, §1.2) y queda documentado como **contexto de línea base**: no es objeto de ningún objetivo específico, que se centran en el padrón, de modo que su eventual indisponibilidad no compromete el cumplimiento (plan B en §4.3).

3.2. Objetivos específicos

Los tres objetivos específicos son secuenciales: cada uno habilita al siguiente, y cumplidos todos agotan el objetivo general sin solaparse.

1. **Cuantificar la calidad del registro** del padrón de investigadores reconocidos de MinCiencias (2013–2021) según las dimensiones de completitud, unicidad, validez y consistencia,

usando el dataset abierto oficial **bqtm-4y2h** y su artefacto consolidado. *Evidencia de cumplimiento*: tabla de indicadores de calidad por convocatoria con conteos verificables (filas reales vs. declaradas, duplicados de **id_persona**, atípicos de edad, errores de codificación) y código reproducible que la genera.

2. **Estimar la dinámica longitudinal** (retención, transición de categoría y tiempo hasta la salida) de los investigadores entre convocatorias consecutivas, contrastando cadenas de Markov y modelos de supervivencia. *Evidencia de cumplimiento*: matrices de transición con IC, curvas de Kaplan–Meier y un modelo de Cox con covariables (área, género, región), todos reproducibles sobre los datos abiertos.
3. **Cuantificar la equidad** del sistema en sus dimensiones territorial y de género, y de diversidad (etnia, discapacidad), con indicadores de concentración (HHI/Gini/Theil) y razones de representación frente al censo DANE 2018; la condición de víctima del conflicto, que el censo no captura, se mide como prevalencia interna del padrón en la ventana disponible (2021). *Evidencia de cumplimiento*: tabla de indicadores de equidad con intervalos de confianza y figura resumen por convocatoria.

Cada objetivo especifica *con qué evidencia se declarará cumplido*, y la secuencia es visible: sin el registro limpio (OE1) no hay panel longitudinal fiable (OE2), y sin ambos no hay lectura de equidad comparable (OE3). El marco de indicadores y el tablero de auditoría se derivan de los tres.

4. Datos disponibles y aproximación metodológica preliminar

4.1. Fuentes de datos (modalidad datos abiertos)

Las fuentes son **datos abiertos oficiales** publicados por el Ministerio de Ciencia, Tecnología e Innovación en el portal nacional **datos.gov.co** (plataforma Socrata). Ya fueron **abiertas y verificadas por el equipo** (conteo real de filas, columnas y valores), no supuestas:

Tabla 1: Descripción de las fuentes de datos

Atributo	Padrón de investigadores	Producción de grupos	Observaciones
Entidad	MinCiencias	MinCiencias	datos.gov.co
Identificador	bqtm-4y2h	33dq-ab5a	Enlace en referencias
Periodo	2013–2021	2013–2021	6 ventanas
Unidad de observación	Investigador × convocatoria	Producto × autor	—
Volumen declarado	77 237 filas; 30 086 únicos	3 166 629 filas	Verificado: el XLSX del clon tiene 50 891
Variables	30 (categoría, área OCDE, género, geografía, diversidad, filiación)	15 (producto, categoría, tipo, grupo, autor)	Diccionario en el catálogo
Acceso	API Socrata / descarga CSV	API Socrata (paginada)	Sin autenticación

Atributo	Padrón	Producción	Observaciones
Licencia	Datos abiertos del portal (uso libre con atribución)	Ídem	Verificar enlace oficial
Llave de cruce	id_persona_pr	id_persona_pd	↔ + id_convocatoria

4.2. Variables ligadas a cada objetivo

- **OE1 (calidad):** ID_CONVOCATORIA, ANO_CONVO, ID_PERSONA_PR (unicidad), EDAD_ANOS_PR (validez), codificación del archivo (consistencia).
- **OE2 (longitudinal):** ID_PERSONA_PR, ANO_CONVO, ID_CLAS_PR/NME_CLASIFICACION_PR (transiciones), más covariables área y región.
- **OE3 (equidad):** NME_DEPARTAMENTO_RES_PR, NME_GENERO_PR, TXT_GRUPO_ETNICO, TXT_POBLACION_DISCA, ID_VICTIMA_CONFLICTO.

4.3. Ruta metodológica preliminar

El diseño sigue un flujo en tres etapas alineado con los objetivos: **(1) auditoría de calidad** del registro (perfilado por las dimensiones de Wang & Strong, contratos de esquema y normalización reproducible); **(2) construcción del panel longitudinal** y estimación de transiciones (matrices de Markov con test de la propiedad markoviana, complementadas con supervivencia Kaplan–Meier/Cox); y **(3) medición de equidad** (HHI, Gini y Theil con intervalos de confianza bootstrap para lo territorial; razones de representación con IC frente al censo DANE 2018 para género, etnia y discapacidad). Todo se implementa en Python sobre un almacén DuckDB, con el código, los datos y los resultados versionados y reproducibles.

Alternativa considerada y descartada: se evaluó complementar con indicadores de producción individual (índice h y variantes) a partir del dataset de producción; se descartó en esta fase porque el cruce de 3,2 millones de filas requiere descargar 1,2 GB y su disponibilidad es intermitente, y porque el objetivo de esta entrega es la auditoría del padrón; el análisis de productividad queda como extensión (se declara en el alcance).

Plan si el dato no llega o cambia: ambas fuentes tienen descarga directa por API Socrata y respaldo versionado; si el dataset de producción no estuviera disponible a tiempo, los objetivos OE1–OE3 no dependen de él (se audita el padrón y su artefacto consolidado). Si cambiara el esquema del padrón, los contratos de esquema detectarían el cambio y se documentará la re-ingesta.

4.4. ¿Por qué no está ya resuelto con estos datos?

Aunque los datos son públicos desde 2021 y existen análisis descriptivos, no se ha publicado —hasta donde alcanza esta revisión— una **auditoría estadística reproducible** del padrón que combine las tres dimensiones (calidad + longitudinal + equidad) con los métodos de la ciencia de la ciencia y que documente explícitamente los defectos del registro (discrepancia 77 237 vs. 50 891, atípicos, mojibake). Nuestro aporte es ese: no repetir un análisis descriptivo, sino **auditar el instrumento** y entregar un marco de indicadores reutilizable.

5. Alcance, riesgos y cronograma

5.1. Qué hará y qué no hará el proyecto

Sí hará: auditar la calidad del padrón de investigadores reconocidos (2013–2021) y de su artefacto consolidado; construir el panel longitudinal y estimar transiciones y supervivencia; medir concentración territorial y equidad de género y diversidad frente al censo DANE 2018; entregar un marco de indicadores, un tablero de auditoría y documentación reproducible.

No hará (y por qué):

- **No** validará el padrón contra registros internos de MinCiencias (no accesibles): se audita la fuente pública, que es el objeto declarado.
- **No** construirá modelos predictivos de carreras individuales ni análisis causal (requieren diseños fuera del alcance semestral y de los datos).
- **No** profundizará en el análisis de producción individual (índice h): exige el dataset de 1,2 GB y se declara como extensión.
- **No** incluirá convocatorias posteriores a 2021 (si 2023 se publicara a tiempo, se documenta como limitación, no se re-escopea).

5.2. Riesgos principales y plan de contingencia

1. **Discrepancia de datos (77 237 declarados vs. 50 891 en el artefacto).** Ya detectada y caracterizada. Contingencia: se audita sobre el artefacto disponible y se documenta la discrepancia como hallazgo (es parte del objetivo, no un bloqueo).
2. **Dataset de producción no descargable (1,2 GB, disponibilidad intermitente).** Contingencia: OE1–OE3 no dependen de él; se procesa si está disponible y se documenta la extensión.
3. **Tiempo insuficiente para la inferencia completa.** Contingencia: se priorizan los entregables por hito y la holgura del cronograma (2 semanas) absorbe retrasos puntuales.

5.3. Cronograma por hitos (12 semanas)

Tabla 2: Cronograma por hitos con entregables verificables

Semanas	Hito	Entregable verificable
1–2	Datos abiertos y contratos	Scripts de ingesta/validación + catálogo actualizado (enlace y licencia verificados)
3–4	Auditoría de calidad (OE1)	Tabla de indicadores de calidad por convocatoria + informe breve
5–6	Panel longitudinal (OE2, parte 1)	Matrices de transición con IC y test de markovianidad
7–8	Supervivencia (OE2, parte 2)	Curvas Kaplan–Meier + modelo Cox con covariables
9–10	Equidad (OE3)	Indicadores HHI/Gini/Theil + razones de representación con IC

Semanas	Hito	Entregable verificable
11	Marco de indicadores y tablero	Tablero de auditoría + marco de indicadores
12	Documentación y sustentación	Informe final reproducible + guion de sustentación

Holgura: semanas 6 y 11 incluyen margen de 2 semanas acumuladas para imprevistos.

Presupuesto de horas: cada integrante dedicará **6 horas semanales** (1 hora diaria después de clases, en la noche, 6 días a la semana) $\times$ 3 integrantes $\times$ 12 semanas $\approx$ **216 horas** disponibles; la carga estimada del plan es de **180 horas**, dejando **36 horas (17 %)** de holgura.

6. Declaración de uso de herramientas de IA y reparto del trabajo

6.1. Reparto del trabajo

- **Kevin Leonardo Chaparro Reyes** — rol principal: ingesta y auditoría de calidad de los datos (OE1); responsable de la reproducibilidad del pipeline; revisó el conjunto.
- **Valentina Muñoz Palma** — rol principal: análisis longitudinal (OE2: panel, transiciones y supervivencia) y programación estadística; revisó el conjunto.
- **Paula Margarita Triana Ancinez** — rol principal: estado del arte, análisis de equidad (OE3) y coordinación de la redacción y la sustentación; revisó el conjunto.

Todos los integrantes leyeron y pueden defender la totalidad del anteproyecto; ninguna sección fue redactada por un solo integrante sin revisión de los demás. (*Ajustable a la división real del trabajo.*)

6.2. Uso declarado de herramientas de IA

Usamos herramientas de IA generativa y agentes autónomos como **apoyo**, no como autores. Específicamente:

- **Cuánto se usó:** de forma **intensiva como asistente de análisis y redacción:** la mayoría de los borradores, fichas de auditoría y material de apoyo se generaron con IA; **todo el contenido final fue revisado, corregido y aprobado por los tres integrantes** antes de la entrega.
- **Para qué se usó:** análisis y documentación de código del repositorio de referencia, generación de fichas de auditoría, búsqueda y síntesis de literatura para el estado del arte, redacción de borradores y revisión de redacción, y propuesta de estructura del documento.
- **Validación en dos niveles, como lo solicitó el equipo:** (i) el **propio agente** que generó el material autoverificó cada afirmación **empíricamente** (ejecución real de los scripts, filas reales del XLSX, 133 commits con `git log`, exit codes de 16 scripts) y con reglas automáticas; (ii) **agentes de validación independientes solicitados por el equipo** revisaron hechos, reglas de construcción, referencias (0 inventadas) y la rúbrica (bloques D y S); sus informes quedaron archivados en `data/validacion/`.
- **Qué se descartó porque estaba mal (casos concretos):** (1) un agente afirmó que el código comparaba la cadena **SÍ** con un dato **SI** y que la métrica de víctimas colapsaría a cero; al leer el código y ejecutarlo se verificó que la normalización previa lo resolvía: la

afirmación se corrigió. (2) Un agente reportó un «orden alfabético» de archivos que en realidad era canónico por capa (artefacto de su propio verificador); se corrigió. (3) Un agente generó texto con un error de codificación (SÃ por Sı) que se detectó y corrigió en la revisión final.

6.3. Riesgos éticos del proyecto y marco legal

El proyecto trata **datos personales** del padrón público (identificadores de persona, edad, geolocalización) e incluye **categorías sensibles** auto-declaradas: grupo étnico, condición de discapacidad y condición de víctima del conflicto. El marco legal aplicable en Colombia es la **Ley 1581 de 2012** (protección de datos personales). Nuestras medidas: (i) no publicar microdatos identificables: los análisis se publican agregados y se mantiene la «gran tabla sin identificadores» como estándar, porque incluso los datos seudonimizados pueden ser reidentificables en ciertas condiciones (Rocher et al., 2019); (ii) declarar la finalidad y el tratamiento en la documentación del proyecto; (iii) tratar las variables sensibles con especial cuidado interpretativo (son auto-declaradas y solo comparables en la ventana 2021). El riesgo de sesgo se mitiga declarando explícitamente los supuestos y las limitaciones de cada indicador.

6.4. Gestión de la información del agente de IA

Usamos IA generativa como **asistente**, no como autora. Para que ese uso fuera **verificable** y no produjera contradicciones entre los documentos del proyecto, implementamos una estrategia de gestión de información del agente con tres piezas, todas ejecutables y ejecutadas sobre los datos reales.

(i) Memoria semántica (RAG). Indexamos el corpus documental —secciones de los seis criterios, sus versiones LITE, el documento maestro, los once informes de validación y este anteproyecto— en **145 fragmentos de 25 documentos** ($\approx 105\,000$ palabras). En su primera versión la recuperación se resolvió con **TF-IDF (1–2 gramas, sublinear.tf) y similitud coseno** (decisión D002), suficiente a esa escala y sin dependencias externas. **El docente decidió después migrar a embeddings vía API key** (decisión D007) para que el proyecto sea transferible y reproducible por otros equipos, dado que un “diccionario” de términos es incómodo de mantener; esa migración queda **pendiente de implementación** y así lo declara la bitácora de decisiones, de modo que el cambio no se pierde: la regla R15 lo detecta y falla mientras el código siga en TF-IDF. Antes de redactar, el generador consulta esta memoria y registra los antecedentes (`data/memoria/consultas_rag.jsonl`); si la similitud supera 0,35 avisa de posible solapamiento.

(ii) Memoria estructural (grafo). El proyecto se modela como un grafo dirigido de **255 nodos y 498 aristas**: Criterio $\rightarrow$ Documento (completo/LITE), Documento $\rightarrow$ TérminoGlosario, ArchivoCodigo $\rightarrow$ Capa, Commit $\rightarrow$ Autor. Se construye con **networkx** a partir de los metadatos que ya eran fuente de verdad (`objetivos.yaml`, `glosario.yaml`, `capas.yaml`, `commits_timeline.csv`, `inventario_codigo.csv`) **más datos vivos del repositorio auditado**: `git log` y `git ls-files` sobre el clon real en el commit 1528939. No se usó un motor de grafos externo (Neo4j/Memgraph): con decenas de nodos y consultas simples no aporta ventaja y sí costo de operación.

(iii) Validación antes de compilar. Dieciséis reglas se ejecutan como **puerta previa a la compilación del PDF final**, integradas en `compilar.py` (si alguna falla, la compilación se aborta; puede omitirse con `-forzar`). Las seis mínimas exigidas —cada criterio con completo y

LITE; conclusiones registradas; veredicto resumido en el LITE; términos del glosario realmente usados; línea de tiempo coincidente con el `git log` real; y todo archivo de código referenciado en el documento del criterio de código— más diez adicionales: commit auditado, capas asignadas por regla explícita, cobertura de fichas, integridad del grafo, cobertura y frescura del índice, $\text{LITE} \leq 40\%$, **contradicciones numéricas entre documentos** (R14), **coherencia entre las decisiones y el código** (R15) e **integridad de los registros de trazabilidad** (R16). Resultado de la ejecución final: **14 PASA, 1 FALLA, 1 ADVERTENCIA**, con coincidencia exacta de **133/133 commits** y **51/51 archivos** entre lo documentado y el repositorio real. La única falla es, precisamente, el desfase declarado de D007 (el código sigue en TF-IDF), que la regla reporta con archivo y marcador.

(iv) Trazabilidad de fuentes externas y de decisiones. Dos registros en `data/memoria/` documentan el trabajo del agente. `fuentes_externas.yaml` registra cada fuente consultada (documentación, comparativas, especificaciones) con su URL verificada, fecha, para qué se usó y qué archivo del proyecto depende de ella; la regla R16 falla si alguna URL queda como “PENDIENTE”. `decisiones.yaml` es la bitácora de decisiones de diseño (7 registradas) con justificación, alternativas descartadas, estado (*vigente*, *superada*, *propuesta*, *pendiente_implementacion*) y la relación de supersesión explícita (p. ej. D007 supera a D002). La regla R15 verifica que ninguna decisión superada siga implementada en el código ni presentada como vigente en los documentos, y que exista una sola decisión actual por tema.

Las reglas detectaron tres defectos reales del material, corregidos en la fuente de verdad y registrados con su evidencia en `data/memoria/validacion_reglas.json`: el LITE del criterio 3 no tenía veredicto declarado; el término “ETL” figuraba en el glosario sin usarse en ningún documento; y el inicializador `src/__init__.py` no tenía capa asignada. La única advertencia restante es una sección de relación entre criterios que el LITE comparte con el documento completo de forma deliberada.

Referencias

- Cañibano, C., & Bozeman, B. (2009). Curriculum vitae method in science policy and research evaluation: The state-of-the-art. *Research Policy*, 38(2), 259–266. <https://doi.org/10.1016/j.respol.2008.09.014>
- Categorización de grupos e investigadores ante el sistema nacional de ciencia, tecnología e innovación en Colombia. (2023). *Universidad y Sociedad*, 15(5). <http://scielo.sld.cu/scielo.php?pid=S2218-36202023000500133>
- Clauset, A., Arbesman, S., & Larremore, D. B. (2015). Systematic inequality and hierarchy in faculty hiring networks. *Science Advances*, 1(1), e1400005. <https://doi.org/10.1126/sciadv.1400005>
- CoARA. (2022). *Agreement on reforming research assessment*. <https://coara.eu/agreement/the-agreement-full-text/>
- Crenshaw, K. (1989). Demarginalizing the intersection of race and sex: A Black feminist critique of antidiscrimination doctrine, feminist theory and antiracist politics. *University of Chicago Legal Forum*, 1989, 139–167.
- Departamento Nacional de Planeación. (2021). *CONPES 4069: Política Nacional de Ciencia Abierta*. <https://colaboracion.dnp.gov.co/CDT/Conpes/Económicos/4069.pdf>
- Deville, P., Song, C., Sinatra, R., Wang, D., & Barabási, A.-L. (2014). Career on the move: Geography, stratification, and scientific impact. *Proceedings of the National Academy of Sciences*, 111(42), 14472–14476. <https://doi.org/10.1073/pnas.1407385111>
- DORA. (2012). *San Francisco Declaration on Research Assessment*. <https://sfdora.org/>
- Fortunato, S., Bergstrom, C. T., Börner, K., Evans, J. A., Helbing, D., Milojević, S., Petersen, A. M., Radicchi, F., Sinatra, R., Uzzi, B., et al. (2018). Science of science. *Science*, 359(6379), eaao0185. <https://doi.org/10.1126/science.aao0185>
- Frenken, K., Hardeman, S., & Hoekman, J. (2009). Spatial scientometrics: Towards a cumulative research program. *Journal of Informetrics*, 3(3), 222–232. <https://doi.org/10.1016/j.joi.2009.03.005>
- Hicks, D., Wouters, P., Waltman, L., de Rijcke, S., & Rafols, I. (2015). The Leiden Manifesto for research metrics. *Nature*, 520(7548), 429–431. <https://doi.org/10.1038/520429a>
- Kemeny, J. G., & Snell, J. L. (1976). *Finite Markov chains*. Springer.
- Larivière, V., Ni, C., Gingras, Y., Cronin, B., & Sugimoto, C. R. (2013). Bibliometrics: Global gender disparities in science. *Nature*, 504(7479), 211–213. <https://doi.org/10.1038/504211a>
- Ley 1581 de 2012. Por la cual se dictan disposiciones generales para la protección de datos personales. Congreso de la República de Colombia.
- Mena-Chalco, J. P., & Cesar Júnior, R. M. (2009). ScriptLattes: integração de dados curriculares à plataforma Lattes. *Conferência sobre Tecnologia, Cultura e Sociedade*.
- Ministerio de Ciencia, Tecnología e Innovación. (2021). *Investigadores reconocidos por convocatoria* [Conjunto de datos]. [datos.gov.co](https://www.datos.gov.co/resource/bqtm-4y2h.csv). <https://www.datos.gov.co/resource/bqtm-4y2h.csv>
- Ministerio de Ciencia, Tecnología e Innovación. (2021). *Producción de grupos de investigación* [Conjunto de datos]. [datos.gov.co](https://www.datos.gov.co/resource/33dq-ab5a.csv). <https://www.datos.gov.co/resource/33dq-ab5a.csv>

- Newman, M. E. J. (2001). The structure of scientific collaboration networks. *Proceedings of the National Academy of Sciences*, 98(2), 404–409. <https://doi.org/10.1073/pnas.98.2.404>
- Petersen, A. M., Riccaboni, M., Stanley, H. E., & Pammolli, F. (2012). Persistence and uncertainty in the academic career. *Proceedings of the National Academy of Sciences*, 109(14), 5213–5218. <https://doi.org/10.1073/pnas.1121429109>
- Revista Iberoamericana de Ciencia, Tecnología y Sociedad. (2010). Dos países latinoamericanos cuentan actualmente con sistemas de información curricular consolidados: Brasil y Colombia. *CTS*, 5(13). <https://www.revistacts.net/wp-content/uploads/2020/01/vol5-nro13-cts13.pdf>
- Rocher, L., Hendrickx, J. M., & de Montjoye, Y.-A. (2019). Estimating the success of re-identifications in incomplete datasets: Generating insights from attacks. *Nature Communications*, 10, 3069. <https://doi.org/10.1038/s41467-019-10933-3>
- Sinatra, R., Wang, D., Deville, P., Song, C., & Barabási, A.-L. (2016). Quantifying the evolution of individual scientific impact. *Science*, 354(6312), aaf5239. <https://doi.org/10.1126/science.aaf5239>
- Souza, R., Skluzacek, T., Wilkinson, S., Ziatdinov, M., & da Silva, R. (2023). *Towards lightweight data integration using multi-workflow provenance and data observability*. IEEE eScience (preprint). <https://arxiv.org/abs/2308.09004>
- Sugimoto, C. R., Robinson-García, N., Murray, D. S., Yegros-Yegros, A., Costas, R., & Larivière, V. (2017). Scientists have most impact when they’re free to move. *Nature*, 550(7674), 29–31. <https://doi.org/10.1038/550029a>
- Theil, H. (1967). *Economics and information theory*. North-Holland.
- Wang, D., & Barabási, A.-L. (2021). *The science of science*. Cambridge University Press.
- Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33. <https://doi.org/10.1080/07421222.1996.11518099>
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., Appleton, G., Axton, M., Baak, A., et al. (2016). The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <https://doi.org/10.1038/sdata.2016.18>