
Guía de estudio — Sustentación

Entrega 1 · Anteproyecto · Consultoría Estadística · USTA 2026-II

Kevin Leonardo Chaparro Reyes · Valentina Muñoz Palma · Paula Margarita Triana Ancinez

Reglas de la rúbrica (60 % de la nota)

- La sustentación pesa 60 %; **S1 es individual**: cada quien debe poder defender el *conjunto*, no solo su bloque.
- Este guion reparte los bloques, pero **todos deben poder responder cualquier pregunta** (banco al final).
- Nota individual $\leq S1 + 1,0$: quien no defiende bien su S1 arrastra a su nota individual, sin importar el resto.

Reparto sugerido de la exposición (10 min)

#	Diapositiva	Quién presenta	Tiempo
1	Título (presentación)	Cualquiera (30 s)	0:00–0:30
2	El problema: qué audita	Kevin	0:30–1:30
3	Evidencia propia (cifras)	Kevin	1:30–2:45
4	La pregunta estadística	Valentina	2:45–3:30
5	Estado del arte y vacío	Paula	3:30–5:00
6	Objetivos	Valentina	5:00–6:00
7	Datos y método	Kevin	6:00–7:15
8	Alcance y riesgos	Paula	7:15–8:00
9	Por qué cabe en el semestre	Valentina	8:00–9:00
10	Cierre	Paula	9:00–10:00

Frases clave por bloque (decirlas, no leerlas)

1. **Problema [Kevin]**: “MinCiencias reconoce a los investigadores por convocatorias y ese padrón alimenta decisiones de política y de carrera. Nadie ha auditado si ese registro es confiable, comparable y equitativo.”
2. **Evidencia [Kevin]**: “No lo decimos por intuición: el padrón público declara 77 237 registros, pero al abrirlo encontramos 50 891 filas con 26 662 personas únicas y solo 3 de 6 convocatorias (781/2017, 833/2018 y 894/2021); 22 edades superan los 100 años; Bogotá y Antioquia concentran el 51 %; 24 % de mujeres en Ingeniería frente a 48 % en ciencias médicas.”
3. **Pregunta [Valentina]**: “Traducimos eso a una pregunta estadística respondible: ¿el padrón es fiable, comparable entre convocatorias y equitativo?”
4. **Estado del arte [Paula]**: “La literatura de la *science of science* y las métricas responsables ya fijó cómo auditar indicadores; en Colombia hay crítica al modelo pero no evidencia cuantitativa reproducible. Ese es el vacío que atendemos. Contrastamos dos enfoques: Markov y supervivencia.”
5. **Objetivos [Valentina]**: “Un general y tres específicos: calidad, dinámica longitudinal y equidad. Cada uno tiene evidencia de cumplimiento.”
6. **Datos [Kevin]**: “Todo son datos abiertos ya abiertos por nosotros: bqtm-4y2h y 33dq-ab5a en datos.gov.co. Método reproducible en Python.”

7. **Riesgos [Paula]:** “El riesgo principal —la discrepancia de datos— ya es un hallazgo del objetivo, no un bloqueo; tenemos holgura de dos semanas.”
8. **Cierre [Paula]:** “Entregamos un marco de indicadores y un tablero para que MinCiencias sepa qué tan confiable y equitativo es su sistema.”

Banco de preguntas probables (rúbrica págs. 12–13) y respuestas-plantilla

- P1. ¿Quién sufre este problema y desde cuándo? [Kevin/Paula]** — MinCiencias y el SNCTI desde 2013 (6 convocatorias); investigadores cuya categoría condiciona su carrera; política pública que usa el padrón.
- P2. ¿Cómo se resuelve hoy sin ustedes?** — Con análisis descriptivos y críticas normativas; sin auditoría reproducible de calidad/equidad del registro.
- P3. ¿Qué pasa si nadie hace nada?** — Decisiones de política sobre un instrumento no auditado; inequidades no cuantificadas.
- P4. ¿Qué fuente los hizo cambiar de idea? [Paula]** — Las críticas al modelo de categorización colombiano + la evidencia propia de 50 891 vs. 77 237: el problema no era solo de diseño, era de registro.
- P5. ¿Qué hicieron distinto los dos enfoques que contrastan? [Valentina]** — Markov supone homogeneidad; supervivencia modela el tiempo al evento con covariables; los contrastamos porque el supuesto markoviano puede violarse.
- P6. ¿Por qué no es una repetición de lo ya leído? [Paula]** — Porque no existe la combinación calidad + longitudinal + equidad reproducible sobre estos datos abiertos.
- P7. Si cumplen los tres específicos, ¿ya resolvieron el general? [Valentina]** — Sí: calidad + comparabilidad + equidad agotan el general; el tablero y el marco de indicadores son producto final.
- P8. ¿Con qué evidencia declaran cumplido el objetivo 2?** — Matrices de transición con IC, curvas Kaplan–Meier y un modelo Cox reproducibles.
- P9. ¿Cuál de sus objetivos es en realidad una actividad? [todos]** — Ninguno: los tres empiezan con verbos verificables (cuantificar, estimar, cuantificar) y declaran evidencia.
- P10. ¿Alguien ya abrió el archivo? ¿Cuántas filas tiene? [Kevin]** — Sí: XLSX verificado con 50 891 filas $\times$ 30 columnas; **26 662 personas únicas** (ID_PERSONA_PR); 3 convocatorias (781/2017, 833/2018 y 894/2021). Ojo: la 833 es “de 2018”, pero su ANO_CONVO dice 06/12/2019 (fecha de resolución): el “2019” no es una cuarta convocatoria.
- P11. ¿Qué variable responde al primer objetivo específico?** — EDAD_ANOS_PR, ID_PERSONA_PR (unicidad), ID_CONVOCATORIA/ANO_CONVO.
- P12. ¿Qué hacen si en octubre el dato no llega? [Kevin]** — OE1–OE3 no dependen de la producción ($\sim 1,2$ GB); el cruce con producción ya se ejecutó para la línea base (el 36,9 % es resultado archivado), así que ningún objetivo específico queda bloqueado; si hace falta actualizar, redescarga por API Socrata con contratos.
- P13. ¿Qué decidieron dejar por fuera y por qué? [Paula]** — producción individual (h), modelos predictivos individuales y causalidad: fuera del alcance semestral y/o del dato.
- P14. ¿Qué es lo más probable que salga mal? [Kevin]** — La discrepancia del consolidado; ya está caracterizada y es parte del hallazgo.
- P15. ¿Cuántas horas por semana reales?** — 1 h diaria después de clases, en la noche, 6 días a la semana por integrante = $6 \text{ h} \times 3 \text{ integrantes} \times 12 \text{ semanas} = 216 \text{ h}$; carga estimada 180 h; 36 h de holgura (17 %).
- P16. Explíquemelo usted, que no redactó esa sección** — Cada quien practica el bloque de los

demás (rotar: Kevin explica objetivos; Paula explica datos; Valentina explica riesgos).

- P17. ¿Qué alternativa consideraron y por qué la descartaron? [Kevin]** — Producción individual con *h*: descartada por volumen (~1,2 GB) y foco.
- P18. Si le digo que su tercer objetivo sobra, ¿qué responde? [Valentina]** — Sin equidad el general queda incompleto: la pregunta incluye la dimensión distributiva explícitamente.
- P19. Resuma el problema en dos frases** — “El registro oficial de investigadores reconocidos no ha sido auditado. Queremos saber si es confiable, comparable y equitativo, con evidencia reproducible.”
- P20. ¿Qué les devolvió la IA que descartaron? [cualquiera]** — Un agente afirmó un bug falso (el “SÍ” de `diversidad.py`) y un orden alfabético que era canónico; se corrigieron al verificar el código.
- P21. ¿Qué riesgo ético tiene este proyecto? [Paula]** — Datos personales y categorías sensibles (etnia, discapacidad, víctimas): Ley 1581 de 2012; no publicamos microdatos identificables (la seudonimización no elimina el riesgo de reidentificación; Rocher et al., 2019).
- P22. ¿Cuál fue exactamente su aporte humano frente a la IA? [cualquiera]** — El problema, el alcance y las exclusiones (D1/D5) los decidió el equipo; la pregunta, los objetivos y el contraste Markov vs. supervivencia (D2/D3/D4) los eligió el equipo; los scripts se ejecutaron y auditaron con criterio humano; la interpretación, qué se descarta, qué se publica y la revisión final fueron humanas. La IA fue asistente, no autora.
- P23. ¿Quién escribió qué y quién revisó qué? [cualquiera]** — Kevin: ingesta y calidad (OE1) + reproducibilidad; Valentina: longitudinal (OE2) + programación estadística; Paula: estado del arte + equidad (OE3) + coordinación. Todos revisaron el conjunto (sección 6.1); cualquiera responde cualquier bloque (S1).
- P24. ¿Por qué empezaron por el problema y no por los datos? [Kevin]** — Porque el problema es la puerta bloqueante (D1) y determina qué datos se necesitan, no al revés; además ya tenía evidencia propia (50 891 vs. 77 237) que orientó el diseño.
- P25. Con solo dos transiciones (2017→2019→2021), ¿qué estiman con Kaplan–Meier/Cox? [Valentina]** — Modelamos la permanencia entre ondas consecutivas como supervivencia discreta/por intervalos; es un análisis acotado y exploratorio, y el contraste con Markov es metodológico (supuestos distintos), no una promesa de inferencia fina.

Checklist 5 minutos antes

- ☐ Portada con los tres nombres (PDF del anteproyecto).
- ☐ Llevar el PDF del anteproyecto, las diapositivas y esta guía.
- ☐ Memorizar los números críticos y que coincidan en documento, láminas y boca: 77 237 declarados vs. 50 891 filas y **26 662 personas únicas** verificadas; convocatorias 781/2017, 833/2018 y 894/2021 (el “2019” es la fecha de resolución de la 833/2018).
- ☐ Cada quien domina los bloques de los demás (rotación de 5 min).
- ☐ Respuestas orales de IA listas (cuánto/para qué/validación en 2 niveles/3 descartes) coherentes con la sección 6.2.
- ☐ Plan B si falla el proyector: las cifras clave van en esta guía.
- ☐ Cronómetro: 10 min sin recortar el cierre.