

Entrega 3 — Sistema de fuentes y trazabilidad

Auditoría del Observatorio MinCiencias — USTA 2026-II

Equipo: Kevin, Valentina, Paula

1. Qué es el sistema

El proyecto usa dos piezas complementarias para gestionar la información que produce el agente de IA, ambas corriendo localmente sin depender de un proveedor en la nube:

Memoria semántica (RAG). Indexa el corpus documental del proyecto — 150 fragmentos de 25 documentos (los 6 criterios completos y sus versiones LITE, el maestro de auditoría, el anteproyecto, y 11 informes de validación), 116 290 palabras en total — usando TF-IDF (1–2 gramas, `sublinear_tf`) y similitud coseno. Antes de que el agente redacte una sección nueva, consulta este índice para no contradecir lo que ya está escrito en otro documento del proyecto.

Memoria estructural (grafo). Un grafo de 255 nodos y 498 relaciones (`networkx`) que modela Criterio → Documento (completo/LITE) → Término de glosario, Commit → Autor, y Archivo de código → Capa. Se construye a partir de los metadatos ya existentes del proyecto (`objetivos.yaml`, `glosario.yaml`, `capas.yaml`, `commits_timeline.csv`) y se extiende con datos en vivo del repositorio auditado real, clonado directamente con git en vez de depender de una copia congelada. Se verificó que el commit auditado documentado (1528939) coincide exactamente con el HEAD real del clon.

Sobre ambas piezas corren **17 reglas de validación automáticas**, que revisan tres tipos de coherencia: la consistencia interna del corpus, la coincidencia entre lo documentado y el repositorio auditado real, y —a partir de la regla R17— la sincronización entre las cifras del propio sistema y los documentos que las citan. El resultado real de la última corrida, verificada directamente sobre el repositorio:

Resultado	Cantidad
PASA	15
ADVERTENCIA	1
FALLA	1

2. Vía elegida

Vía propia: RAG local (TF-IDF) + grafo en memoria (`networkx`), sin motor de base de datos externo ni servicio de embeddings en la nube. Se prefirió sobre la vía empaquetada o gestionada porque el equipo ya contaba con un corpus documental propio e indexable, y porque correr localmente evita enviar documentos del proyecto —algunos con datos derivados del repositorio auditado— a un proveedor externo.

3. Tabla de trazabilidad

La siguiente tabla mapea 15 afirmaciones factuales del anteproyecto a su fuente exacta. Se construyó consultando cada documento y verificando la fuente contra el repositorio auditado, no contra la memoria del agente que redactó. Por legibilidad se presenta en dos partes.

Parte 1 — Afirmaciones del anteproyecto

#	Afirmación	Doc.	Ubic.	Fuente	¿V.?
1	6 convocatorias 2013–2021 (640/2013 ... 894/2021)	01_problema	§1.1	Repo auditado: <code>catalogo.yaml</code>	SÍ
2	77 237 registros, 6 convocatorias, 30 086 únicos	01_problema	§1.2	README.md + <code>catalogo.yaml</code>	SÍ
3	50 891 filas, 3 convocatorias, 26 662 únicos	01_problema	§1.2	<code>consolidado.xlsx</code> + <code>calidad_resumen.json</code>	SÍ
4	22 registros con edad > 100 (máx. 956)	01_problema	§1.2	<code>calidad_resumen.json</code> dice 19; el 22 viene del informe sobre 77 237 filas	NO
5	Bogotá + Antioquia = 51 % de investigadores	01_problema	§1.2	Depende del año: 52,0 % (2017), 47,9 % (2021)	PARC.
6	Retención de Bogotá 92 %; absorbe > 1 000	01_problema	§1.2	<code>geografia_resumen.csv</code> : 91,8 % y 1 705	SÍ
7	24 % mujeres en Ingeniería (vs. 48 % médicas)	01_problema	§1.2	<code>genero_pct_femenino.csv</code> : 25,7–26,5 %	PARC.
8	Afro 3×, indígena 7,9×, discapacidad 8×	01_problema	§1.2	<code>diversidad_comparacion_dane.csv</code> : 3,0 / 7,9 / 8,0	SÍ

Parte 2 — Afirmaciones del método y del propio sistema

#	Afirmación	Doc.	Ubic.	Fuente	¿V.?
9	36,9 % de autores únicos son investigadores reconocidos	01_problema	§1.2	Sin fuente en ningún artefacto; no recomputable (dataset fuera del repo)	NO

#	Afirmación	Doc.	Ubic.	Fuente	¿V.?
10	Tabla 1: 77 237 / 30 086 / 3 166 629 filas / 30 vars.	04_datos	§4.1	README.md + catalogo.yaml + XLSX	SÍ
11	El cruce requiere ~1,2 GB; disponibilidad intermitente	04_datos	§4.3	README.md del repo auditado	SÍ
12	Estado del arte: 20 págs., 39 referencias	02_estado	§2	estado_del_arte.pdf + refs.bib	SÍ
13	RAG: 150 fragmentos, 25 docs, 116 290 palabras	06b_memoria	§6.2(i)	rag_indice.json + rag.py	SÍ
14	Grafo: 255 nodos, 498 aristas	06b_memoria	§6.2(ii)	grafo_resumen.json	SÍ
15	17 reglas: 15/1/1; 133 commits; 51 archivos; R15 falla	06b_memoria	§6.2(iii)	validacion_reglas.json + CSVs	SÍ

Resumen de la tabla: 11 verificadas (73 %), 2 parciales (13 %), 2 no verificadas (13 %).

4. Hallazgos del sistema de trazabilidad

La tabla anterior no es decorativa: al construirla, el sistema detectó cuatro problemas reales en los documentos del propio equipo, más un defecto en el repositorio auditado.

Hallazgo 1 — Cifra sin respaldo en el anteproyecto

La afirmación “*se detectaron 22 registros con edad mayor a 100*” (01_problema.tex, §1.2) no coincide con el artefacto real del repo auditado. El archivo evidencias/calidad_resumen.json registra `n_atipicos_edad`: 19 con umbral 100. El conteo directo sobre investigadores_consolidado.xlsx confirma **19**. El “22” proviene del informe del repo auditado, calculado sobre el universo declarado de 77 237 filas — no sobre el consolidado disponible de 50 891 que el anteproyecto dice estar verificando. Además, el propio repo auditado se contradice internamente (22 en informe_final.tex, 10 en inventario_notebooks.md, 19 en calidad_resumen.json).

Causa técnica: el agente que redactó el anteproyecto tomó la cifra del informe narrativo del repo auditado en vez del artefacto calculado, sin verificar que el universo de referencia fuera el mismo.

Hallazgo 2 — Cifra sin fuente

La afirmación “*solo el 36,9 % de los autores únicos que firman la producción son investigadores reconocidos*” (01_problema.tex, §1.2) no tiene respaldo en ningún artefacto del repositorio. Ningún CSV de evidencias/ contiene ese valor, y no es recomputable localmente porque el dataset de producción (~1,2 GB) está fuera del repo (`gitignored`).

Causa técnica: cifra generada sin verificación contra fuente, en un dominio donde el dato de origen no es auditable desde un clon del repositorio.

Hallazgo 3 — Cifra imprecisa

“*Bogotá y Antioquia concentran el 51 %*” (01_problema.tex, §1.2). Ningún artefacto dice 51 %. El valor depende del año: 52,0 % en 2017, 47,9 % en 2021, 49,7 % del total. La afirmación es defendible si se cita el año, pero sin él es imprecisa.

Hallazgo 4 — Confusión de métrica

“*24 % de mujeres en Ingeniería*” (01_problema.tex, §1.2). La evidencia (genero_pct_femenino_por_gran_area.csv) reporta 25,7–26,5 % en Ingeniería. El valor 24,04 que aparece en el repo auditado corresponde a **promedio de productos por mujer**, no a porcentaje de mujeres. Es una confusión entre dos métricas distintas.

Hallazgo 5 — Defecto de procedencia en el repositorio auditado

El archivo evidencias/diversidad_comparacion_dane.csv etiqueta la fila VICTIMA CONFLICTO con `pct_dane_2018 = 17.7`. Ese valor en realidad proviene del **RUV 2021**, no del censo DANE

2018 — así lo dice el comentario del propio código (`src/analisis/diversidad.py:25`), pero el mismo archivo (`diversidad.py:103`) exporta toda referencia bajo el nombre `pct_dane_2018` sin distinguir la fuente. El anteproyecto acierta al decir que el censo no captura la condición de víctima; el error está en el repositorio auditado.

5. Autoauditoría: el sistema detectó y corrigió un defecto propio

Esta sección documenta el ciclo completo de un defecto real detectado durante la construcción del banco de evaluación del sistema (Entrega 4). No es un error oculto: es un hallazgo del propio sistema, medido, corregido, y registrado en la bitácora de decisiones.

El defecto

Al correr el banco de evaluación del RAG (20 preguntas con respuesta conocida), 5 preguntas resultaron irrespondibles y varias otras quedaron mal rankeadas. La causa no era TF-IDF: el propio indexador tenía un defecto. En `documentacion_auditoria/src/memoria/rag.py`, línea 85:

```
t = re.sub(r"^\s*\|.*$", , t, flags=re.M) # filas de tabla
```

Esa línea borraba las filas de tabla completas antes de indexar, no solo los delimitadores. Medido sobre las 11 fuentes de validación: 329 filas descartadas y el **37,0 %** del texto perdido. Además, la línea 87 eliminaba el carácter `_`, degradando identificadores como `n_atipicos_edad` a `n atipicos edad` antes de indexar.

La corrección

El arreglo fue de dos líneas de código: reemplazar el borrado de filas de tabla por limpieza de la sintaxis (conservar el contenido, eliminar solo los delimitadores) y quitar el `_` de la lista de caracteres a eliminar en markdown. Después se reindexó. El efecto medido:

Métrica	Antes	Después
Fragmentos indexados	145	150
Palabras indexadas	105 167	116 290
Texto de validación indexado	158 184 car. (63,0 %)	235 949 car. (94,0 %)
Top-1 con la respuesta correcta	3/20	9/20
Alucinaciones latentes	5	1

El caso emblemático fue una pregunta sobre el número de registros con edad mayor a 100 en el consolidado (19): antes de la corrección era irrespondible (su dato vivía en una tabla, y las tablas se descartaban); después está en el índice.

El registro en la bitácora

La corrección quedó registrada como decisión **D008** en `data/memoria/decisiones.yaml`, con la justificación, las alternativas descartadas (dejar el bug documentado sin corregir; solo arreglar tablas sin tocar el carácter `_`) y las métricas antes/después.

6. R17: una regla que vigila que el sistema no se contradiga a sí mismo

Al corregir el defecto anterior, el corpus pasó de 145 a 150 fragmentos. Esa cifra estaba citada en 6 documentos del proyecto (la sección 6.2 del anteproyecto, el README, la guía de defensa, el archivo de texto de la sección, la evidencia de validación, y la Q8 del banco), y **ninguna de las 16 reglas existentes la detectó**. Ese era un hueco real de trazabilidad: el sistema vigilaba la coherencia del corpus, pero no la coherencia entre sus propias cifras y los documentos que las citaban.

Se agregó la regla **R17** (`src/memoria/reglas.py`), que vigila tres tipos de cita:

- **7 cifras del sistema:** fragmentos, palabras, términos, nodos, aristas, reglas, decisiones. Compara lo que citan los documentos contra las fuentes de verdad (`rag_indice.json`, `grafo_resumen.json`, `decisiones.yaml`).
- **El recuento de estados:** que los documentos citen el mismo resultado (15 PASA · 1 FALLA · 1 ADVERTENCIA) que arroja la última corrida.
- **Los estados de regla citados en el banco de evaluación:** si una pregunta del banco cita “R15 = FALLA”, R17 verifica que ese estado siga siendo el real.

R17 se auditó a sí misma: en su primera corrida detectó 26 cifras desactualizadas en 5 documentos, incluyendo 3 sitios que la revisión manual no había localizado (el vocabulario de la guía, una segunda mención de “137 fragmentos” en el texto histórico, y dos menciones de “Trece reglas”). Después de actualizar esos sitios, R17 pasa con 49 citas verificadas.

Prueba de que R17 muerde

Para verificar que la regla no es decorativa, se simuló que R15 cambiara a PASA (como si la decisión D007 se hubiera implementado) sin tocar ningún archivo del repositorio. R17 nombró entonces, con archivo y línea, cada uno de los 8 sitios que quedaban obsoletos: 7 documentos que citaban el recuento anterior, más la Q16 del banco que citaba “R15 = FALLA”. Con los estados reales, R17 pasa. Es decir: el sistema no solo se audita, se audita contra escenarios futuros.

7. R15 como fallo documentado, no como invención

La regla R15 compara las decisiones de diseño documentadas (`decisiones.yaml`) contra lo que el código realmente implementa. Resultado real de la última corrida:

“D002 está SUPERADA (D007) pero su implementación sigue en el código: `TfidfVectorizer` en `documentacion_auditoria/src/memoria/rag.py`”

En español: el equipo decidió (decisión D007) migrar de TF-IDF a embeddings siguiendo el pedido del docente de priorizar reproducibilidad, pero el código todavía no se actualizó — sigue usando TF-IDF. La regla lo detecta automáticamente y bloquea la compilación estándar del proyecto (`compilar.py` exige la bandera `-forzar` para saltarse esta validación).

Por qué se decidió no resolverlo antes de esta entrega: la rúbrica de la actividad pide explícitamente mostrar un caso donde el sistema propio falló, con su causa técnica. R15 fallando es

exactamente ese caso: un desfase real entre una decisión de diseño y su implementación, detectado por el propio sistema sin intervención externa, con causa técnica exacta y verificable. Se prefirió documentarlo tal como está, en vez de forzar una excepción o resolverlo apresuradamente.

R15 no es un caso de invención — es un desfase entre decisión de diseño y código. Los dos casos de invención real están en los Hallazgos 1 y 2.

8. Evidencia de “responde con cita”

Se corrió una consulta real contra el RAG del proyecto. El sistema devolvió fragmentos con su documento y ruta de archivo exactos, sin inventar ninguna fuente:

1. `cos=0.0686 anteproyecto::01_problema`
`documentacion_auditoria\latex\anteproyecto\secciones\01_problema.tex`
2. `cos=0.0555 validacion_anteproyecto_D.md::1. D1 -- Problema, contexto...`
`documentacion_auditoria\data\validacion\validacion_anteproyecto_D.md`